

PARECER TÉCNICO E AVALIAÇÃO ACADÊMICA DE DOUTORADO

Disciplina: EEE933 — Planejamento e Análise de Experimentos | PPGE - UFMG

Trabalho Avaliado: Estudo de Caso 01: Comparação do IMC médio de alunos do PPGE-UFG ao longo de dois semestres
Autores do Relatório: Beatriz S. Campagnaro, Izabela C. S. Barbosa, Filipe C. Andrade e Stephanie F. Lemos (28/08/2026)
Professor / Disciplina: Prof. Michel Bessani | EEE933 — Planejamento e Análise de Experimentos (PPGE/UFG)
Documentos de Referência: Especificação Oficial (EC01.pdf); Slides das Aulas 01 a 07 (Bessani); Relatório PDF e Rmd; Bases de Dados (2016-2 e 2017-2)
Nível da Avaliação: Pós-Graduação Estrito Senso (Padrão Doutorado em Engenharia Elétrica)

SÍNTESE DA AVALIAÇÃO DO AVALIADOR:
O trabalho apresenta mérito na padronização computacional e na introdução do teste TOST. Contudo, incorre em falhas metodológicas de alta gravidade: **omissão total de intervalos de confiança e tamanhos de efeito no relatório, inconsistência paramétrica** (TOST paramétrico em grupo com normalidade rejeitada), **desconhecimento da teoria do curso** (afirmação de inexistência de fórmula para o TOST quando os slides ensinam a fórmula de Zhang), **descumprimento de requisitos formais** (papéis da equipe omitidos) e **quebra de reprodutibilidade** nos caminhos dos arquivos. Nota atribuída: **6,3 / 10,0 (Grau C — Abaixo do padrão de Doutorado)**.

1. COMPREENSÃO DO QUE FOI PEDIDO (CHECKLIST DE REQUISITOS)

Confrontou-se o relatório com a especificação oficial da atividade (EC01.pdf). O trabalho atendeu integralmente aos requisitos de consolidação e separação por sexo, mas falhou criticamente na apresentação de estimativas de efeito, intervalos de confiança, papéis da equipe e reprodutibilidade do diretório de dados.

Item / Requisito do Enunciado	Status	Localização	Avaliação Crítica e Fundamentação
R01. Consolidação e filtro: Isolar PPGE (descartar ENGSIS 2016) e unificar bases.	ATENDIDO (Pleno)	Seção Coleta e Tratamento (p. 1–3)	Implementação correta via metaprogramação ('dplyr'), gerando N=28 (2016-2) e N=25 (2017-2).
R02. Estratificação por subpopulações: Testes independentes por gênero.	ATENDIDO (Pleno)	Seção Desenho Exp. e Chunks (p. 3–5)	Estratificação executada para M (21 vs 21) e F (7 vs 4).
R03. Definição formal de hipóteses: H0, H1, justificativa de direcionalidade.	PARCIAL	Seção Desenho Exp. (p. 3–4)	Apresenta as equações de H0 e H1, mas omite o modelo aditivo linear subjacente ($y = \mu + e$) e justificativa da simetria bilateral.
R04. Teste de hipóteses comparativo: Aplicação do teste de médias/postos.	ATENDIDO (Pleno)	Seção Análise Estatística (p. 7)	Aplicou Welch para homens e Mann-Whitney para mulheres.
R05. Tamanho do efeito e ICs: Reporte numérico na grandeza de interesse.	NÃO ATENDIDO (Crítico)	Omitido no texto e na tabela (p. 7)	O código calcula internamente, mas o texto e a tabela omitem a diferença observada (Delta_mu), Cohen's d e os ICs de 95% e 90%. Violação grave do enunciado.
R06. Verificação de premissas: Normalidade, homocedasticidade, independência.	PARCIAL	Seção Desenho (p. 4) e Fig. 1 (p. 6)	Avaliou apenas normalidade (Shapiro-Wilk). Homocedasticidade (Fligner) e independência (Durbin-Watson) foram omitidas.
R07. Discussão sobre potência do teste: Análise de poder e sensibilidade.	PARCIAL	Seções Desenho (p. 5) e Análise (p. 7)	Calculou n ideal a priori sob delta*, mas não calculou o poder retrospectivo real alcançado pelas amostras observadas.
R08. Propostas de melhoria experimental: Aprimoramento do delineamento.	PARCIAL	Seção Conclusões (p. 8)	Sugestão superficial (apenas questionários e mais amostra), sem abordar pareamento longitudinal ou controle de confundidores.
R09. Reprodutibilidade e paths: Execução no mesmo diretório do arquivo.	NÃO ATENDIDO	Chunk 'configuracao_fontes' (l. 45-66)	O código depende de subpasta 'Dados/' e do nome alterado 'imc_20172.csv' em vez de 'CS01_20172.csv', quebrando a compilação padrão.
R10. Papéis desempenhados pela equipe: Relator, verificador, etc.	NÃO ATENDIDO	Ausente em todo o relatório e Rmd	Instrução obrigatória do enunciado ignorada ('Importante: Inclua no relatório os papéis desempenhados por cada membro').

R11. Declaração de uso de IA generativa: Política padrão Elsevier/UFGM.	ATENDIDO	Seção final (p. 8)	Incluída adequadamente ao final do documento.
--	-----------------	--------------------	---

2. COMPARAÇÃO COM A TEORIA DOS SLIDES DA DISCIPLINA

A fundamentação teórica foi confrontada com os slides das Aulas 01 a 07 (Prof. Michel Bessani). Evidenciam-se lacunas teóricas substanciais:

• Cálculo Amostral do TOST

O que o relatório afirma/faz: O código afirma: '#n ideal pro TOST: não tem fórmula pronta simples pra isso. Estima por simulação' (chunk calcular_n_ideal).

O que a teoria dos slides estabelece: O Slide 07 (p. 13 e 16) estabelece formalmente a Fórmula de Zhang (2003) para TOST com variâncias desiguais e disponibiliza o script calcN_tost.R.

Qual é o problema: Erro conceitual e desconhecimento do material didático. A simulação foi executada apenas sob $\Delta_{\mu} = 0$, ignorando que a teoria da disciplina equaciona o poder para qualquer $\Delta_{\mu}^* < \Delta_{\mu}^*$.

Como deveria ser apresentado: Deveria ter citado Zhang (2003), demonstrado a equação analítica e aplicado calcN_tost2() com $\Delta_{\mu}^* = 0,5$.

• Apresentação de Intervalos de Confiança

O que o relatório afirma/faz: O relatório omite todos os intervalos de confiança no texto e na tabela, apresentando somente p-valores.

O que a teoria dos slides estabelece: Slide 04 (p. 20) e Slide 05 (p. 34 e 38): 'Apresentar intervalos é sempre melhor do que apenas estimativas pontuais'. Slide 07 (p. 10): TOST deve ser interpretado pela contenção do IC de $(1-2\alpha)$ em $[-\Delta_{\mu}^*, \Delta_{\mu}^*]$.

Qual é o problema: Omissão metodológica grave. Sem o IC de 90%, o leitor não pode constatar visualmente se a equivalência foi atingida por margem de folga ou precisão amostral.

Como deveria ser apresentado: Apresentar na tabela: IC 95% da diferença e IC 90% do TOST. Para homens, $[-1,38; 2,68]$ está dentro de $[-3,25; 3,25]$; para mulheres, $[0,40; 4,88]$ extrapola o limite.

• Consistência Paramétrica do TOST

O que o relatório afirma/faz: Aplica o teste t paramétrico no TOST para mulheres, mesmo após rejeitar a normalidade no teste de diferença.

O que a teoria dos slides estabelece: Slide 05 (p. 44) e Slide 07 (p. 12): O teste t de Student/Welch fundamenta-se na normalidade dos dados ou no Teorema Central do Limite (assintótico).

Qual é o problema: Contradição metodológica interna. Se $n=4$ viola a normalidade e impede o teste t de diferença, é ilógico aplicar testes t de Welch no TOST para o mesmo grupo.

Como deveria ser apresentado: Explicar a limitação de $n=4$ e aplicar o teste de equivalência de postos/Mann-Whitney via intervalo de Hodges-Lehmann ou bootstrap.

• Verificação de Premissa de Independência

O que o relatório afirma/faz: Nenhuma verificação de independência é realizada ou discutida no relatório.

O que a teoria dos slides estabelece: Slide 05 (p. 48–52) e Slide 06 (p. 19): A independência é a premissa mais crítica da inferência e deve ser avaliada via teste de Durbin-Watson.

Qual é o problema: Omissão de procedimento obrigatório na rotina experimental ensinada nas aulas.

Como deveria ser apresentado: Aplicar o teste de Durbin-Watson ($\text{Im}(\text{IMC} \sim \text{Semestre})$) ordenando as observações pela coleta e discutir os potenciais efeitos de correlação temporal.

3. ANÁLISE DA LÓGICA DO TRABALHO

A pergunta-chave do avaliador: 'Consigo reconstruir claramente como os autores saíram dos dados e chegaram às conclusões?'

Resposta: NÃO. A cadeia lógica apresenta 5 quebras estruturais severas:

- 1. Ruptura na proxy de Estilo de Vida:** O IMC é estático e reflete antropometria individual. Sem avaliar composição corporal, idade ou hábitos, atribuir oscilações entre turmas não pareadas a 'mudanças de estilo de vida' é salto inferencial.
- 2. Ruptura na Margem Δ_{μ}^* :** Fixar $\Delta_{\mu}^* = 3,25 \text{ kg/m}^2$ representa uma tolerância de quase 10 kg em peso corporal. O teste foi considerado 'equivalente' para homens unicamente porque a régua de tolerância é excessivamente permissiva.

3. **Ruptura na Bipolaridade Paramétrica:** O grupo feminino foi declarado não-normal no teste de diferença (migrando para Mann-Whitney), mas tratado como estritamente normal no TOST e na simulação amostral.
4. **Ocultação dos Parâmetros de Efeito:** A tabela e o texto suprimem a diferença média e os intervalos de confiança. A conclusão apoia-se num raciocínio de caixa-preta baseado apenas em 'p < 0,05'.
5. **Falsa Atribuição de Erro Tipo II:** O relatório atribui a não-equivalência feminina apenas à falta de amostra. Na realidade, a diferença observada foi de 2,64 kg/m2 (d de Cohen = 1,29, efeito gigantesco). A não-equivalência decorre da própria disparidade biológica entre os grupos, não apenas do n.

4. ANÁLISE DO CÓDIGO R E CONSISTÊNCIA METODOLÓGICA

- 4.1 **Entrada e Tratamento dos Dados:** Excelente uso de listas de configuração e metaprogramação (`dplyr::rename(!!!config$mapa_colunas)``). Porém, o path hardcoded ``Dados/`` inviabiliza a compilação autônoma.
- 4.2 **Implementação Matemática:** O cálculo de ``sd_pool <- sqrt((var(x) + var(y)) / 2)`` é uma média simples não ponderada. Para o grupo feminino desbalanceado (n1=7, n2=4), a variância agrupada correta ponderada pelos graus de liberdade é $S_p = 2,18 \text{ kg/m}^2$, e não $2,05 \text{ kg/m}^2$ (subestimação de 6%).
- 4.3 **Métodos Estatísticos:** Testar normalidade via Shapiro-Wilk com n=4 é estatisticamente frágil. A simulação de n ideal no TOST assume $\Delta_{\mu} = 0$ e equilíbrio amostral, desconsiderando a formulação analítica de Zhang (2003).
- 4.4 **Gráficos e Visualizações:** A Figura 1 emprega histograma com 8 bins em facetas onde há apenas 4 dados (mulheres 2017). O gráfico fica vazio e enganoso. Deveria utilizar boxplot com jitter.

Seção Específica: Código vs. Descrição Metodológica

- *Armazenamento vs Exibição:* O código calcula ``ic`` e ``estimativa``, mas a função ``kable`` os descarta propositalmente.
- *Tratamento de Exceção Paramétrica:* O texto anuncia proteção contra não-normalidade, mas o código submete o grupo não-normal ao TOST paramétrico.
- *Justificativa de Simulação:* O código justifica simulação alegando falta de fórmula simples, contrariando a teoria do curso.

6. VERIFICAÇÃO MINUCIOSA DOS RESULTADOS

Todos os dados foram recalculados a partir dos arquivos brutos e confrontados com o relatório:

Grupo / Parâmetro	Valor Recalculado Exato	Valor no Relatório	Classificação da Gravidade	Impacto na Análise Científica
Masc.: Média 2016 / 2017	24,94 / 24,29 kg/m2	Omitido	Moderado	Leitor não tem acesso aos valores basais dos grupos.
Masc.: Diferença (Delta_mu)	+0,65 kg/m2 (d = 0,17)	Omitido	Alto	Oculto que a diferença observada foi clinicamente desprezível.
Masc.: p-valor Dif. / TOST	p = 0,592 / p_TOST = 0,019	0,592 / 0,019	Baixo (Correto)	Cálculos exatos para alpha = 0,05 e delta* = 3,25.
Masc.: IC 90% (TOST)	[-1,38; +2,68] kg/m2	Omitido	Alto	A contenção estrita em [-3,25; 3,25] é a prova formal da equivalência.
Fem.: Média 2016 / 2017	21,08 / 18,45 kg/m2	Omitido	Moderado	18,45 kg/m2 está no limiar de 'Abaixo do peso' pela OMS. Fato ignorado.
Fem.: Diferença (Delta_mu)	+2,64 kg/m2 (d = 1,29)	Omitido	CRÍTICO	Diferença biológica enorme (d > 1,2). Omissão distorce a interpretação.
Fem.: p-valor Dif. (Mann-Wh.)	p = 0,073 (W = 24,0)	0,073	Moderado	Marginalmente não-significativo a 5% (com Welch daria p = 0,059).
Fem.: p-valor TOST (t-test)	p_TOST = 0,314	0,314	Alto	Calculado com teste t sobre amostra declarada não-normal.
Fem.: IC 90% (Welch)	[+0,40; +4,88] kg/m2	Omitido	CRÍTICO	Extrapolou o teto de 3,25. Prova que a não-equivalência decorre da grande diferença.

7. AFIRMAÇÕES SEM FUNDAMENTAÇÃO E CONTRADIÇÕES

- **Alegação de 'Estabilidade Comprovada' para Homens:** O texto afirma que o resultado 'reforça a conclusão de que não houve alteração no IMC dos homens'. Não rejeitar H0 não prova estabilidade absoluta; comprova apenas ausência de evidência para diferenças maiores que 3,25 kg/m2.
- **Atribuição Unilateral do Resultado Feminino à Falta de Amostra:** Atribuir a não-equivalência exclusivamente a n=4 desconsidera que a diferença observada foi de 2,64 kg/m2. Se a diferença amostral fosse 0, o TOST teria p_valor muito menor mesmo com amostras reduzidas.
- **Contradição de Método:** O relatório declara proteger-se contra violações de normalidade aplicando Mann-Whitney, mas usa testes t paramétricos para o TOST feminino sem ressalva teórica.

10. ORTOGRAFIA, GRAMÁTICA E LINGUAGEM ACADÊMICA

O documento exibe lapsos ortográficos e conceituais graves que comprometem o padrão de excelência de pós-graduação:

Trecho Original no Relatório	Problema Identificado	Correção Recomendada	Justificativa Gramatical / Acadêmica
'As distribuições se comportam...'	Erro de flexão de plural	'As distribuições comportam-se...'	Erro morfológico elementar. Próclise inadequada em início de período.
'...filtro para selcionar somente alunos...'	Erro de digitação / ortografia	'...filtro para selecionar somente alunos...'	Omissão da vogal 'e'.
'Após essa etapa proseguimos com o cálculo...'	Erro ortográfico	'Após essa etapa, prosseguiu-se com o cálculo...'	Verbo prosseguir grafa-se com 'ss'. Impessoalidade requerida.
'...conforme o codigo abaixo.'	Ausência de acento	'...conforme o código abaixo.'	Palavra proparoxítona exige acento agudo.
'...foi inciada a eta seguinte...'	Duplo erro de digitação	'...iniciou-se a etapa seguinte...'	Palavras truncadas ('inciada' -> iniciada; 'eta' -> etapa).
'...discorridos na proxima secção.'	Grafia arcaica / falta acento	'...discutidos na próxima seção.'	'Próxima' é proparoxítona. Uso de 'seção' no padrão brasileiro.
'...dado incio ao ao teste...'	Digitação e duplicação	'...iniciou-se o teste...'	'Início' exige acento e remoção da duplicação 'ao ao'.
'TOST feito na mão...' / 'n ideal pro teste'	Informalidade nos chunks R	'Implementação manual do TOST...' / 'n planejado...'	Comentários de código devem manter sobriedade científica.

14. SUGESTÕES DE MELHORIA PONTO A PONTO (PRIORIDADES)

- **PRIORIDADE 1 — CORRIGIR OBRIGATORIAMENTE (Compromete Validade e Requisitos):**
 1. *Incluir Estimativas e Intervalos de Confiança:* Inserir colunas na tabela com a diferença média pontual, d de Cohen, IC 95% do teste de diferença e IC 90% do TOST.
 2. *Ajustar Paths de Reprodutibilidade:* Corrigir o chunk de carregamento para buscar `imc\_20162.csv` e `CS01\_20172.csv` diretamente no diretório de trabalho corrente.
 3. *Identificar os Papéis dos Membros:* Inserir subseção explícita com as atribuições individuais (Relator, Verificador, etc.), conforme exigência do enunciado.
- **PRIORIDADE 2 — CORRIGIR ANTES DA ENTREGA (Fundamentação e Metodologia):**
 4. *Incorporar a Fórmula de Zhang (2003):* Substituir a alegação de inexistência de fórmula analítica pela equação analítica de Zhang ensinada no Slide 07.
 5. *Harmonizar a Análise do Grupo Feminino:* Justificar o uso do teste t no TOST para mulheres ou implementar versão não-paramétrica/bootstrap correspondente.
- **PRIORIDADE 3 — MELHORIAS RECOMENDADAS (Aprofundamento Científico):**
 6. *Análise de Sensibilidade de delta*:* Demonstrar a variação do p_TOST com delta* variando de 1,0 a 3,5 kg/m2.
 7. *Substituição dos Histogramas:* Adotar boxplots paralelos com jitter de pontos reais.
- **PRIORIDADE 4 — REFINAMENTOS ESTÉTICOS E REVISÃO:**
 8. *Revisão Ortográfica Rigorosa:* Corrigir integralmente as 8 incorreções catalogadas na Seção 10.

16. CHECKLIST FINAL DE CONFORMIDADE & 17. PARECER FINAL

Critério Avaliado	Situação	Síntese do Parecer do Avaliador
Atendimento ao Enunciado	■ Parcial	Omitiu intervalos de confiança e papéis da equipe; quebrou path padrão.
Alinhamento com os Slides	■ Parcial	Ignorou a fórmula de Zhang, homocedasticidade e teste de independência.
Rigor Metodológico	■ Parcial	Incoerência paramétrica no grupo feminino e variância combinada não ponderada.
Implementação do Código R	■ Pleno	Código funcional, modular e sem erros de execução sintática.
Confiabilidade dos Resultados	■ Parcial	Cálculos numéricos exatos, mas interpretação prejudicada pela omissão dos ICs.
Consistência Lógica	■ Frágil	Contradição entre premissa não-paramétrica na diferença e paramétrica no TOST.
Redação e Ortografia	■ Parcial	Erros recorrentes de concordância, acentuação e truncamento de palavras.
Reprodutibilidade	■ Parcial	Compilação automática quebra devido à dependência da subpasta 'Dados'.
Nível Acadêmico Compatível	■ Não	Padrão adequado para Mestrado com restrições; abaixo do nível de Doutorado.

Dimensão Avaliada	Peso	Nota (0-10)	Nota Ponderada	Justificativa
1. Atendimento aos Requisitos	25%	6,0	1,50	Omitiu ICs e papéis da equipe; path dependente de subpasta.
2. Rigor Teórico e Metodológico	25%	6,5	1,63	TOST correto, mas ignorou fórmula de Zhang e cometeu contradição no grupo feminino.
3. Análise Crítica dos Resultados	25%	6,0	1,50	Foco restrito a p-valores; omitiu discussão clínica de d = 1,29 nas mulheres.
4. Redação, Estilo e Reprodutibilidade	25%	6,5	1,63	Gráfico frágil para n=4 e múltiplos erros ortográficos e de digitação.
NOTA FINAL CONSOLIDADA	100%	—	6,3 / 10,0	Grau C (Regular / Suficiente para aprovação simples).

VEREDITO FINAL DO AVALIADOR:

O trabalho possui estrutura computacional sólida e atende aos objetivos essenciais de programação em R. Entretanto, carece da maturidade analítica, da precisão metodológica e do rigor de comunicação científica exigidos em um programa de Doutorado de ponta como o PPGEE-UFMG. **Recomenda-se a revisão profunda do manuscrito** antes de qualquer submissão final, sanando as omissões e inconsistências detalhadas neste relatório.