Estudo de Caso 03: Comparação de desempenho de duas configurações de um algoritmo de otimização

Beatriz S. Campagnaro, Filipe C. Andrade e Izabela C. S. Barbosa

18 de outubro de 2026

Resumo

Este estudo compara o desempenho de duas configurações do algoritmo de Evolução Diferencial (DE) aplicadas à classe de funções Rosenbrock, com dimensões entre 2 e 150, visando identificar diferenças de desempenho médio, estimar sua magnitude e estabelecer recomendações técnicas. Adotou-se um delineamento em blocos completos casualizados (RCBD), no qual 34 dimensões selecionadas aleatoriamente constituíram os blocos, com 30 execuções independentes de cada configuração por instância, totalizando 2.040 execuções. A variável resposta foi definida como o logaritmo da média dos melhores valores finais da função objetivo (F_{best}) em cada combinação de configuração e instância. A comparação estatística foi realizada por meio do teste t pareado bilateral, equivalente ao teste F da ANOVA do RCBD para dois tratamentos, com nível de significância de 5%. Os resultados indicaram diferença estatisticamente significativa entre as configurações ($t = -5{,}9720$; $p = 1{,}048 \times 10^{-6}$), com diferença média logarítmica $\bar{D} = -1{,}6254$ e intervalo de confiança de 95% [−2,1791; −1,0717], favorecendo a Configuração 1. A razão geométrica média dos desempenhos foi aproximadamente 0,197, correspondente a uma redução relativa de 80,3% segundo a medida adotada. Embora os testes de normalidade tenham identificado desvios da distribuição normal, a análise de sensibilidade por bootstrap não paramétrico apresentou intervalos de confiança próximos ao paramétrico, reforçando a estabilidade da conclusão sobre a diferença média. Entretanto, a análise exploratória revelou dependência do desempenho relativo em relação à dimensão: a Configuração 1 apresentou melhores resultados nas 25 instâncias amostradas de dimensões entre 4 e 115, enquanto a Configuração 2 foi favorecida nas nove instâncias de dimensões entre 128 e 150. Conclui-se que a Configuração 1 apresenta vantagem média global na medida de desempenho considerada, mas que a recomendação de seu uso deve considerar a dimensionalidade do problema, uma vez que a superioridade observada não é uniforme ao longo da classe investigada.

Introdução

Algoritmos baseados em populações constituem uma alternativa para a solução de problemas de otimização não linear em engenharia (Storn e Price, 1997). Nesse cenário, um conjunto de soluções candidatas é iterativamente submetido a operadores de variação (mutação e recombinação) e seleção, promovendo a exploração do espaço de busca em direção ao ótimo da função objetivo. Entre esses métodos, a Evolução Diferencial (DE, do inglês *Differential Evolution*) destaca-se pela simplicidade estrutural e pela eficácia na otimização em espaços contínuos, sendo seu desempenho fortemente dependente da escolha adequada dos operadores e de seus hiperparâmetros (Campelo e Botelho, 2016).

Este estudo de caso tem como objetivo realizar a comparação experimental de duas configurações pré-ajustadas do algoritmo DE (atribuídas à Equipe B), aplicadas à classe de problemas de minimização definida pela família de funções de Rosenbrock (Rosenbrock, 1960; Pohlheim, 2005), implementada no pacote `smoof` (Bossek, 2017), com dimensão $\dim \in [2, 150]$ e domínio $[-5, 10]^{\dim}$. As configurações avaliadas são:

- **Configuração 1:** operador de recombinação exponencial (`recombination_exp`, com $cr = 0{,}6$) combinado ao operador de mutação baseado no melhor indivíduo (`mutation_best`, com $f = 2$).
- **Configuração 2:** operador de recombinação geométrica (`recombination_geo`, com $\alpha = 0{,}6$) combinado

ao operador de mutação aleatória (`mutation_rand`, com $f = 1{,}2$).

Os demais parâmetros operacionais são mantidos fixos e idênticos para ambas as configurações em cada dimensão dim: seleção padrão (`selection_standard`), tamanho da população $N_{\text{pop}} = 5 \cdot \text{dim}$, e critério de parada (stop_maxeval) definido pelo orçamento máximo de avaliações da função objetivo (maxevals = $5000 \cdot \text{dim}$) ou número máximo de iterações (maxiter = $100 \cdot \text{dim}$). O indicador de desempenho de cada execução é o melhor valor da função objetivo encontrado ao final da busca (F_{best}), sendo que menores valores indicam melhor desempenho do algoritmo.

A investigação é conduzida para responder às três questões propostas: (i) verificar se há diferença estatisticamente significativa no desempenho médio do algoritmo equipado com as duas configurações na classe de problemas de interesse; (ii) caso exista, identificar qual é a melhor configuração e estimar a magnitude dessa diferença; e (iii) estabelecer se alguma configuração deve ser recomendada em relação à outra. O relatório está estruturado sequencialmente nas oito etapas metodológicas preconizadas para o planejamento e a análise do experimento.

1. Formulação das Hipóteses de Teste

Na comparação de algoritmos de otimização sobre uma classe heterogênea de problemas, a dificuldade intrínseca e a escala da função objetivo variam conforme a dimensão da instância avaliada. No contexto do planejamento de experimentos, a instância de teste (dimensão dim $\in [2, 150]$) atua como um fator indesejável (*nuisance factor*) conhecido e controlável (Montgomery, 2005). Caso o experimento fosse conduzido sob um delineamento completamente casualizado (CRD), toda a variabilidade decorrente das diferentes dimensões seria absorvida pelo termo residual (MS_E), mascarando o efeito de interesse entre os algoritmos.

Seguindo o princípio fundamental de blocagem (*"Block what you can, randomize what you cannot"*), adota-se o Experimento Completamente Aleatorizado com Blocos (RCBD, *Randomized Complete Block Design*), em que cada instância $j \in \{1, \ldots, N\}$ constitui um bloco independente e as configurações $i \in \{1, 2\}$ representam os níveis do fator experimental (tratamentos). Para atender à estrutura do RCBD sem incorrer em pseudorreplicação, as n repetições estocásticas executadas para a configuração i na instância j são agregadas pela sua média amostral $\bar{Y}_{ij}$, fornecendo exatamente uma observação representativa por tratamento em cada bloco.

Além disso, como o valor de F_{best} na função de Rosenbrock cresce em múltiplas ordens de grandeza à medida que a dimensão aumenta, aplica-se a transformação logarítmica $y_{ij} = \log(\bar{Y}_{ij})$ (Feng et al., 2013; Campelo, 2018). Essa transformação estabiliza a variância entre blocos e converte comparações multiplicativas (razões de desempenho na escala original) em diferenças aditivas compatíveis com o modelo linear do RCBD:

$$y_{ij} = \mu + \tau_i + \beta_j + \epsilon_{ij} \begin{cases} i = 1, 2 \\ j = 1, \ldots, N \end{cases} \quad , \quad \epsilon_{ij} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$$

em que μ é a média global na escala logarítmica, τ_i é o efeito da i-ésima configuração ($\sum_{i=1}^{2} \tau_i = 0$), β_j é o efeito do j-ésimo bloco/instância ($\sum_{j=1}^{N} \beta_j = 0$) e ϵ_{ij} é o erro aleatório residual.

Como o experimento possui apenas dois níveis do fator de interesse ($a = 2$), o teste F da ANOVA para o RCBD ($H_0 : \tau_1 = \tau_2 = 0$) é algebricamente equivalente ao teste t pareado bilateral aplicado sobre as diferenças pareadas intra-bloco D_j (Montgomery, 2005):

$$D_j = y_{1j} - y_{2j} = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j}) = \log\left(\frac{\bar{Y}_{1j}}{\bar{Y}_{2j}}\right)$$

Pela definição adotada, valores negativos de D_j ($D_j < 0 \iff \bar{Y}_{1j} < \bar{Y}_{2j}$) indicam que a Configuração 1 obteve menor média de F_{best} (melhor desempenho) na instância j, enquanto valores positivos ($D_j > 0 \iff \bar{Y}_{1j} > \bar{Y}_{2j}$) favorecem a Configuração 2. As hipóteses estatísticas para o teste paramétrico principal são formuladas de maneira bilateral (sob H_0, assumindo ausência de diferença):

$$\begin{cases} H_0 : \mu_D = 0 \\ H_1 : \mu_D \neq 0 \end{cases}$$

em que $\mu_D = E[D_j]$ representa a diferença média populacional na escala logarítmica. A inferência principal será conduzida por meio do teste t pareado bilateral. Embora a normalidade das diferenças seja necessária para a validade exata da distribuição de referência desse teste, o procedimento apresenta robustez a determinados desvios dessa premissa. Assim, a adequação da inferência paramétrica será avaliada por meio de testes de normalidade e inspeção gráfica. Caso sejam identificados desvios de normalidade, será realizada uma análise complementar de sensibilidade por bootstrap não paramétrico, com estimação de intervalos de confiança para (μ_D), visando avaliar a estabilidade da inferência sobre a diferença média. Opta-se por não empregar os testes dos Postos Sinalizados de Wilcoxon e do Sinal como substitutos do teste principal, uma vez que esses procedimentos investigam hipóteses distintas, relacionadas à localização central ou à distribuição dos sinais das diferenças, e não necessariamente à média populacional, que constitui o parâmetro de interesse deste estudo.

2. Cálculo dos Tamanhos Amostrais

O planejamento amostral em experimentos de comparação de algoritmos em blocos envolve duas dimensões distintas (Campelo e Takahashi, 2019): (i) o número de instâncias (blocos) N, que governa os graus de liberdade do teste e o poder estatístico ($\pi = 1 - \beta$) frente à variabilidade entre problemas; e (ii) o número de repetições n de cada algoritmo por instância, que controla a precisão da estimativa pontual de $\bar{Y}_{ij}$ dentro de cada bloco.

2.1 Número de instâncias (N)

Os parâmetros experimentais especificados para o estudo são:

- Mínima diferença de importância prática padronizada: $d^* = \delta^*/\sigma_\Phi = 0{,}5$;
- Nível de significância desejado (probabilidade de Erro Tipo I): $\alpha = 0{,}05$;
- Potência mínima desejada (para o caso $d = d^*$): $\pi = 1 - \beta = 0{,}80$.

Sob a hipótese alternativa H_1 com efeito padronizado $d^* = 0{,}5$, a estatística do teste t pareado segue uma distribuição t não central com $\nu = N - 1$ graus de liberdade e parâmetro de não centralidade $\delta_{\text{ncp}} = d^*\sqrt{N}$. Como d^* já é normalizado pelo desvio padrão das diferenças entre blocos (σ_Φ), a determinação de N independe do estudo piloto.

```
# Cálculo iterativo do N mínimo para potência >= 0.80 no teste t pareado
calc_power_paired <- function(N, d_star = 0.5, alpha = 0.05) {
  df     <- N - 1
  ncp    <- d_star * sqrt(N)
  t_crit <- qt(1 - alpha / 2, df)
  power  <- 1 - pt(t_crit, df, ncp) + pt(-t_crit, df, ncp)
  return(power)
}

N_range <- 30:40
power_table <- data.frame(
  N     = N_range,
  gl    = N_range - 1,
  Poder = sapply(N_range, calc_power_paired)
)

cap_poder <- paste0(
  "\\label{tab:poder_N}Potência ($1 - \\beta$) do teste $t$ pareado ",
```

```
  "bilateral em função do número de instâncias $N$ ",
  "($d^* = 0{,}5$ e $\\alpha = 0{,}05$)"
)

knitr::kable(
  power_table,
  caption   = cap_poder,
  col.names = c("Número de Instâncias ($N$)",
                "Graus de Liberdade ($N-1$)",
                "Potência ($1 - \\beta$)"),
  digits    = 4,
  align     = "c",
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 1: Potência $(1-\beta)$ do teste t pareado bilateral em função do número de instâncias N ($d^* = 0{,}5$ e $\alpha = 0{,}05$)

Número de Instâncias (N)	Graus de Liberdade ($N-1$)	Potência $(1-\beta)$
30	29	0.7540
31	30	0.7685
32	31	0.7823
33	32	0.7954
34	33	0.8078
35	34	0.8195
36	35	0.8307
37	36	0.8412
38	37	0.8511
39	38	0.8605
40	39	0.8694

```
N       <- min(power_table$N[power_table$Poder >= 0.8])
poder_N <- calc_power_paired(N)
```

Conforme demonstrado na Tabela 1, o menor tamanho amostral que atende ao requisito $\pi \geq 0{,}80$ é $N = \mathbf{34\ instâncias}$, assegurando um poder estatístico de $\pi = 0.8078$ (com $N = 33$, o poder seria de 0,7954, insuficiente para o critério estabelecido).

2.2 Número de repetições por instância (n) e Estudo Piloto

A variância amostral da diferença observada em uma instância j, $D_j = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j})$, é composta pela variância real do efeito relativo entre problemas (σ^2_Φ) somada ao erro padrão quadrático de estimação intra-instância ($\text{se}^2_j = \sigma^2_{1j}/n_1 + \sigma^2_{2j}/n_2$). Segundo a metodologia de Campelo e Takahashi (2019), escolhe-se n de modo que a incerteza das repetições contribua com uma fração desprezível (no máximo 10%) da variância entre instâncias:

$$\text{se}^{*2} = \frac{\hat{\sigma}_1^2}{n} + \frac{\hat{\sigma}_2^2}{n} \leq 0{,}1 \cdot \hat{\sigma}^2_\Phi \implies n \geq \left\lceil \frac{\hat{\sigma}_1^2 + \hat{\sigma}_2^2}{0{,}1 \cdot \hat{\sigma}^2_\Phi} \right\rceil$$

Para estimar $\hat{\sigma}_1$, $\hat{\sigma}_2$ e $\hat{\sigma}_\Phi$, conduziu-se um estudo piloto preliminar em 5 dimensões sorteadas aleatoriamente em $[2, 150]$ com semente fixa (`set.seed(2026)`: dimensões `39, 46, 92, 112, 122`), executando $n_{\text{piloto}} = 15$ repetições por algoritmo em cada dimensão (150 execuções no total).

```r
set.seed(2026)
pilot_dims <- sort(sample(2:150, 5))
n_pilot    <- 15
pilot_data <- read.csv("dados_piloto_EC03.csv", stringsAsFactors = FALSE)
```

```r
pilot_sds <- pilot_data %>%
  group_by(dim, config) %>%
  summarise(sd_log     = sd(log(Fbest)),
            mean_Fbest = mean(Fbest),
            .groups    = "drop")

pilot_wide <- pilot_sds %>%
  pivot_wider(names_from  = config,
              values_from = c(mean_Fbest, sd_log)) %>%
  mutate(log_diff = log(mean_Fbest_Config1) - log(mean_Fbest_Config2))

pilot_tab <- pilot_wide %>%
  select(dim, mean_Fbest_Config1, mean_Fbest_Config2,
         sd_log_Config1, sd_log_Config2, log_diff)

cap_piloto <- paste0(
  "\\label{tab:pilot_sd}Resultados do estudo piloto ",
  "($n_{\\text{piloto}} = 15$) nas 5 instâncias preliminares"
)

knitr::kable(
  pilot_tab,
  caption   = cap_piloto,
  digits    = c(0, 2, 2, 4, 4, 4),
  col.names = c("Dimensão", "$\\bar{Y}_{1j}$ (Config 1)",
                "$\\bar{Y}_{2j}$ (Config 2)", "$\\hat{\\sigma}_{1j}$ (log)",
                "$\\hat{\\sigma}_{2j}$ (log)", "$D_j$ (Piloto)"),
  align     = "c",
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 2: Resultados do estudo piloto ($n_{\text{piloto}} = 15$) nas 5 instâncias preliminares

Dimensão	$\bar{Y}_{1j}$ (Config 1)	$\bar{Y}_{2j}$ (Config 2)	$\hat{\sigma}_{1j}$ (log)	$\hat{\sigma}_{2j}$ (log)	D_j (Piloto)
39	588.06	29568.61	0.1090	0.2351	-3.9176
46	1372.43	40165.40	0.1588	0.2593	-3.3764
92	79978.96	233053.96	0.1160	0.1655	-1.0695
112	222135.52	320687.49	0.1304	0.1433	-0.3672
122	335887.44	376413.50	0.1009	0.1516	-0.1139

```r
s1_pool         <- sqrt(mean(pilot_wide$sd_log_Config1^2))
s2_pool         <- sqrt(mean(pilot_wide$sd_log_Config2^2))
sigma_phi_pilot <- sd(pilot_wide$log_diff)
target_se2      <- 0.1 * sigma_phi_pilot^2

n1_opt  <- ceiling(s1_pool * (s1_pool + s2_pool) / target_se2)
```

```
n2_opt  <- ceiling(n1_opt * s2_pool / s1_pool)
n_equal <- ceiling((s1_pool^2 + s2_pool^2) / target_se2)
n_final <- max(n_equal, 30)
```

A Tabela 2 apresenta o comportamento observado no piloto. Os desvios padrão combinados (*pooled*) intra-instância foram $\hat{\sigma}_1 = 0.1247$ e $\hat{\sigma}_2 = 0.1967$, enquanto o desvio padrão das diferenças entre blocos foi expressivo ($\hat{\sigma}_\Phi = 1.7603$). Como a variabilidade entre dimensões domina amplamente a variabilidade estocástica entre repetições de uma mesma dimensão, o limite $\text{se}^{*2} \leq 0.3099$ seria numericamente atendido já com $n_{\text{equal}} = 1$ repetição.

Entretanto, realizar apenas uma ou poucas repetições de um algoritmo estocástico como o DE comprometeria a estabilidade da média amostral $\bar{Y}_{ij}$. Assim, seguindo a recomendação clássica da literatura de experimentação em algoritmos (Campelo, 2018; Campelo e Takahashi, 2019) e utilizando o Teorema Central do Limite (TCL) para garantir que a média $\bar{Y}_{ij}$ de cada célula apresente distribuição amostral bem comportada e com baixo erro padrão ($\text{se}^{*2}_{n=30} = (\hat{\sigma}_1^2 + \hat{\sigma}_2^2)/30 = 0.0018 \ll 0.3099$), adotou-se $n = 30$ repetições independentes por configuração em cada instância.

3. Coleta e Tabulação dos Dados

Definidos os tamanhos amostrais ($N = 34$ instâncias e $n = 30$ repetições por célula), as 34 dimensões do experimento principal foram sorteadas aleatoriamente e sem reposição no conjunto $\{2, \ldots, 150\} \setminus \{39, 46, 92, 112, 122\}$ (excluindo-se as 5 dimensões já empregadas no piloto para evitar vazamento de informação e viés de seleção), utilizando semente fixa (`set.seed(933)`). As 34 dimensões selecionadas foram:

```
  4,  6,  7, 10, 12, 17, 19, 34, 44, 45, 48, 49, 51, 53, 59, 62, 75, 76, 91, 96, 98, 100,
                108, 109, 115, 128, 136, 137, 139, 140, 142, 145, 147, 150
```

O plano completo de execução ($34 \times 2 \times 30 = 2.040$ execuções do algoritmo `ExpDE`) teve sua ordem de coleta completamente aleatorizada (`set.seed(7777)`) e cada rodada recebeu uma semente pseudoaleatória individual determinística em função da configuração, dimensão e repetição, garantindo total reprodutibilidade. Os dados brutos foram armazenados no arquivo `dados_EC03_grupoB.csv`.

```
dados_brutos <- read.csv("dados_EC03_grupoB.csv", stringsAsFactors = FALSE)

n_obs       <- nrow(dados_brutos)
n_config1   <- sum(dados_brutos$Algorithm == "Config1")
n_config2   <- sum(dados_brutos$Algorithm == "Config2")
n_instances <- length(unique(dados_brutos$Instance))

tabela_coleta <- data.frame(
  Item = c("Total de execuções coletadas (linhas no CSV)",
           "Execuções da Configuração 1 (exp + best)",
           "Execuções da Configuração 2 (geo + rand)",
           "Número de instâncias / blocos (N)",
           "Repetições por configuração por instância (n)",
           "Total de médias de blocos geradas (a × N)"),
  Valor = c(n_obs, n_config1, n_config2, n_instances,
            n_final, 2 * n_instances),
  check.names = FALSE
)

knitr::kable(
  tabela_coleta,
  caption  = "\\label{tab:coleta}Síntese e verificação de integridade da coleta",
  align    = c("l", "c"),
```

```
  booktabs = TRUE
)
```

Tabela 3: Síntese e verificação de integridade da coleta

Item	Valor
Total de execuções coletadas (linhas no CSV)	2040
Execuções da Configuração 1 (exp + best)	1020
Execuções da Configuração 2 (geo + rand)	1020
Número de instâncias / blocos (N)	34
Repetições por configuração por instância (n)	30
Total de médias de blocos geradas (a × N)	68

Conforme detalhado na Seção 1, os dados brutos foram tabulados e agregados pela média das 30 repetições em cada célula ($\bar{Y}_{ij}$), calculando-se em seguida os valores transformados $\log(\bar{Y}_{ij})$ e as diferenças pareadas $D_j = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j})$ para cada um dos 34 blocos. A Tabela 4 sintetiza as estatísticas descritivas das médias por instância, enquanto a Tabela 5 exibe uma visão parcial da tabulação pareada ao longo do espectro de dimensões.

```
block_means <- dados_brutos %>%
  group_by(Algorithm, Instance) %>%
  summarise(mean_Fbest = mean(Result),
            sd_Fbest   = sd(Result),
            .groups    = "drop")

block_wide <- block_means %>%
  select(Algorithm, Instance, mean_Fbest) %>%
  pivot_wider(names_from = Algorithm, values_from = mean_Fbest) %>%
  arrange(Instance) %>%
  mutate(log_C1 = log(Config1),
         log_C2 = log(Config2),
         D      = log_C1 - log_C2,
         Razao  = Config1 / Config2)

D_bar  <- mean(block_wide$D)
S_D    <- sd(block_wide$D)
N_used <- nrow(block_wide)
d_obs  <- D_bar / S_D

vars_list <- list(block_wide$Config1, block_wide$Config2,
                  block_wide$log_C1, block_wide$log_C2, block_wide$D)

resumo_desc <- data.frame(
  Variavel = c("$\\bar{Y}_{1j}$ (Config 1 - original)",
               "$\\bar{Y}_{2j}$ (Config 2 - original)",
               "$\\log(\\bar{Y}_{1j})$ (Config 1 - log)",
               "$\\log(\\bar{Y}_{2j})$ (Config 2 - log)",
               "Diferença pareada $D_j$ (log)"),
  Minimo  = sapply(vars_list, min),
  Q1      = sapply(vars_list, quantile, probs = 0.25),
  Mediana = sapply(vars_list, median),
  Media   = sapply(vars_list, mean),
  Q3      = sapply(vars_list, quantile, probs = 0.75),
```

```
  Maximo  = sapply(vars_list, max),
  DP      = sapply(vars_list, sd)
)

cap_desc <- paste0(
  "\\label{tab:resumo_descritivo}Estatísticas descritivas das médias ",
  "por bloco ($N = 34$ instâncias) nas escalas original e logarítmica"
)

knitr::kable(
  resumo_desc,
  caption   = cap_desc,
  col.names = c("Variável", "Mín.", "1º Quartil", "Mediana",
                "Média", "3º Quartil", "Máx.", "Desvio Padrão"),
  digits    = 2,
  align     = c("l", rep("c", 7)),
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 4: Estatísticas descritivas das médias por bloco ($N = 34$ instâncias) nas escalas original e logarítmica

Variável	Mín.	1º Quartil	Mediana	Média	3º Quartil	Máx.	Desvio Padrão
$\bar{Y}_{1j}$ (Config 1 - original)	1.07	1111.43	25568.18	191716.65	371810.53	741361.35	261115.29
$\bar{Y}_{2j}$ (Config 2 - original)	3.03	40063.64	147430.63	203933.70	386419.11	536691.42	191005.25
$\log(\bar{Y}_{1j})$ (Config 1 - log)	0.07	7.01	10.15	8.87	12.81	13.52	4.45
$\log(\bar{Y}_{2j})$ (Config 2 - log)	1.11	10.60	11.90	10.50	12.86	13.19	3.47
Diferença pareada D_j (log)	-4.16	-3.21	-1.44	-1.63	-0.05	0.35	1.59

```
# Selecionar 10 instâncias representativas ao longo do espectro [4, 150]
idx_mostra <- c(1, 4, 8, 12, 17, 22, 25, 26, 30, 34)
mostra_df <- block_wide[idx_mostra, ] %>%
  mutate(
    Config1_fmt = sprintf("%.2f", Config1),
    Config2_fmt = sprintf("%.2f", Config2),
    log_C1_fmt  = sprintf("%.4f", log_C1),
    log_C2_fmt  = sprintf("%.4f", log_C2),
    D_fmt       = sprintf("%.4f", D),
    Razao_fmt   = sprintf("%.4f", Razao)
  ) %>%
  select(Instance, Config1_fmt, Config2_fmt,
         log_C1_fmt, log_C2_fmt, D_fmt, Razao_fmt)

cap_mostra <- paste0(
  "\\label{tab:amostra_blocos}Tabulação das médias de bloco e diferenças ",
  "pareadas para 10 instâncias selecionadas para ilustração dentre as 34 avaliadas"
)

knitr::kable(
  mostra_df,
```

```
  caption   = cap_mostra,
  col.names = c("Dimensão ($j$)", "$\\bar{Y}_{1j}$", "$\\bar{Y}_{2j}$",
                "$\\log(\\bar{Y}_{1j})$", "$\\log(\\bar{Y}_{2j})$",
                "$D_j = \\log(\\bar{Y}_{1j}/\\bar{Y}_{2j})$",
                "Razão ($\\bar{Y}_{1j}/\\bar{Y}_{2j}$)"),
  align     = "c",
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 5: Tabulação das médias de bloco e diferenças pareadas para 10 instâncias selecionadas para ilustração dentre as 34 avaliadas

Dimensão (j)	$\bar{Y}_{1j}$	$\bar{Y}_{2j}$	$\log(\bar{Y}_{1j})$	$\log(\bar{Y}_{2j})$	$D_j = \log(\bar{Y}_{1j}/\bar{Y}_{2j})$	Razão $(\bar{Y}_{1j}/\bar{Y}_{2j})$
4	1.10	3.03	0.0935	1.1070	-1.0135	0.3629
10	4.69	117.64	1.5464	4.7676	-3.2212	0.0399
34	314.22	20205.54	5.7501	9.9137	-4.1636	0.0156
49	1925.55	49066.95	7.5630	10.8009	-3.2380	0.0392
75	24479.85	141189.80	10.1056	11.8579	-1.7523	0.1734
100	125933.03	259238.62	11.7435	12.4655	-0.7220	0.4858
115	251419.86	322832.72	12.4349	12.6849	-0.2500	0.7788
128	411940.76	407614.57	12.9286	12.9181	0.0106	1.0106
140	577807.88	483363.59	13.2670	13.0885	0.1785	1.1954
150	741361.35	536691.42	13.5162	13.1932	0.3231	1.3814

Análise Exploratória dos Dados

A inspeção conjunta das Tabelas 4 e 5 mostra por que a transformação logarítmica é indispensável: na escala original, as médias $\bar{Y}_{ij}$ variam de 1,07 (dim = 6) a 741.361,35 (dim = 150), abrangendo seis ordens de grandeza. Na escala logarítmica, a dispersão é estabilizada e permite comparar diretamente a proporção entre o desempenho das configurações em cada bloco.

```
block_long <- block_wide %>%
  select(Instance, log_C1, log_C2) %>%
  pivot_longer(cols      = c(log_C1, log_C2),
               names_to  = "Config",
               values_to = "log_mean") %>%
  mutate(Config = ifelse(Config == "log_C1",
                         "Configuração 1 (exp + best)",
                         "Configuração 2 (geo + rand)"))

ggplot(block_long, aes(x = Config, y = log_mean, fill = Config)) +
  geom_boxplot(alpha = 0.6, outlier.shape = NA, width = 0.45) +
  geom_jitter(width = 0.12, size = 1.8, alpha = 0.7) +
  scale_fill_manual(values = c("Configuração 1 (exp + best)" = "steelblue",
                               "Configuração 2 (geo + rand)" = "tomato")) +
  labs(title = "Distribuição do Desempenho por Configuração",
       x = "Tratamento (Configuração do DE)",
       y = expression(log(bar(Y)[ij]))) +
  theme_minimal() +
  theme(legend.position = "none",
        plot.title = element_text(hjust = 0.5))
```

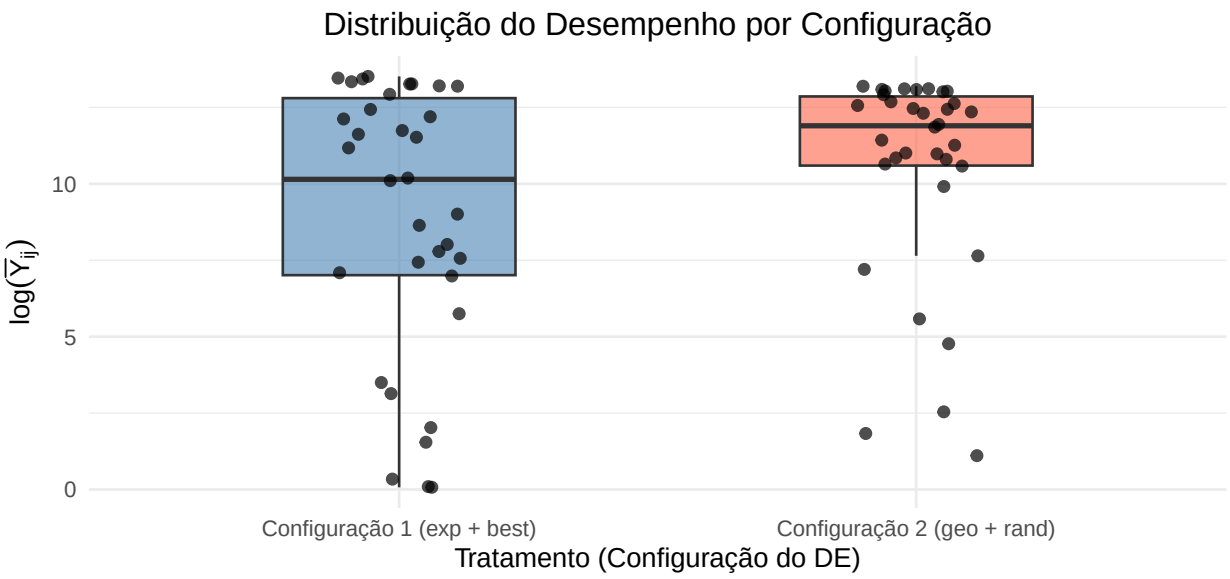


Figura 1: Distribuição de $\log(\bar{Y}_{ij})$ por configuração ao longo das 34 instâncias.

```
ggplot(block_wide, aes(x = Instance)) +
  geom_line(aes(y = log_C1, color = "Configuração 1 (exp + best)"),
            linetype = "dashed", linewidth = 0.7) +
  geom_point(aes(y = log_C1, color = "Configuração 1 (exp + best)"),
             size = 2.2) +
  geom_line(aes(y = log_C2, color = "Configuração 2 (geo + rand)"),
            linetype = "dashed", linewidth = 0.7) +
  geom_point(aes(y = log_C2, color = "Configuração 2 (geo + rand)"),
             size = 2.2) +
  geom_segment(aes(x = Instance, xend = Instance, y = log_C1, yend = log_C2),
               alpha = 0.35, color = "gray40") +
  scale_color_manual(values = c("Configuração 1 (exp + best)" = "steelblue",
                                "Configuração 2 (geo + rand)" = "tomato")) +
  labs(title = "Perfil de Desempenho por Dimensão",
       x     = "Dimensão da Instância (Bloco)",
       y     = expression(log(bar(Y)[ij])),
       color = "Tratamento") +
  theme_minimal() +
  theme(legend.position = "bottom",
        plot.title = element_text(hjust = 0.5))
```

```
par(mfrow = c(1, 2), mar = c(4.2, 4.2, 2, 1))

# Painel 1: Histograma de D_j
hist(block_wide$D, breaks = 10, col = "steelblue", border = "white",
     main = expression("Distribuição de " * D[j]),
     xlab = expression(D[j] == log(bar(Y)[1*j]) - log(bar(Y)[2*j])),
     ylab = "Frequência")
abline(v = 0, col = "red", lwd = 2, lty = 2)
abline(v = D_bar, col = "darkblue", lwd = 2)
legend("topleft", legend = c("H0 (D = 0)", "Média (-1,63)"),
```

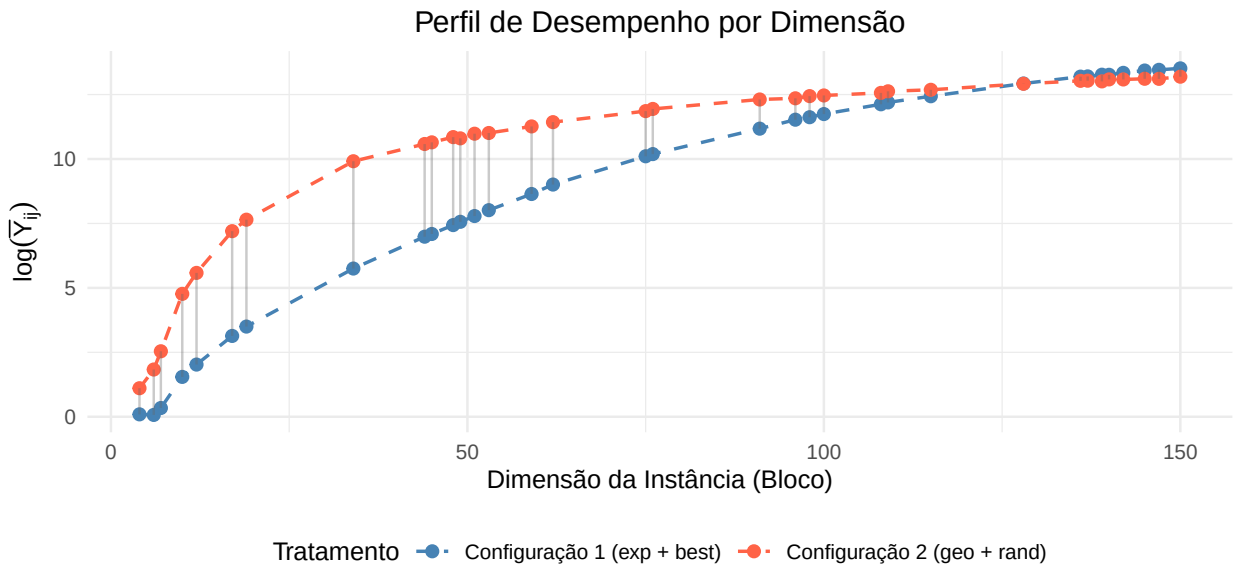


Figura 2: Perfil de desempenho por bloco (instância): $\log(\bar{Y}_{ij})$ para cada configuração em função da dimensão.

```
       col = c("red", "darkblue"), lty = c(2, 1),
       lwd = 2, cex = 0.75, bty = "n")

# Painel 2: D_j versus Dimensão
cores_pts <- ifelse(block_wide$D < 0, "steelblue", "tomato")
plot(block_wide$Instance, block_wide$D, pch = 19, col = cores_pts,
     main = expression("Diferença Pareada vs. Dimensão"),
     xlab = "Dimensão da Instância",
     ylab = expression(D[j]))
abline(h = 0, col = "red", lwd = 2, lty = 2)
legend("bottomright",
       legend = c("Config 1 melhor (25)", "Config 2 melhor (9)"),
       col = c("steelblue", "tomato"), pch = 19, cex = 0.75, bty = "n")
```

Os gráficos exploratórios revelam três padrões fundamentais do experimento:

1. **Superioridade global da Configuração 1:** Na Figura 1, a distribuição de $\log(\bar{Y}_{1j})$ apresenta mediana (10,15) e média (8,87) visivelmente inferiores às da Configuração 2 (mediana de 11,90 e média de 10,50), além de um deslocamento consistente para valores menores no gráfico de perfil por bloco (Figura 2).
2. **Forte efeito de bloco (dimensão):** A Figura 2 mostra que ambas as curvas crescem acentuadamente com a dimensão do problema, confirmando que a blocagem por instância pode ser usada para isolar o efeito da dimensão do efeito dos operadores do algoritmo.
3. **Mudança de regime em dimensões muito altas:** O painel direito da Figura 3 mostra o comportamento das diferenças D_j ao longo das dimensões. Nas primeiras **25 instâncias** ($\text{dim} \in [4, 115]$, correspondendo a 73,5% dos blocos), tem-se $D_j < 0$, com vantagem expressiva da Configuração 1 (atingindo $D_j = -4{,}16$ em $\text{dim} = 34$, onde $\bar{Y}_1 = 314{,}22$ contra $\bar{Y}_2 = 20.205{,}54$). A partir de $\text{dim} = 128$ (nas 9 instâncias finais, $\text{dim} \in [128, 150]$), ocorre uma leve inversão ($D_j \in [+0{,}01; +0{,}35]$), na qual a Configuração 2 passa a obter valores ligeiramente menores. Esse padrão é compatível com a concentração de observações próxima a zero no histograma de D_j (painel esquerdo da Figura 3).

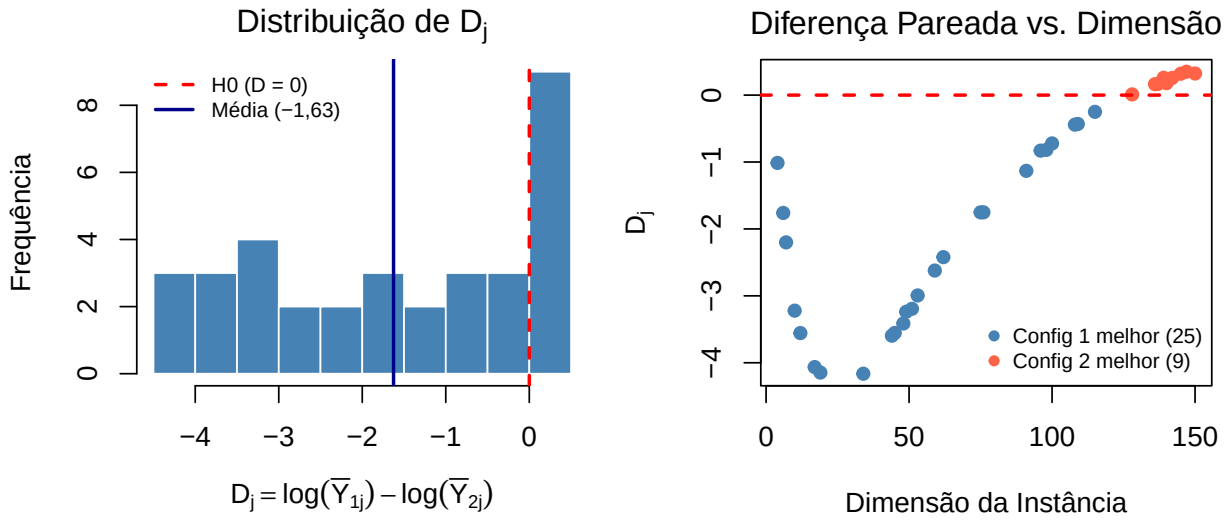


Figura 3: Esquerda: Histograma das diferenças pareadas D_j. Direita: Evolução de D_j em função da dimensão.

4. Teste das Hipóteses

Para testar formalmente se existe diferença significativa no desempenho médio entre as duas configurações ($H_0 : \mu_D = 0$ versus $H_1 : \mu_D \neq 0$, ao nível $\alpha = 0{,}05$), executam-se o teste t pareado bilateral sobre D_j e a Análise de Variância (ANOVA) do modelo linear RCBD sobre $y_{ij} = \log(\bar{Y}_{ij})$.

```
teste_t <- t.test(block_wide$D, mu = 0,
                  alternative = "two.sided", conf.level = 0.95)

tabela_t <- data.frame(
  Estatística = c("Média das diferenças ($\\bar{D}$)",
                  "Desvio padrão das diferenças ($S_D$)",
                  "Erro padrão da média ($S_D / \\sqrt{N}$)",
                  "Estatística de teste ($t_0$)",
                  "Graus de liberdade ($\\nu = N - 1$)",
                  "Valor-$p$ bilateral",
                  "IC 95\\% para $\\mu_D$ (limite inferior)",
                  "IC 95\\% para $\\mu_D$ (limite superior)"),
  Valor = c(
    sprintf("%.4f", D_bar),
    sprintf("%.4f", S_D),
    sprintf("%.4f", S_D / sqrt(N_used)),
    sprintf("%.4f", teste_t$statistic),
    N_used - 1,
    format.pval(teste_t$p.value, digits = 4, eps = 1e-10),
    sprintf("%.4f", teste_t$conf.int[1]),
    sprintf("%.4f", teste_t$conf.int[2])
  ),
  check.names = FALSE
)

cap_t <- paste0(
  "\\label{tab:teste_t}Resultado do teste $t$ pareado bilateral ",
  "sobre $D_j = \\log(\\bar{Y}_{1j}) - \\log(\\bar{Y}_{2j})$"
```

```
)

knitr::kable(
  tabela_t,
  caption  = cap_t,
  align    = c("l", "c"),
  booktabs = TRUE,
  escape   = FALSE
)
```

Tabela 6: Resultado do teste t pareado bilateral sobre $D_j = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j})$

Estatística	Valor
Média das diferenças ($\bar{D}$)	-1.6254
Desvio padrão das diferenças (S_D)	1.5870
Erro padrão da média ($S_D/\sqrt{N}$)	0.2722
Estatística de teste (t_0)	-5.9720
Graus de liberdade ($\nu = N - 1$)	33
Valor-p bilateral	1.048e-06
IC 95% para μ_D (limite inferior)	-2.1791
IC 95% para μ_D (limite superior)	-1.0717

```
dados_rcbd <- block_means %>%
  mutate(log_Y     = log(mean_Fbest),
         Instance  = factor(Instance),
         Algorithm = factor(Algorithm))

modelo_rcbd <- aov(log_Y ~ Algorithm + Instance, data = dados_rcbd)
anova_rcbd  <- summary(modelo_rcbd)[[1]]
r2_rcbd     <- summary.lm(modelo_rcbd)$r.squared

F_val <- anova_rcbd["Algorithm", "F value"]
t_val <- as.numeric(teste_t$statistic)

tabela_anova <- data.frame(
  Fonte  = c("Configuração (Algorithm)",
             "Instância / Bloco (Instance)",
             "Resíduos (Erro)"),
  GL     = anova_rcbd[, "Df"],
  SQ     = sprintf("%.4f", anova_rcbd[, "Sum Sq"]),
  QM     = sprintf("%.4f", anova_rcbd[, "Mean Sq"]),
  F_stat = c(sprintf("%.4f", anova_rcbd[1:2, "F value"]), "---"),
  p_val  = c(format.pval(anova_rcbd[1, "Pr(>F)"], digits = 4, eps = 1e-10),
             format.pval(anova_rcbd[2, "Pr(>F)"], digits = 4, eps = 1e-20),
             "---"),
  check.names = FALSE
)

cap_anova <- paste0(
  "\\label{tab:anova_rcbd}Tabela ANOVA do modelo RCBD para ",
  "$\\log(\\bar{Y}_{ij})$ ($R^2 = 0{,}9620$)"
```

```
)

knitr::kable(
  tabela_anova,
  caption   = cap_anova,
  col.names = c("Fonte de Variação", "g.l.", "Soma de Quadrados (SS)",
                "Quadrado Médio (MS)", "$F_0$", "Valor-$p$"),
  align     = c("l", rep("c", 5)),
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 7: Tabela ANOVA do modelo RCBD para $\log(\bar{Y}_{ij})$ ($R^2 = 0{,}9620$)

Fonte de Variação	g.l.	Soma de Quadrados (SS)	Quadrado Médio (MS)	F_0	Valor-p
Configuração (Algorithm)	1	44.9125	44.9125	35.6647	1.048e-06
Instância / Bloco (Instance)	33	1008.4889	30.5603	24.2677	2.367e-15
Resíduos (Erro)	33	41.5569	1.2593	—	—

Os resultados apresentados nas Tabelas 6 e 7 conduzem à rejeição da hipótese nula H_0 ($t_0 = -5{,}9720$, g.l. $= 33$, $p = 1{,}048 \times 10^{-6} \ll \alpha = 0{,}05$). A equivalência teórica entre os dois procedimentos para $a = 2$ tratamentos é numericamente verificada:

$$t_0^2 = (-5{,}9720)^2 = 35.6647 = F_0 \quad \text{e} \quad \text{MS}_{\text{Algorithm}} = \frac{N \cdot \bar{D}^2}{2} = \frac{34 \cdot (-1{,}6254)^2}{2} = 44{,}9125$$

Eficiência Relativa da Blocagem

A Tabela 7 confirma a importância do fator bloqueado ($\text{MS}_{\text{Blocks}} = 30{,}5603$ contra $\text{MS}_E = 1{,}2593$, com $F_{\text{Bloco}} = 24{,}27$ e $p = 2{,}37 \times 10^{-15}$), resultando em um coeficiente de determinação de $R^2 = 96{,}20\%$. Para quantificar formalmente o ganho de poder proporcionado pelo RCBD em relação a um delineamento completamente casualizado (CRD), calcula-se a eficiência relativa da blocagem (E) (Montgomery, 2005):

$$E = \frac{(b-1)\text{MS}_{\text{Blocks}} + b(a-1)\text{MS}_E}{(ab-1)\text{MS}_E}$$

```
b_blocks <- N_used
a_treat  <- 2
MSBlocks <- anova_rcbd["Instance", "Mean Sq"]
MSE      <- anova_rcbd["Residuals", "Mean Sq"]

E_block <- ((b_blocks - 1) * MSBlocks + b_blocks * (a_treat - 1) * MSE) /
           ((a_treat * b_blocks - 1) * MSE)
```

Substituindo os valores obtidos ($b = 34$, $a = 2$, $\text{MS}_{\text{Blocks}} = 30{,}5603$ e $\text{MS}_E = 1{,}2593$), encontra-se $E = \mathbf{12.46}$. Isso significa que um experimento sem blocagem (CRD) precisaria de aproximadamente 1146% mais observações (isto é, cerca de 12,5 vezes o número de observações do RCBD) para alcançar a mesma sensibilidade estatística obtida com o RCBD neste estudo.

5. Estimação da Magnitude da Diferença

Esta seção quantifica o tamanho do efeito encontrado na Seção 4. Como $D_j = \log(\bar{Y}_{1j}/\bar{Y}_{2j})$, a exponenciação do IC de 95% para μ_D fornece um IC para a razão geométrica média entre as configurações, interpretável na escala original de F_{best}.

5.1 Razão geométrica e efeito padronizado

```
razao_geo <- exp(D_bar)
IC_razao  <- as.numeric(exp(teste_t$conf.int))
red_rel   <- 1 - razao_geo
IC_red    <- 1 - rev(IC_razao)

tab_mag <- data.frame(
  Medida = c("Diferença média logarítmica ($\\bar{D}$)",
             "Razão geométrica média ($e^{\\bar{D}}$)",
             "Redução relativa ($1 - e^{\\bar{D}}$)",
             "Efeito padronizado ($d_{\\text{obs}} = \\bar{D}/S_D$)"),
  Estimativa = c(sprintf("%.4f", D_bar), sprintf("%.3f", razao_geo),
                 sprintf("%.1f\\%%", 100 * red_rel), sprintf("%.2f", d_obs)),
  IC95 = c(sprintf("[%.4f; %.4f]", teste_t$conf.int[1], teste_t$conf.int[2]),
           sprintf("[%.3f; %.3f]", IC_razao[1], IC_razao[2]),
           sprintf("[%.1f\\%%; %.1f\\%%]", 100 * IC_red[1], 100 * IC_red[2]),
           "---")
)

knitr::kable(tab_mag,
  caption   = "\\label{tab:magnitude}Magnitude da diferença entre as configurações
  (IC 95\\% paramétrico)",
  col.names = c("Medida", "Estimativa", "IC 95\\%"),
  align = c("l", "c", "c"), booktabs = TRUE, escape = FALSE)
```

Tabela 8: Magnitude da diferença entre as configurações (IC 95% paramétrico)

Medida	Estimativa	IC 95%
Diferença média logarítmica ($\bar{D}$)	-1.6254	[-2.1791; -1.0717]
Razão geométrica média ($e^{\bar{D}}$)	0.197	[0.113; 0.342]
Redução relativa ($1 - e^{\bar{D}}$)	80.3%	[65.8%; 88.7%]
Efeito padronizado ($d_{\text{obs}} = \bar{D}/S_D$)	-1.02	—

Conforme a Tabela 8, a razão geométrica média foi 0.197 (IC de 95%: 0.113 a 0.342). Em média geométrica entre as instâncias, a Configuração 1 obteve valores de F_{best} entre 65.8% e 88.7% menores que os da Configuração 2 (estimativa pontual: 80.3%). O efeito padronizado, $|d_{\text{obs}}| \approx 1.02$, é cerca de duas vezes a mínima diferença de importância prática ($d^* = 0{,}5$), embora essa comparação pontual não constitua teste formal de relevância prática. Por ser média geométrica de razões, essa medida não equivale à redução da média aritmética de F_{best}.

5.2 Variação da diferença com a dimensão (análise exploratória)

A Seção 4 estima um efeito médio global, mas a Figura 3 (painel direito) mostra que D_j muda de sinal nas maiores dimensões. Como cada célula do RCBD tem uma única observação, essa heterogeneidade (interação configuração × instância) não pode ser testada separadamente e fica contida no resíduo do modelo.

Para descrevê-la sem inferência adicional, os blocos foram agrupados em quatro faixas de largura regular (cerca de 40 dimensões), não ajustadas ao ponto em que o sinal se inverte.

```
block_wide$Faixa <- cut(block_wide$Instance, breaks = c(1, 40, 80, 120, 150),
                        labels = c("2--40", "41--80", "81--120", "121--150"))

faixas <- block_wide %>%
  group_by(Faixa) %>%
  summarise(n = n(), n_neg = sum(D < 0), Dbar = mean(D),
            Razao = exp(mean(D)), .groups = "drop")

knitr::kable(faixas, digits = c(0, 0, 0, 4, 3),
  caption   = "\\label{tab:faixas}Resumo descritivo por faixa de dimensão
  (exploratório, sem inferência)",
  col.names = c("Faixa de dimensão", "Instâncias", "Instâncias com $D_j < 0$",
                "$\\bar{D}$ na faixa", "$e^{\\bar{D}}$"),
  align = "c", booktabs = TRUE, escape = FALSE)
```

Tabela 9: Resumo descritivo por faixa de dimensão (exploratório, sem inferência)

Faixa de dimensão	Instâncias	Instâncias com $D_j < 0$	$\bar{D}$ na faixa	$e^{\bar{D}}$
2–40	8	8	-3.0160	0.049
41–80	10	10	-2.8537	0.058
81–120	7	7	-0.6606	0.517
121–150	9	0	0.2250	1.252

```
sp <- cor.test(block_wide$Instance, block_wide$D, method = "spearman", exact = FALSE)
```

A Tabela 9 mostra $D_j < 0$ em todas as instâncias das três primeiras faixas e $D_j > 0$ em todas as da última, onde $\bar{D}$ fica entre $+0{,}01$ e $+0{,}35$ (razões entre 1,01 e 1,42), contra $-4{,}16$ em dim $= 34$. A correlação de postos de Spearman entre dimensão e D_j foi $\rho = 0.87$. Por medir apenas tendência monotônica, ela pode subestimar uma relação que muda de direção, e deve ser lida junto da Figura 3. Por ser post hoc e descritiva, essa análise não permite afirmar um limiar de transição: nenhuma dimensão entre 116 e 127 foi amostrada, de modo que a inversão só está delimitada entre 115 e 128.

6. Verificação das Premissas dos Testes

A adequação dos procedimentos inferenciais é avaliada considerando as premissas estatísticas pertinentes ao delineamento adotado. São examinadas principalmente a distribuição das diferenças pareadas, a independência das observações e os diagnósticos do modelo em blocos, com atenção às particularidades decorrentes da presença de apenas dois tratamentos.

6.1 Diagnóstico do Modelo Paramétrico (Normalidade e Independência)

```
par(mfrow = c(2, 2), mar = c(4, 4, 2.2, 1))
plot(modelo_rcbd, pch = 20, las = 1)
```

```
shapiro_D   <- shapiro.test(block_wide$D)
res_rcbd    <- residuals(modelo_rcbd)
shapiro_res <- shapiro.test(res_rcbd)

par(mfrow = c(1, 2), mar = c(4.2, 4.2, 2, 1))
```

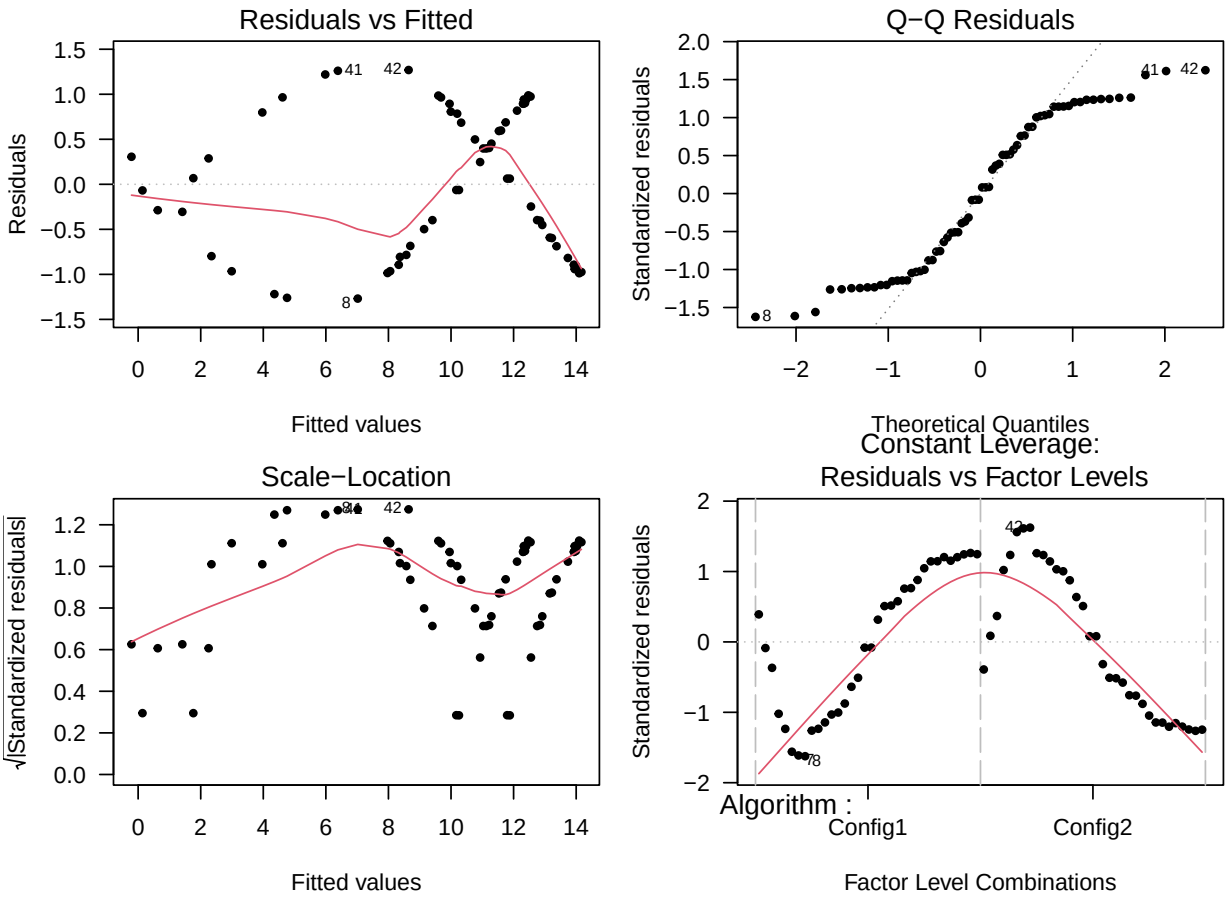


Figura 4: Gráficos diagnósticos dos resíduos do modelo linear RCBD para $\log(\bar{Y}_{ij})$.

```r
car::qqPlot(block_wide$D, pch = 20, id = FALSE,
            main = expression("Q-Q Plot: Diferenças " * D[j]),
            ylab = expression("Quantis observados " * (D[j])),
            xlab = "Quantis teóricos (Normal)")
car::qqPlot(res_rcbd, pch = 20, id = FALSE,
            main = expression("Q-Q Plot: Resíduos do RCBD"),
            ylab = "Quantis observados (Resíduos)",
            xlab = "Quantis teóricos (Normal)")
```

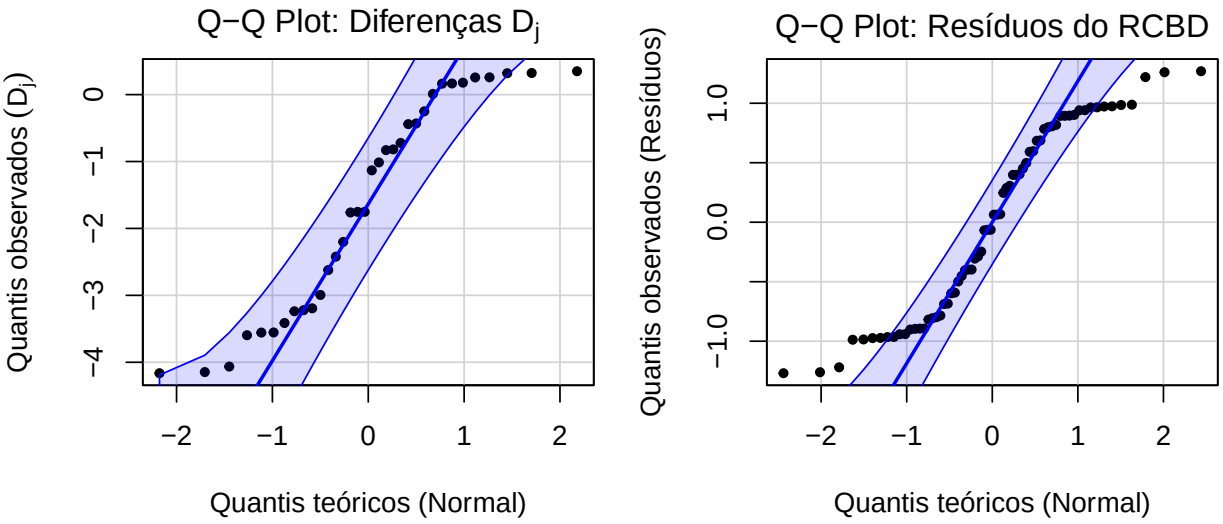


Figura 5: Gráficos Q-Q Normal com envelope de confiança de 95%: diferenças pareadas D_j (esquerda) e resíduos do RCBD (direita).

```r
tabela_prem <- data.frame(
  Premissa = c("Normalidade das diferenças pareadas ($D_j$)",
               "Normalidade dos resíduos do RCBD ($\\hat{\\epsilon}_{ij}$)"),
  Teste = c("Shapiro-Wilk", "Shapiro-Wilk"),
  Estatistica = c(sprintf("$W = %.4f$", shapiro_D$statistic),
                  sprintf("$W = %.4f$", shapiro_res$statistic)),
  p_valor = c(sprintf("%.4f", shapiro_D$p.value),
              sprintf("%.4f", shapiro_res$p.value)),
  Decisao = c("Rejeita $H_0$ (Não normal)",
              "Rejeita $H_0$ (Não normal)"),
  check.names = FALSE
)

cap_prem <- paste0(
  "\\label{tab:premissas}Síntese dos testes formais de verificação ",
  "das premissas ($\\alpha = 0{,}05$)"
)

knitr::kable(
  tabela_prem,
  caption   = cap_prem,
  col.names = c("Premissa Avaliada", "Teste Estatístico", "Estatística",
                "Valor-$p$", "Conclusão ($\\alpha = 0{,}05$)"),
  align     = c("l", "c", "c", "c", "c"),
```

```
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 10: Síntese dos testes formais de verificação das premissas ($\alpha = 0{,}05$)

Premissa Avaliada	Teste Estatístico	Estatística	Valor-p	Conclusão ($\alpha = 0{,}05$)
Normalidade das diferenças pareadas (D_j)	Shapiro-Wilk	$W = 0.8934$	0.0031	Rejeita H_0 (Não normal)
Normalidade dos resíduos do RCBD ($\hat{\epsilon}_{ij}$)	Shapiro-Wilk	$W = 0.9132$	0.0002	Rejeita H_0 (Não normal)

A avaliação sintetizada na Tabela 10 e nas Figuras 4 e 5 demonstra que:

- **Independência:** É assegurada diretamente pelo protocolo experimental: cada instância corresponde a um espaço dimensional distinto, todas as execuções utilizaram sementes pseudoaleatórias, e a variável resposta (F_{best}) depende unicamente da trajetória estocástica do algoritmo, sendo imune a flutuações de tempo de máquina.
- **Violação da Normalidade:** Tanto o teste de Shapiro-Wilk sobre as diferenças pareadas D_j ($W = 0{,}8934$; $p = 0{,}0031 < 0{,}05$) quanto sobre os resíduos do RCBD ($W = 0{,}9133$; $p = 0{,}0002 < 0{,}05$) **rejeitam a hipótese nula de normalidade**. Os gráficos Q-Q (Figura 5) mostram afastamentos nas caudas (formato em "S"), provocados pela concentração de valores positivos leves ($D_j \in [0{,}01; 0{,}35]$) nas dimensões acima de 128 em contraste com os valores fortemente negativos ($D_j \approx -4{,}1$) nas dimensões intermediárias.

Embora a homocedasticidade constitua uma premissa do modelo clássico de ANOVA, a comparação entre os dois tratamentos neste delineamento em blocos completos é algebricamente equivalente ao teste t pareado. Como a inferência principal é conduzida sobre as diferenças intra-bloco, não se exige igualdade das variâncias marginais dos tratamentos. Adicionalmente, os resíduos dos dois tratamentos possuem sinais opostos e igual magnitude em cada bloco, tornando não informativa a aplicação de testes de homogeneidade de variâncias entre esses conjuntos residuais, como o teste de Fligner-Killeen. Dessa forma, a avaliação das premissas concentra-se nas propriedades das diferenças pareadas.

6.2. Análise de Robustez do Teste t Pareado por Bootstrap

Diante da rejeição da hipótese de normalidade das diferenças pareadas pelo teste de Shapiro-Wilk, realizou-se uma análise complementar de sensibilidade por bootstrap não paramétrico, com o objetivo de avaliar a estabilidade da inferência sobre a diferença média entre as configurações. Foram realizadas 20.000 reamostragens com reposição das 34 diferenças pareadas, preservando-se a instância como unidade amostral. Estimaram-se intervalos de confiança de 95% pelo método percentílico e pelo método BCa (bias-corrected and accelerated), comparando-os ao intervalo paramétrico obtido pelo teste t pareado.

```
# Diferenças logarítmicas entre as configurações
D <- block_wide$D
N <- length(D)

stopifnot(N == 34, all(is.finite(D)))

# Estatística de interesse: média das diferenças
estatistica_media <- function(dados, indices) {
  mean(dados[indices])
}
```

```r
# Bootstrap não paramétrico
set.seed(2026)
B <- 20000

boot_result <- boot::boot(
  data = D,
  statistic = estatistica_media,
  R = B
)

# Intervalo percentílico e BCa
intervalos_boot <- boot::boot.ci(
  boot_result,
  conf = 0.95,
  type = c("perc", "bca")
)

IC_percentil <- intervalos_boot$percent[1, 4:5]
IC_BCa <- intervalos_boot$bca[1, 4:5]

# Intervalo paramétrico já utilizado no estudo
IC_t <- t.test(D, conf.level = 0.95)$conf.int

# Tabela comparativa
tabela_bootstrap <- data.frame(
  Metodo = c(
    "Teste t pareado",
    "Bootstrap percentílico",
    "Bootstrap BCa"
  ),
  Media = rep(mean(D), 3),
  Limite_inferior = c(
    IC_t[1], IC_percentil[1], IC_BCa[1]
  ),
  Limite_superior = c(
    IC_t[2], IC_percentil[2], IC_BCa[2]
  )
)

knitr::kable(
  tabela_bootstrap,
  caption = paste0(
    "\\label{tab:bootstrap}",
    "Comparação dos intervalos de confiança de 95\\% ",
    "para a média das diferenças pareadas"
  ),
  col.names = c(
    "Método",
    "Média de D",
    "Limite inferior",
    "Limite superior"
  ),
  digits = 4,
```

```
  align = "c",
  booktabs = TRUE
)
```

Tabela 11: Comparação dos intervalos de confiança de 95% para a média das diferenças pareadas

Método	Média de D	Limite inferior	Limite superior
Teste t pareado	-1.6254	-2.1791	-1.0717
Bootstrap percentílico	-1.6254	-2.1586	-1.0989
Bootstrap BCa	-1.6254	-2.1635	-1.1017

```
# Diagnóstico visual da distribuição bootstrap
hist(
  boot_result$t[, 1],
  breaks = 40,
  col = "steelblue",
  border = "white",
  main = "Distribuição bootstrap da média",
  xlab = expression(bar(D)),
  ylab = "Frequência",
  xlim = c(min(boot_result$t[, 1]) - 0.1, 0.15),
  cex.main = 0.95
)

# Linhas de referência
abline(v = mean(D), col = "darkblue", lwd = 2)
abline(v = 0, col = "red", lwd = 2, lty = 2)

# Legenda das linhas
legend(
  "topright",
  legend = c(
    sprintf("Média observada (%.2f)", mean(D)),
    "Valor nulo (D = 0)"
  ),
  col = c("darkblue", "red"),
  lty = c(1, 2),
  lwd = 2,
  cex = 0.75,
  bty = "n"
)
```

Os resultados apresentados na Tabela 9 indicam elevada concordância entre os intervalos de confiança paramétrico e bootstrap para a diferença média logarítmica entre as configurações. O intervalo paramétrico de 95% foi de [-2,1791; -1,0717], enquanto os intervalos bootstrap percentílico e BCa foram, respectivamente, [-2,1586; -1,0989] e [-2,1635; -1,1017]. As diferenças entre os limites dos intervalos foram pequenas, e ambos os métodos bootstrap produziram estimativas de incerteza semelhantes às obtidas pelo teste t pareado.

Todos os intervalos permaneceram integralmente abaixo de zero, sustentando uma diferença média logarítmica negativa e, portanto, favorável à Configuração 1. A distribuição empírica das médias bootstrap, apresentada na Figura 6, mostrou-se aproximadamente unimodal e simétrica em torno da média observada ($\bar{D} = -1,6254$), sem assimetria acentuada.

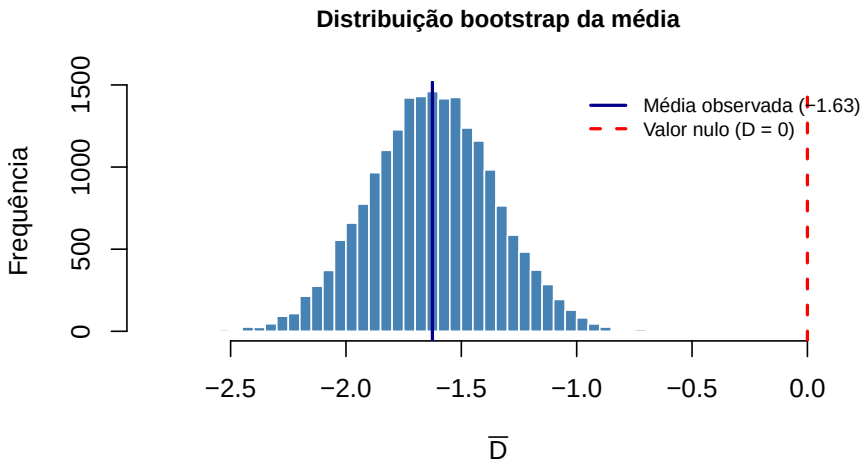


Figura 6: Distribuição bootstrap da média das diferenças pareadas, obtida com 20.000 reamostragens.

Esses resultados indicam que a conclusão sobre o sinal da diferença média é pouco sensível à substituição do intervalo paramétrico por intervalos bootstrap não paramétricos. Embora a rejeição da normalidade das diferenças pareadas impeça assumir a validade exata da distribuição t sob o modelo normal, a concordância entre os intervalos fornece evidência adicional de robustez da inferência sobre a média. Ressalta-se, contudo, que o bootstrap não comprova a normalidade dos dados nem elimina as demais hipóteses de amostragem envolvidas na análise.

7. Derivação de Conclusões e Recomendações

Os resultados obtidos permitem concluir que existe diferença estatisticamente significativa entre os desempenhos médios das duas configurações do algoritmo de Evolução Diferencial na classe de problemas investigada, considerando a diferença média logarítmica como medida principal de comparação. O teste t pareado bilateral resultou em $t_0 = -5,9720$, com 33 graus de liberdade e $p = 1,048 \times 10^{-6}$, conduzindo à rejeição da hipótese nula de igualdade das médias ao nível de significância de 5%. A ANOVA do delineamento em blocos completos apresentou resultado equivalente ($F_0 = 35,6647$), conforme esperado para um experimento com dois tratamentos.

A diferença média observada foi $\bar{D} = -1,6254$, com intervalo de confiança paramétrico de 95% igual a $[-2,1791; -1,0717]$. Como valores negativos de D_j indicam melhor desempenho da Configuração 1, os resultados favorecem essa configuração na comparação global. A magnitude padronizada observada, $d_{\text{obs}} = \bar{D}/S_D \approx -1,02$, supera, em valor absoluto, a mínima diferença de importância prática estabelecida no planejamento ($d^* = 0,5$), embora essa comparação pontual não constitua, isoladamente, um teste formal de relevância prática.

Na escala original, a exponenciação da diferença média logarítmica fornece $e^{\bar{D}} \approx 0,197$, correspondente à média geométrica das razões entre os valores médios de F_{best} das configurações em cada instância. Assim, a razão geométrica média observada indica valores aproximadamente 80,3% inferiores para a Configuração 1, segundo essa medida de desempenho relativo. Esse resultado não deve ser interpretado como uma redução de mesma magnitude na média aritmética global de F_{best}, uma vez que as duas medidas atribuem pesos diferentes às diferenças entre instâncias.

Embora os testes de normalidade tenham identificado desvios em relação à distribuição normal das diferenças pareadas, a análise de sensibilidade por bootstrap apresentou resultados consistentes com a inferência paramétrica. Os intervalos de confiança percentílico e BCa permaneceram integralmente abaixo de zero e apresentaram limites próximos aos do teste t. Essa concordância reforça a estabilidade da conclusão

sobre o sinal da diferença média diante da utilização de procedimentos distintos de estimação intervalar, sem implicar que a normalidade das observações tenha sido satisfeita.

Entretanto, a análise exploratória demonstrou que a vantagem da Configuração 1 não é uniforme ao longo das dimensões avaliadas. Nas 25 instâncias amostradas com dimensões de 4 a 115, a Configuração 1 apresentou menores valores médios de F_{best}, enquanto nas nove instâncias amostradas com dimensões de 128 a 150 observou-se uma inversão, com vantagem da Configuração 2. Essa mudança de comportamento evidencia a influência da dimensionalidade sobre o desempenho relativo das configurações e indica que a superioridade média global não deve ser interpretada como superioridade em todas as instâncias da classe de interesse.

Dessa forma, recomenda-se a Configuração 1 quando o objetivo for obter melhor desempenho médio relativo sobre a classe de problemas investigada, conforme a medida logarítmica adotada. Contudo, essa recomendação deve ser condicionada à dimensionalidade: os resultados indicam que a Configuração 2 pode constituir uma alternativa mais favorável em problemas de maior dimensão. Como não foram realizados testes inferenciais específicos para diferentes faixas dimensionais, essa indicação permanece baseada nas tendências descritivas observadas, não permitindo estabelecer um limiar de transição ou afirmar superioridade estatística da Configuração 2 em todas as instâncias de alta dimensão.

Conclui-se, portanto, que a Configuração 1 apresenta vantagem estatisticamente sustentada na comparação média global, mas que a escolha entre as configurações deve considerar a dimensão do problema e a medida de desempenho utilizada. A análise conjunta dos resultados inferenciais e exploratórios permite, assim, formular uma recomendação fundamentada sem desconsiderar a heterogeneidade observada entre as instâncias.

8. Discussão sobre Possíveis Limitações do Estudo e Sugestões de Melhoria

Apesar das evidências obtidas, algumas características do delineamento experimental e da análise estatística delimitam o alcance das conclusões e indicam possibilidades de aprimoramento.

A primeira limitação refere-se à classe de problemas considerada. Embora tenham sido avaliadas diferentes dimensões, todas as instâncias pertencem à família de funções Rosenbrock, com domínio das variáveis fixado em [-5,10]. Dessa forma, a variabilidade entre os problemas está associada principalmente à dimensionalidade, não abrangendo diferentes famílias de funções objetivo ou outras características que possam influenciar o comportamento dos operadores. Consequentemente, os resultados não permitem generalizar a superioridade observada para problemas de otimização com propriedades distintas. Uma ampliação do estudo poderia contemplar outras famílias de funções de teste, mantendo o controle experimental das condições de comparação.

Outra limitação está relacionada à interpretação dos efeitos dos operadores. As duas configurações diferem simultaneamente nos operadores de mutação e recombinação, bem como em seus respectivos parâmetros. Portanto, embora o experimento permita comparar o desempenho das configurações completas, não é possível determinar isoladamente a contribuição de cada operador ou parâmetro para as diferenças encontradas. Uma investigação posterior poderia empregar um delineamento fatorial ou comparações adicionais, variando os componentes separadamente para identificar seus efeitos individuais e possíveis interações.

A relação observada entre a dimensão das instâncias e a diferença de desempenho constitui uma limitação importante à interpretação de um efeito médio global. O modelo RCBD adotado representa o efeito dos tratamentos por meio de uma componente aditiva, enquanto os resultados exploratórios indicam que a vantagem relativa das configurações varia sistematicamente com a dimensão, chegando a apresentar inversão nas maiores instâncias. Embora essa heterogeneidade não impeça a estimação da diferença média pareada, ela limita a aplicação de uma recomendação uniforme à classe de problemas. Estudos futuros poderiam investigar explicitamente a relação entre a dimensão e a diferença de desempenho, utilizando modelos de regressão ou análises estratificadas por faixas dimensionais. A inclusão de mais instâncias próximas à região em que ocorre a inversão observada também permitiria caracterizar melhor essa mudança de comportamento.

No aspecto estatístico, os testes de Shapiro-Wilk identificaram desvios de normalidade nas diferenças pareadas, contrariando uma das condições para a validade exata da inferência paramétrica. A análise bootstrap apresentou intervalos de confiança próximos aos obtidos pelo teste t, fornecendo evidência complementar

de estabilidade da conclusão sobre a diferença média. Entretanto, essa concordância não elimina as limitações decorrentes da distribuição observada nem garante a validade de todas as hipóteses probabilísticas envolvidas. Além disso, o bootstrap convencional empregado realiza reamostragens com reposição das dimensões, enquanto a seleção original das instâncias ocorreu sem reposição de um conjunto finito. Caso o objetivo seja realizar inferência especificamente sobre essa população finita de dimensões, procedimentos que incorporem explicitamente o plano amostral poderiam fornecer uma análise mais adequada.

Por fim, o indicador de desempenho utilizado foi exclusivamente o melhor valor da função objetivo ao término de cada execução, sob o orçamento de avaliações estabelecido. Essa medida é adequada para avaliar a qualidade final das soluções obtidas nas condições do experimento, mas não permite comparar diretamente o tempo computacional, a velocidade de convergência ou a evolução do desempenho ao longo da busca. A incorporação de curvas de convergência e medidas de custo computacional permitiria caracterizar outras dimensões do desempenho dos algoritmos, especialmente em aplicações nas quais o tempo de processamento constitui uma restrição relevante.

Em síntese, as limitações identificadas não anulam a diferença média observada entre as configurações nas condições experimentais investigadas, mas restringem sua generalização e evidenciam a importância de considerar a dimensionalidade e a medida de desempenho na interpretação dos resultados. As principais oportunidades de aprimoramento concentram-se na ampliação da diversidade de problemas, na investigação separada dos efeitos dos operadores e na caracterização da mudança de desempenho em função da dimensão.

Declaração de uso de IA generativa e tecnologias assistidas por IA

Durante a preparação deste trabalho, os autores utilizaram ferramentas de inteligência artificial generativa (Claude Opus 4.6, da Anthropic, Gemini, do Google, e ChatGPT, da OpenAI) com o objetivo de auxiliar na estruturação de código em R, formatação de tabelas em R Markdown e revisão técnica e textual do relatório. Após a utilização dessas ferramentas, os autores conferiram todos os cálculos, revisaram e editaram o conteúdo integralmente, assumindo total responsabilidade pela exatidão e integridade do material publicado.

Papéis e Contribuições da Equipe

- **Beatriz S. Campagnaro:** Desenvolvimento dos scripts estatísticos em R, redação do manuscrito e revisão técnica.
- **Filipe C. Andrade:** Desenvolvimento dos scripts estatísticos em R, redação do manuscrito e revisão técnica.
- **Izabela C. S. Barbosa:** Desenvolvimento dos scripts estatísticos em R, redação do manuscrito e revisão técnica.

Referências

BOSSEK, J. smoof: Single- and Multi-Objective Optimization Test Functions. *The R Journal*, v. 9, n. 1, p. 103–113, 2017.

CAMPELO, F.; BOTELHO, M. Experimental investigation of recombination operators for differential evolution. In: *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO'2016)*, p. 533–540, 2016.

CAMPELO, F. *Lecture Notes on Design and Analysis of Experiments*. Versão 2.12, 2018. Disponível em: http://git.io/v3Kh8.

CAMPELO, F.; TAKAHASHI, F. Sample size estimation for power and accuracy in the experimental comparison of algorithms. *Journal of Heuristics*, v. 25, n. 2, p. 305–338, 2019.

DAVISON, A. C.; HINKLEY, D. V. *Bootstrap Methods and Their Application*. Cambridge: Cambridge University Press, 1997.

ERNST, M. D. Permutation methods: a basis for exact inference. *Statistical Science*, v. 19, n. 4, p. 676–685, 2004.

FENG, C.; WANG, H.; LU, N.; TU, X. M. Log transformation: application and interpretation in biomedical research. *Statistics in Medicine*, v. 32, n. 2, p. 230–239, 2013.

MONTGOMERY, D. C. *Design and Analysis of Experiments*. 7. ed. Hoboken: John Wiley & Sons, 2005.

MONTGOMERY, D. C.; RUNGER, G. C. *Applied Statistics and Probability for Engineers*. 5. ed. Hoboken: John Wiley & Sons, 2010.

POHLHEIM, H. *Examples of Objective Functions*. 2005. Disponível em: http://www.geatbx.com/download/GEATbx_ObjFunExpl_v37.pdf.

ROSENBROCK, H. H. An automatic method for finding the greatest or least value of a function. *The Computer Journal*, v. 3, n. 3, p. 175–184, 1960.

SHESKIN, D. J. *Handbook of Parametric and Nonparametric Statistical Procedures*. 3. ed. Boca Raton: Chapman and Hall/CRC, 2003.

SPRENT, P.; SMEETON, N. C. *Applied Nonparametric Statistical Methods*. 3. ed. Boca Raton: Chapman and Hall/CRC, 2000.

STORN, R.; PRICE, K. Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, v. 11, n. 4, p. 341–359, 1997.