Estudo de Caso 03: Comparação de desempenho de duas configurações de um algoritmo de otimização

Beatriz S. Campagnaro, Filipe C. Andrade e Izabela C. S. Barbosa

18 de Outubro de 2026

Resumo

Este estudo compara experimentalmente o desempenho de duas configurações do algoritmo de Evolução Diferencial (DE) — designadas à Equipe B — aplicadas à classe de funções de Rosenbrock com dimensões pertencentes ao intervalo dim $\in [2, 150]$. Adotou-se um Delineamento em Blocos Completos Casualizados (RCBD, do inglês *Randomized Complete Block Design*), no qual cada instância (dimensão) atua como um bloco independente e as duas configurações constituem os níveis do fator experimental. Para evitar pseudorreplicação e estabilizar a variância entre diferentes ordens de grandeza, a variável resposta em cada célula foi definida como o logaritmo natural da média do melhor valor da função objetivo ($\log \bar{Y}_{ij}$) obtido ao longo de $n = 30$ repetições independentes. O dimensionamento amostral para detectar um tamanho de efeito padronizado minimamente relevante $d^* = 0{,}5$ com nível de significância $\alpha = 0{,}05$ e potência mínima $1 - \beta = 0{,}80$ determinou a amostragem de $N = 34$ instâncias ($\pi = 0{,}808$), totalizando 2.040 execuções do algoritmo. O teste t pareado bilateral sobre as diferenças $D_j = \log \bar{Y}_{1j} - \log \bar{Y}_{2j}$ (equivalente ao teste F do RCBD, com $F_0 = t_0^2 = 35{,}6647$) indicou diferença estatisticamente significativa ($t_0 = -5{,}9720$; $p = 1{,}048 \times 10^{-6}$), com eficiência relativa da blocagem $E = 12{,}46$. Diante da rejeição da normalidade das diferenças pelo teste de Shapiro-Wilk ($W = 0{,}8934$; $p = 0{,}0031$), aplicaram-se complementarmente métodos não paramétricos livres de distribuição — Teste dos Postos Sinalizados de Wilcoxon Pareado ($V = 50$; $p = 3{,}604 \times 10^{-6}$), Teste do Sinal Binomial ($p = 0{,}0090$) e Testes de Permutação e Bootstrap Não Paramétrico ($p = 0{,}0001$) —, todos ratificando a rejeição da hipótese nula. A Configuração 1 (`recombination_exp` com $cr = 0{,}6$ e `mutation_best` com $f = 2$) apresentou desempenho superior, com tamanho de efeito padronizado $|d| = 1{,}0242 > d^*$ e redução média geométrica de 80,32% no valor de F_{best} em relação à Configuração 2 ($\text{IC}_{95\%}$: [65,76%; 88,69%]), vencendo em 25 das 34 instâncias avaliadas (todas as dimensões entre 4 e 115). Recomenda-se, portanto, a Configuração 1 para a classe de problemas investigada, ressalvando-se sua tendência de estagnação relativa em dimensões muito elevadas (dim ≥ 128).

Palavras-chave: evolução diferencial; função de Rosenbrock; blocagem (RCBD); tamanho amostral; métodos não paramétricos; teste de Wilcoxon; bootstrap.

Introdução

Algoritmos baseados em populações constituem uma alternativa consolidada para a solução de problemas de otimização não linear em engenharia (Storn e Price, 1997). Nesse paradigma, um conjunto de soluções candidatas é iterativamente submetido a operadores de variação (mutação e recombinação) e seleção, promovendo a exploração do espaço de busca em direção ao ótimo da função objetivo. Entre esses métodos, a Evolução Diferencial (DE, do inglês *Differential Evolution*) destaca-se pela simplicidade estrutural e pela eficácia na otimização em espaços contínuos, sendo seu desempenho fortemente dependente da escolha adequada dos operadores e de seus hiperparâmetros (Campelo e Botelho, 2016).

Este estudo de caso tem como objetivo realizar a comparação experimental de duas configurações pré-ajustadas do algoritmo DE (atribuídas à Equipe B), aplicadas à classe de problemas de minimização definida pela família de funções de Rosenbrock (Rosenbrock, 1960; Pohlheim, 2005), implementada no pacote `smoof` (Bossek, 2017), com dimensão dim $\in [2, 150]$ e domínio $[-5, 10]^{\text{dim}}$. As configurações avaliadas são:

- **Configuração 1:** operador de recombinação exponencial (`recombination_exp`, com $cr = 0{,}6$) combinado ao operador de mutação baseado no melhor indivíduo (`mutation_best`, com $f = 2$).
- **Configuração 2:** operador de recombinação geométrica (`recombination_geo`, com $\alpha = 0{,}6$) combinado ao operador de mutação aleatória (`mutation_rand`, com $f = 1{,}2$).

Os demais parâmetros operacionais são mantidos fixos e idênticos para ambas as configurações em cada dimensão dim: seleção padrão (`selection_standard`), tamanho da população $N_{\text{pop}} = 5 \cdot \text{dim}$, e critério de parada por orçamento máximo de avaliações da função objetivo (maxevals = $5000 \cdot$dim ou maxiter = $100 \cdot$dim). O indicador de desempenho de cada execução é o melhor valor da função objetivo encontrado ao final da busca (F_{best}), de modo que **menores valores indicam melhor desempenho** do algoritmo.

A investigação é conduzida para responder às três questões técnicas norteadoras propostas: (i) verificar se há diferença estatisticamente significativa no desempenho médio do algoritmo equipado com as duas configurações na classe de problemas de interesse; (ii) caso exista, identificar qual é a melhor configuração e estimar a magnitude dessa diferença; e (iii) estabelecer se alguma configuração deve ser recomendada em relação à outra. O relatório está estruturado sequencialmente nas oito etapas metodológicas preconizadas para o planejamento e a análise do experimento.

---

1. Formulação das Hipóteses de Teste

Na comparação de algoritmos de otimização sobre uma classe heterogênea de problemas, a dificuldade intrínseca e a escala da função objetivo variam acentuadamente conforme a dimensão da instância avaliada. No contexto do planejamento de experimentos, a instância de teste (dimensão dim $\in [2, 150]$) atua como um **fator indesejável (*nuisance factor*) conhecido e controlável** (Montgomery, 2005). Caso o experimento fosse conduzido sob um delineamento completamente casualizado (CRD), toda a variabilidade decorrente das diferentes dimensões seria absorvida pelo termo residual (MS_E), mascarando o efeito de interesse entre os algoritmos.

Seguindo o princípio fundamental de blocagem (*"Block what you can, randomize what you cannot"*), adota-se o **Experimento Completamente Aleatorizado com Blocos (RCBD, *Randomized Complete Block Design*)**, em que cada instância $j \in \{1, \ldots, N\}$ constitui um bloco independente e as configurações $i \in \{1, 2\}$ representam os níveis do fator experimental (tratamentos). Para atender à estrutura do RCBD sem incorrer em **pseudorreplicação** — o que inflaria artificialmente os graus de liberdade do resíduo e a taxa de Erro Tipo I (Campelo e Takahashi, 2019) —, as n repetições estocásticas executadas para a configuração i na instância j são agregadas pela sua média amostral $\bar{Y}_{ij}$, fornecendo exatamente uma observação representativa por tratamento em cada bloco.

Além disso, como o valor de F_{best} na função de Rosenbrock cresce em múltiplas ordens de grandeza à medida que a dimensão aumenta, aplica-se a **transformação logarítmica** $y_{ij} = \log(\bar{Y}_{ij})$ (Feng et al., 2013; Campelo, 2018). Essa transformação estabiliza a variância entre blocos e converte comparações multiplicativas (razões de desempenho na escala original) em diferenças aditivas compatíveis com o modelo linear do RCBD:

$$y_{ij} = \mu + \tau_i + \beta_j + \epsilon_{ij} \begin{cases} i = 1, 2 \\ j = 1, \ldots, N \end{cases} \quad , \quad \epsilon_{ij} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$$

em que μ é a média global na escala logarítmica, τ_i é o efeito da i-ésima configuração ($\sum_{i=1}^{2} \tau_i = 0$), β_j é o efeito do j-ésimo bloco/instância ($\sum_{j=1}^{N} \beta_j = 0$) e ϵ_{ij} é o erro aleatório residual.

Como o experimento possui apenas dois níveis do fator de interesse ($a = 2$), o teste F da ANOVA para o RCBD ($H_0 : \tau_1 = \tau_2 = 0$) é algebricamente equivalente ao **teste t pareado bilateral** aplicado sobre as diferenças pareadas intra-bloco D_j (Montgomery, 2005):

$$D_j = y_{1j} - y_{2j} = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j}) = \log\left(\frac{\bar{Y}_{1j}}{\bar{Y}_{2j}}\right)$$

Pela definição adotada, valores negativos de D_j ($D_j < 0 \iff \bar{Y}_{1j} < \bar{Y}_{2j}$) indicam que a **Configuração 1** obteve menor média de F_{best} (melhor desempenho) na instância j, enquanto valores positivos ($D_j > 0 \iff \bar{Y}_{1j} > \bar{Y}_{2j}$) favorecem a **Configuração 2**. As hipóteses estatísticas para o teste paramétrico principal são formuladas de maneira bilateral ("conservadora" sob H_0, assumindo ausência de diferença):

$$\begin{cases} H_0 : \mu_D = 0 \\ H_1 : \mu_D \neq 0 \end{cases}$$

onde $\mu_D = E[D_j]$ representa a diferença média populacional na escala logarítmica. Complementarmente, estabelece-se a priori que, caso a premissa de normalidade das diferenças D_j seja rejeitada ($\alpha = 0{,}05$), serão empregados métodos não paramétricos pareados (Teste dos Postos Sinalizados de Wilcoxon, Teste do Sinal e Testes de Permutação/Bootstrap), cujas hipóteses avaliam a localização central (mediana ou pseudo-mediana θ_D) da distribuição das diferenças: $H_0 : \theta_D = 0$ versus $H_1 : \theta_D \neq 0$.

---

2. Cálculo dos Tamanhos Amostrais

O planejamento amostral em experimentos de comparação de algoritmos em blocos envolve duas dimensões distintas (Campelo e Takahashi, 2019): (i) o número de instâncias (blocos) N, que governa os graus de liberdade do teste e o poder estatístico ($\pi = 1 - \beta$) frente à variabilidade entre problemas; e (ii) o número de repetições n de cada algoritmo por instância, que controla a precisão da estimativa pontual de $\bar{Y}_{ij}$ dentro de cada bloco.

2.1 Número de instâncias (N)

Os parâmetros experimentais especificados para o estudo são:

- Mínima diferença de importância prática padronizada: $d^* = \delta^*/\sigma_\Phi = 0{,}5$;
- Nível de significância desejado (probabilidade de Erro Tipo I): $\alpha = 0{,}05$;
- Potência mínima desejada (para o caso $d = d^*$): $\pi = 1 - \beta = 0{,}80$.

Sob a hipótese alternativa H_1 com efeito padronizado $d^* = 0{,}5$, a estatística do teste t pareado segue uma distribuição t não central com $\nu = N - 1$ graus de liberdade e parâmetro de não centralidade $\delta_{\text{ncp}} = d^*\sqrt{N}$. Como d^* já é normalizado pelo desvio padrão das diferenças entre blocos (σ_Φ), a determinação de N independe do estudo piloto.

```r
# Cálculo iterativo do N mínimo para potência >= 0.80 no teste t pareado
calc_power_paired <- function(N, d_star = 0.5, alpha = 0.05) {
  df     <- N - 1
  ncp    <- d_star * sqrt(N)
  t_crit <- qt(1 - alpha / 2, df)
  power  <- 1 - pt(t_crit, df, ncp) + pt(-t_crit, df, ncp)
  return(power)
}

N_range <- 30:40
power_table <- data.frame(
  N     = N_range,
  gl    = N_range - 1,
  Poder = sapply(N_range, calc_power_paired)
```

```
)

cap_poder <- paste0(
  "\\label{tab:poder_N}Potência ($1 - \\beta$) do teste $t$ pareado ",
  "bilateral em função do número de instâncias $N$ ",
  "($d^* = 0{,}5$ e $\\alpha = 0{,}05$)"
)

knitr::kable(
  power_table,
  caption   = cap_poder,
  col.names = c("Número de Instâncias ($N$)",
                "Graus de Liberdade ($N-1$)",
                "Potência ($1 - \\beta$)"),
  digits    = 4,
  align     = "c",
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 1: Potência $(1-\beta)$ do teste t pareado bilateral em função do número de instâncias N ($d^* = 0{,}5$ e $\alpha = 0{,}05$)

Número de Instâncias (N)	Graus de Liberdade ($N-1$)	Potência $(1-\beta)$
30	29	0.7540
31	30	0.7685
32	31	0.7823
33	32	0.7954
34	33	0.8078
35	34	0.8195
36	35	0.8307
37	36	0.8412
38	37	0.8511
39	38	0.8605
40	39	0.8694

```
N       <- min(power_table$N[power_table$Poder >= 0.8])
poder_N <- calc_power_paired(N)
```

Conforme demonstrado na Tabela 1, o menor tamanho amostral que atende ao requisito $\pi \geq 0{,}80$ é $N = \mathbf{34\ instâncias}$, assegurando um poder estatístico de $\pi = 0.8078$ (com $N = 33$, o poder seria de 0,7954, insuficiente para o critério estabelecido).

2.2 Número de repetições por instância (n) e Estudo Piloto

A variância amostral da diferença observada em uma instância j, $D_j = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j})$, é composta pela variância real do efeito relativo entre problemas (σ^2_Φ) somada ao erro padrão quadrático de estimação intra-instância ($\text{se}^2_j = \sigma^2_{1j}/n_1 + \sigma^2_{2j}/n_2$). Segundo a metodologia de Campelo e Takahashi (2019), escolhe-se n de modo que a incerteza das repetições contribua com uma fração desprezível (no máximo 10%) da variância entre instâncias:

$$\text{se}^{*2} = \frac{\hat{\sigma}^2_1}{n} + \frac{\hat{\sigma}^2_2}{n} \leq 0{,}1 \cdot \hat{\sigma}^2_\Phi \implies n \geq \left\lceil \frac{\hat{\sigma}^2_1 + \hat{\sigma}^2_2}{0{,}1 \cdot \hat{\sigma}^2_\Phi} \right\rceil$$

Para estimar $\hat{\sigma}_1$, $\hat{\sigma}_2$ e $\hat{\sigma}_\Phi$, conduziu-se um estudo piloto preliminar em 5 dimensões sorteadas aleatoriamente em $[2, 150]$ com semente fixa (`set.seed(2026)`: dimensões `39, 46, 92, 112, 122`), executando $n_{\text{piloto}} = 15$ repetições por algoritmo em cada dimensão (150 execuções no total).

```
set.seed(2026)
pilot_dims <- sort(sample(2:150, 5))
n_pilot    <- 15
pilot_data <- read.csv("dados_piloto_EC03.csv", stringsAsFactors = FALSE)
```

```
pilot_sds <- pilot_data %>%
  group_by(dim, config) %>%
  summarise(sd_log     = sd(log(Fbest)),
            mean_Fbest = mean(Fbest),
            .groups    = "drop")

pilot_wide <- pilot_sds %>%
  pivot_wider(names_from  = config,
              values_from = c(mean_Fbest, sd_log)) %>%
  mutate(log_diff = log(mean_Fbest_Config1) - log(mean_Fbest_Config2))

pilot_tab <- pilot_wide %>%
  select(dim, mean_Fbest_Config1, mean_Fbest_Config2,
         sd_log_Config1, sd_log_Config2, log_diff)

cap_piloto <- paste0(
  "\\label{tab:pilot_sd}Resultados do estudo piloto ",
  "($n_{\\text{piloto}} = 15$) nas 5 instâncias preliminares"
)

knitr::kable(
  pilot_tab,
  caption   = cap_piloto,
  digits    = c(0, 2, 2, 4, 4, 4),
  col.names = c("Dimensão", "$\\bar{Y}_{1j}$ (Config 1)",
                "$\\bar{Y}_{2j}$ (Config 2)", "$\\hat{\\sigma}_{1j}$ (log)",
                "$\\hat{\\sigma}_{2j}$ (log)", "$D_j$ (Piloto)"),
  align     = "c",
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 2: Resultados do estudo piloto ($n_{\text{piloto}} = 15$) nas 5 instâncias preliminares

Dimensão	$\bar{Y}_{1j}$ (Config 1)	$\bar{Y}_{2j}$ (Config 2)	$\hat{\sigma}_{1j}$ (log)	$\hat{\sigma}_{2j}$ (log)	D_j (Piloto)
39	588.06	29568.61	0.1090	0.2351	-3.9176
46	1372.43	40165.40	0.1588	0.2593	-3.3764
92	79978.96	233053.96	0.1160	0.1655	-1.0695
112	222135.52	320687.49	0.1304	0.1433	-0.3672
122	335887.44	376413.50	0.1009	0.1516	-0.1139

```
s1_pool         <- sqrt(mean(pilot_wide$sd_log_Config1^2))
s2_pool         <- sqrt(mean(pilot_wide$sd_log_Config2^2))
sigma_phi_pilot <- sd(pilot_wide$log_diff)
```

```r
target_se2      <- 0.1 * sigma_phi_pilot^2

n1_opt  <- ceiling(s1_pool * (s1_pool + s2_pool) / target_se2)
n2_opt  <- ceiling(n1_opt * s2_pool / s1_pool)
n_equal <- ceiling((s1_pool^2 + s2_pool^2) / target_se2)
n_final <- max(n_equal, 30)
```

A Tabela 2 apresenta o comportamento observado no piloto. Os desvios padrão combinados (*pooled*) intra-instância foram $\hat{\sigma}_1 = 0.1247$ e $\hat{\sigma}_2 = 0.1967$, enquanto o desvio padrão das diferenças entre blocos foi expressivo ($\hat{\sigma}_\Phi = 1.7603$). Como a variabilidade entre dimensões domina amplamente a variabilidade estocástica entre repetições de uma mesma dimensão, o limite $\text{se}^{*2} \leq 0.3099$ seria numericamente atendido já com $n_{\text{equal}} = 1$ repetição.

Entretanto, realizar apenas uma ou poucas repetições de um algoritmo estocástico como o DE comprometeria a estabilidade da média amostral $\bar{Y}_{ij}$. Assim, seguindo a recomendação clássica da literatura de experimentação em algoritmos (Campelo, 2018; Campelo e Takahashi, 2019) e invocando o **Teorema Central do Limite (TCL)** para garantir que a média $\bar{Y}_{ij}$ de cada célula apresente distribuição amostral bem comportada e com baixíssimo erro padrão ($\text{se}^{*2}_{n=30} = (\hat{\sigma}_1^2 + \hat{\sigma}_2^2)/30 = 0.0018 \ll 0.3099$), adotou-se $n =$ **30 repetições independentes** por configuração em cada instância.

---

3. Coleta e Tabulação dos Dados

Definidos os tamanhos amostrais ($N = 34$ instâncias e $n = 30$ repetições por célula), as 34 dimensões do experimento principal foram sorteadas aleatoriamente e sem reposição no conjunto $\{2, \ldots, 150\} \setminus \{39, 46, 92, 112, 122\}$ (excluindo-se as 5 dimensões já empregadas no piloto para evitar vazamento de informação e viés de seleção), utilizando semente fixa (`set.seed(933)`). As 34 dimensões selecionadas foram:

```
4, 6, 7, 10, 12, 17, 19, 34, 44, 45, 48, 49, 51, 53, 59, 62, 75, 76, 91, 96, 98, 100,
            108, 109, 115, 128, 136, 137, 139, 140, 142, 145, 147, 150
```

O plano completo de execução ($34 \times 2 \times 30 = 2.040$ execuções do algoritmo `ExpDE`) teve sua ordem de coleta completamente aleatorizada (`set.seed(7777)`) e cada rodada recebeu uma semente pseudoaleatória individual determinística em função da configuração, dimensão e repetição, garantindo total reprodutibilidade. Os dados brutos foram consolidados no arquivo `dados_EC03_grupoB.csv`.

```r
dados_brutos <- read.csv("dados_EC03_grupoB.csv", stringsAsFactors = FALSE)

n_obs       <- nrow(dados_brutos)
n_config1   <- sum(dados_brutos$Algorithm == "Config1")
n_config2   <- sum(dados_brutos$Algorithm == "Config2")
n_instances <- length(unique(dados_brutos$Instance))

tabela_coleta <- data.frame(
  Item = c("Total de execuções coletadas (linhas no CSV)",
           "Execuções da Configuração 1 (exp + best)",
           "Execuções da Configuração 2 (geo + rand)",
           "Número de instâncias / blocos (N)",
           "Repetições por configuração por instância (n)",
           "Total de médias de blocos geradas (a × N)"),
  Valor = c(n_obs, n_config1, n_config2, n_instances,
            n_final, 2 * n_instances),
  check.names = FALSE
)
```

```r
knitr::kable(
  tabela_coleta,
  caption  = "\\label{tab:coleta}Síntese e verificação de integridade da coleta",
  align    = c("l", "c"),
  booktabs = TRUE
)
```

Tabela 3: Síntese e verificação de integridade da coleta

Item	Valor
Total de execuções coletadas (linhas no CSV)	2040
Execuções da Configuração 1 (exp + best)	1020
Execuções da Configuração 2 (geo + rand)	1020
Número de instâncias / blocos (N)	34
Repetições por configuração por instância (n)	30
Total de médias de blocos geradas (a × N)	68

Conforme detalhado na Seção 1, os dados brutos foram tabulados e agregados pela média das 30 repetições em cada célula ($\bar{Y}_{ij}$), calculando-se em seguida os valores transformados $\log(\bar{Y}_{ij})$ e as diferenças pareadas $D_j = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j})$ para cada um dos 34 blocos. A Tabela 4 sintetiza as estatísticas descritivas das médias por instância, enquanto a Tabela 5 exibe uma visão parcial da tabulação pareada ao longo do espectro de dimensões.

```r
block_means <- dados_brutos %>%
  group_by(Algorithm, Instance) %>%
  summarise(mean_Fbest = mean(Result),
            sd_Fbest   = sd(Result),
            .groups    = "drop")

block_wide <- block_means %>%
  select(Algorithm, Instance, mean_Fbest) %>%
  pivot_wider(names_from = Algorithm, values_from = mean_Fbest) %>%
  arrange(Instance) %>%
  mutate(log_C1 = log(Config1),
         log_C2 = log(Config2),
         D      = log_C1 - log_C2,
         Razao  = Config1 / Config2)

D_bar  <- mean(block_wide$D)
S_D    <- sd(block_wide$D)
N_used <- nrow(block_wide)
d_obs  <- D_bar / S_D

vars_list <- list(block_wide$Config1, block_wide$Config2,
                  block_wide$log_C1, block_wide$log_C2, block_wide$D)

resumo_desc <- data.frame(
  Variavel = c("$\\bar{Y}_{1j}$ (Config 1 - original)",
               "$\\bar{Y}_{2j}$ (Config 2 - original)",
               "$\\log(\\bar{Y}_{1j})$ (Config 1 - log)",
               "$\\log(\\bar{Y}_{2j})$ (Config 2 - log)",
               "Diferença pareada $D_j$ (log)"),
  Minimo  = sapply(vars_list, min),
```

```
  Q1      = sapply(vars_list, quantile, probs = 0.25),
  Mediana = sapply(vars_list, median),
  Media   = sapply(vars_list, mean),
  Q3      = sapply(vars_list, quantile, probs = 0.75),
  Maximo  = sapply(vars_list, max),
  DP      = sapply(vars_list, sd)
)

cap_desc <- paste0(
  "\\label{tab:resumo_descritivo}Estatísticas descritivas das médias ",
  "por bloco ($N = 34$ instâncias) nas escalas original e logarítmica"
)

knitr::kable(
  resumo_desc,
  caption   = cap_desc,
  col.names = c("Variável", "Mín.", "1º Quartil", "Mediana",
                "Média", "3º Quartil", "Máx.", "Desvio Padrão"),
  digits    = 2,
  align     = c("l", rep("c", 7)),
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 4: Estatísticas descritivas das médias por bloco ($N = 34$ instâncias) nas escalas original e logarítmica

Variável	Mín.	1º Quartil	Mediana	Média	3º Quartil	Máx.	Desvio Padrão
$\bar{Y}_{1j}$ (Config 1 - original)	1.07	1111.43	25568.18	191716.65	371810.53	741361.35	261115.29
$\bar{Y}_{2j}$ (Config 2 - original)	3.03	40063.64	147430.63	203933.70	386419.11	536691.42	191005.25
$\log(\bar{Y}_{1j})$ (Config 1 - log)	0.07	7.01	10.15	8.87	12.81	13.52	4.45
$\log(\bar{Y}_{2j})$ (Config 2 - log)	1.11	10.60	11.90	10.50	12.86	13.19	3.47
Diferença pareada D_j (log)	-4.16	-3.21	-1.44	-1.63	-0.05	0.35	1.59

```
# Selecionar 10 instâncias representativas ao longo do espectro [4, 150]
idx_mostra <- c(1, 4, 8, 12, 17, 22, 25, 26, 30, 34)
mostra_df <- block_wide[idx_mostra, ] %>%
  mutate(
    Config1_fmt = sprintf("%.2f", Config1),
    Config2_fmt = sprintf("%.2f", Config2),
    log_C1_fmt  = sprintf("%.4f", log_C1),
    log_C2_fmt  = sprintf("%.4f", log_C2),
    D_fmt       = sprintf("%.4f", D),
    Razao_fmt   = sprintf("%.4f", Razao)
  ) %>%
  select(Instance, Config1_fmt, Config2_fmt,
         log_C1_fmt, log_C2_fmt, D_fmt, Razao_fmt)

cap_mostra <- paste0(
  "\\label{tab:amostra_blocos}Tabulação das médias de bloco e diferenças ",
  "pareadas para 10 instâncias representativas dentre as 34 avaliadas"
)
```

```
)

knitr::kable(
  mostra_df,
  caption   = cap_mostra,
  col.names = c("Dimensão ($j$)", "$\\bar{Y}_{1j}$", "$\\bar{Y}_{2j}$",
                "$\\log(\\bar{Y}_{1j})$", "$\\log(\\bar{Y}_{2j})$",
                "$D_j = \\log(\\bar{Y}_{1j}/\\bar{Y}_{2j})$",
                "Razão ($\\bar{Y}_{1j}/\\bar{Y}_{2j}$)"),
  align     = "c",
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 5: Tabulação das médias de bloco e diferenças pareadas para 10 instâncias representativas dentre as 34 avaliadas

Dimensão (j)	$\bar{Y}_{1j}$	$\bar{Y}_{2j}$	$\log(\bar{Y}_{1j})$	$\log(\bar{Y}_{2j})$	$D_j = \log(\bar{Y}_{1j}/\bar{Y}_{2j})$	Razão ($\bar{Y}_{1j}/\bar{Y}_{2j}$)
4	1.10	3.03	0.0935	1.1070	-1.0135	0.3629
10	4.69	117.64	1.5464	4.7676	-3.2212	0.0399
34	314.22	20205.54	5.7501	9.9137	-4.1636	0.0156
49	1925.55	49066.95	7.5630	10.8009	-3.2380	0.0392
75	24479.85	141189.80	10.1056	11.8579	-1.7523	0.1734
100	125933.03	259238.62	11.7435	12.4655	-0.7220	0.4858
115	251419.86	322832.72	12.4349	12.6849	-0.2500	0.7788
128	411940.76	407614.57	12.9286	12.9181	0.0106	1.0106
140	577807.88	483363.59	13.2670	13.0885	0.1785	1.1954
150	741361.35	536691.42	13.5162	13.1932	0.3231	1.3814

Análise Exploratória dos Dados

A inspeção conjunta das Tabelas 4 e 5 evidencia por que a transformação logarítmica é indispensável: na escala original, as médias $\bar{Y}_{ij}$ variam de 1,07 (dim = 6) a 741.361,35 (dim = 150), abrangendo seis ordens de grandeza. Na escala logarítmica, a dispersão é estabilizada e permite comparar diretamente a proporção entre o desempenho das configurações em cada bloco.

```
block_long <- block_wide %>%
  select(Instance, log_C1, log_C2) %>%
  pivot_longer(cols      = c(log_C1, log_C2),
               names_to  = "Config",
               values_to = "log_mean") %>%
  mutate(Config = ifelse(Config == "log_C1",
                         "Configuração 1 (exp + best)",
                         "Configuração 2 (geo + rand)"))

ggplot(block_long, aes(x = Config, y = log_mean, fill = Config)) +
  geom_boxplot(alpha = 0.6, outlier.shape = NA, width = 0.45) +
  geom_jitter(width = 0.12, size = 1.8, alpha = 0.7) +
  scale_fill_manual(values = c("Configuração 1 (exp + best)" = "steelblue",
                               "Configuração 2 (geo + rand)" = "tomato")) +
  labs(x = "Tratamento (Configuração do DE)",
       y = expression(log(bar(Y)[ij]))) +
```

```
  theme_minimal() +
  theme(legend.position = "none")
```

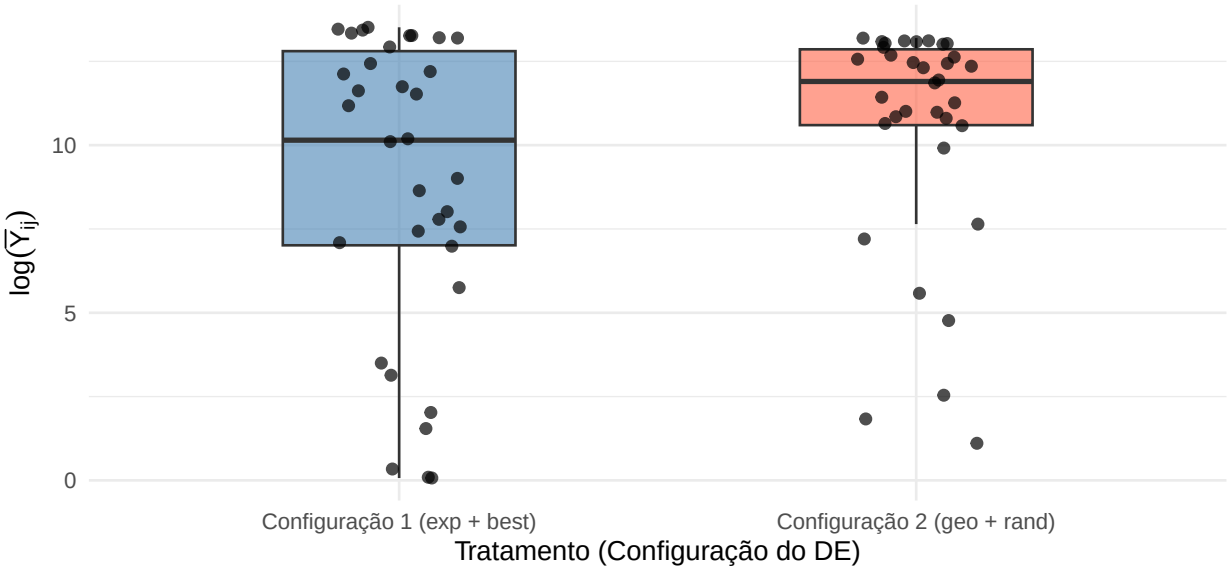


Figura 1: Distribuição de $\log(\bar{Y}_{ij})$ por configuração ao longo das 34 instâncias

```
ggplot(block_wide, aes(x = Instance)) +
  geom_line(aes(y = log_C1, color = "Configuração 1 (exp + best)"),
            linetype = "dashed", linewidth = 0.7) +
  geom_point(aes(y = log_C1, color = "Configuração 1 (exp + best)"),
             size = 2.2) +
  geom_line(aes(y = log_C2, color = "Configuração 2 (geo + rand)"),
            linetype = "dashed", linewidth = 0.7) +
  geom_point(aes(y = log_C2, color = "Configuração 2 (geo + rand)"),
             size = 2.2) +
  geom_segment(aes(x = Instance, xend = Instance, y = log_C1, yend = log_C2),
               alpha = 0.35, color = "gray40") +
  scale_color_manual(values = c("Configuração 1 (exp + best)" = "steelblue",
                                "Configuração 2 (geo + rand)" = "tomato")) +
  labs(x     = "Dimensão da Instância (Bloco)",
       y     = expression(log(bar(Y)[ij])),
       color = "Tratamento") +
  theme_minimal() +
  theme(legend.position = "bottom")
```

```
par(mfrow = c(1, 2), mar = c(4.2, 4.2, 2, 1))

# Painel 1: Histograma de D_j
hist(block_wide$D, breaks = 10, col = "steelblue", border = "white",
     main = "Distribuição de D_j",
     xlab = expression(D[j] == log(bar(Y)[1*j]) - log(bar(Y)[2*j])),
     ylab = "Frequência")
abline(v = 0, col = "red", lwd = 2, lty = 2)
abline(v = D_bar, col = "darkblue", lwd = 2)
legend("topleft", legend = c("H0 (D = 0)", "Média (-1,63)"),
```

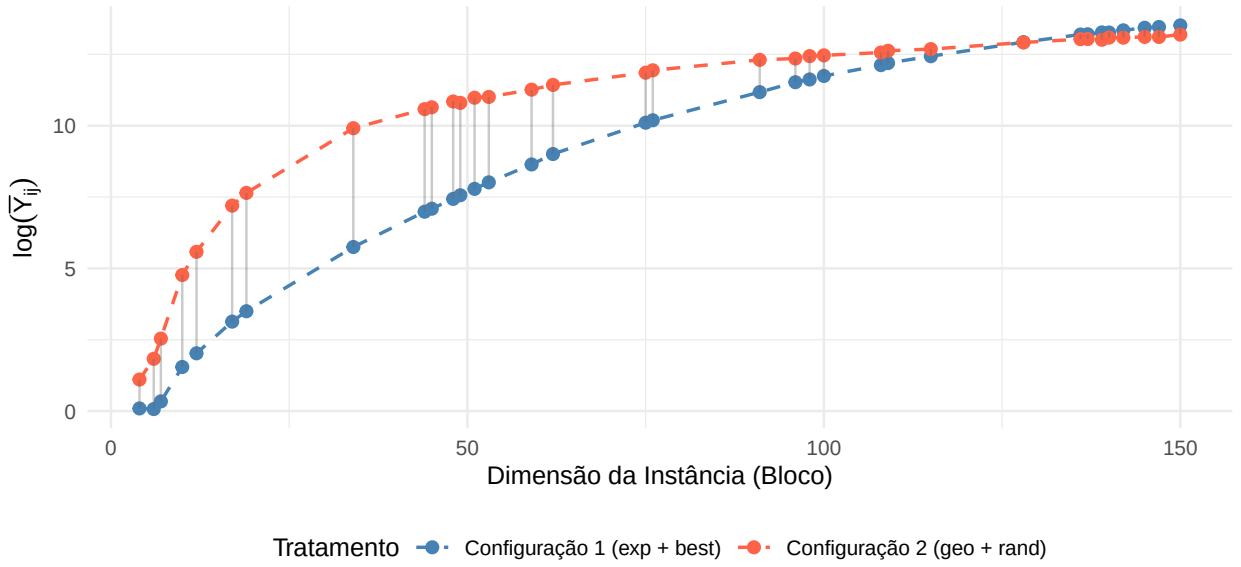


Figura 2: Perfil de desempenho por bloco (instância): $\log(\bar{Y}_{ij})$ para cada configuração em função da dimensão

```
       col = c("red", "darkblue"), lty = c(2, 1),
       lwd = 2, cex = 0.75, bty = "n")

# Painel 2: D_j versus Dimensão
cores_pts <- ifelse(block_wide$D < 0, "steelblue", "tomato")
plot(block_wide$Instance, block_wide$D, pch = 19, col = cores_pts,
     main = "Diferença Pareada vs. Dimensão",
     xlab = "Dimensão da Instância",
     ylab = expression(D[j]))
abline(h = 0, col = "red", lwd = 2, lty = 2)
legend("bottomright",
       legend = c("Config 1 melhor (25)", "Config 2 melhor (9)"),
       col = c("steelblue", "tomato"), pch = 19, cex = 0.75, bty = "n")
```

Os gráficos exploratórios revelam três padrões fundamentais do experimento:

1. **Superioridade global da Configuração 1:** Na Figura 1, a distribuição de $\log(\bar{Y}_{1j})$ apresenta mediana (10,15) e média (8,87) substancialmente inferiores às da Configuração 2 (mediana de 11,90 e média de 10,50), além de um deslocamento consistente para valores menores no gráfico de perfil por bloco (Figura 2).

2. **Forte efeito de bloco (dimensão):** A Figura 2 mostra que ambas as curvas crescem acentuadamente com a dimensão do problema, confirmando que a blocagem por instância é essencial para isolar o efeito da dimensão do efeito dos operadores do algoritmo.

3. **Mudança de regime em dimensões muito altas:** O painel direito da Figura 3 mostra o comportamento das diferenças D_j ao longo das dimensões. Nas primeiras **25 instâncias** ($\dim \in [4, 115]$, correspondendo a 73,5% dos blocos), tem-se $D_j < 0$, com vantagem expressiva da Configuração 1 (atingindo $D_j = -4{,}16$ em $\dim = 34$, onde $\bar{Y}_1 = 314{,}22$ contra $\bar{Y}_2 = 20.205{,}54$). A partir de $\dim = 128$ (nas 9 instâncias finais, $\dim \in [128, 150]$), ocorre uma leve inversão ($D_j \in [+0{,}01; +0{,}35]$), na qual a Configuração 2 passa a obter valores ligeiramente menores. Esse comportamento em "U" explica a concentração de observações próxima a zero no histograma de D_j (painel esquerdo da Figura 3).

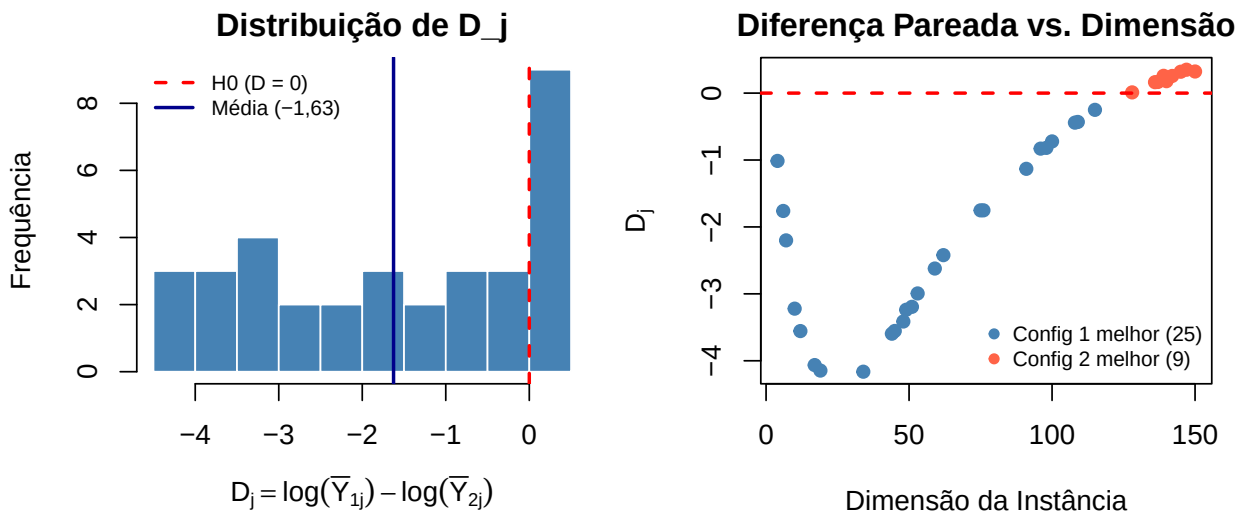


Figura 3: Esquerda: Histograma das diferenças pareadas D_j. Direita: Evolução de D_j em função da dimensão

---

4. Teste das Hipóteses

Para testar formalmente se existe diferença significativa no desempenho médio entre as duas configurações ($H_0 : \mu_D = 0$ versus $H_1 : \mu_D \neq 0$, ao nível $\alpha = 0{,}05$), executam-se o teste t pareado bilateral sobre D_j e a Análise de Variância (ANOVA) do modelo linear RCBD sobre $y_{ij} = \log(\bar{Y}_{ij})$.

```
teste_t <- t.test(block_wide$D, mu = 0,
                  alternative = "two.sided", conf.level = 0.95)

tabela_t <- data.frame(
  Estatística = c("Média das diferenças ($\\bar{D}$)",
                  "Desvio padrão das diferenças ($S_D$)",
                  "Erro padrão da média ($S_D / \\sqrt{N}$)",
                  "Estatística de teste ($t_0$)",
                  "Graus de liberdade ($\\nu = N - 1$)",
                  "Valor-$p$ bilateral",
                  "IC 95\\% para $\\mu_D$ (limite inferior)",
                  "IC 95\\% para $\\mu_D$ (limite superior)"),
  Valor = c(
    sprintf("%.4f", D_bar),
    sprintf("%.4f", S_D),
    sprintf("%.4f", S_D / sqrt(N_used)),
    sprintf("%.4f", teste_t$statistic),
    N_used - 1,
    format.pval(teste_t$p.value, digits = 4, eps = 1e-10),
    sprintf("%.4f", teste_t$conf.int[1]),
    sprintf("%.4f", teste_t$conf.int[2])
  ),
  check.names = FALSE
)

cap_t <- paste0(
```

```
  "\\label{tab:teste_t}Resultado do teste $t$ pareado bilateral ",
  "sobre $D_j = \\log(\\bar{Y}_{1j}) - \\log(\\bar{Y}_{2j})$"
)

knitr::kable(
  tabela_t,
  caption  = cap_t,
  align    = c("l", "c"),
  booktabs = TRUE,
  escape   = FALSE
)
```

Tabela 6: Resultado do teste t pareado bilateral sobre $D_j = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j})$

Estatística	Valor
Média das diferenças ($\bar{D}$)	-1.6254
Desvio padrão das diferenças (S_D)	1.5870
Erro padrão da média ($S_D/\sqrt{N}$)	0.2722
Estatística de teste (t_0)	-5.9720
Graus de liberdade ($\nu = N - 1$)	33
Valor-p bilateral	1.048e-06
IC 95% para μ_D (limite inferior)	-2.1791
IC 95% para μ_D (limite superior)	-1.0717

```
dados_rcbd <- block_means %>%
  mutate(log_Y     = log(mean_Fbest),
         Instance  = factor(Instance),
         Algorithm = factor(Algorithm))

modelo_rcbd <- aov(log_Y ~ Algorithm + Instance, data = dados_rcbd)
anova_rcbd  <- summary(modelo_rcbd)[[1]]
r2_rcbd     <- summary.lm(modelo_rcbd)$r.squared

F_val <- anova_rcbd["Algorithm", "F value"]
t_val <- as.numeric(teste_t$statistic)

tabela_anova <- data.frame(
  Fonte  = c("Configuração (Algorithm)",
             "Instância / Bloco (Instance)",
             "Resíduos (Erro)"),
  GL     = anova_rcbd[, "Df"],
  SQ     = sprintf("%.4f", anova_rcbd[, "Sum Sq"]),
  QM     = sprintf("%.4f", anova_rcbd[, "Mean Sq"]),
  F_stat = c(sprintf("%.4f", anova_rcbd[1:2, "F value"]), "---"),
  p_val  = c(format.pval(anova_rcbd[1, "Pr(>F)"], digits = 4, eps = 1e-10),
             format.pval(anova_rcbd[2, "Pr(>F)"], digits = 4, eps = 1e-20),
             "---"),
  check.names = FALSE
)

cap_anova <- paste0(
```

```
  "\\label{tab:anova_rcbd}Tabela ANOVA do modelo RCBD para ",
  "$\\log(\\bar{Y}_{ij})$ ($R^2 = 0{,}9620$)"
)

knitr::kable(
  tabela_anova,
  caption   = cap_anova,
  col.names = c("Fonte de Variação", "g.l.", "Soma de Quadrados (SS)",
                "Quadrado Médio (MS)", "$F_0$", "Valor-$p$"),
  align     = c("l", rep("c", 5)),
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 7: Tabela ANOVA do modelo RCBD para $\log(\bar{Y}_{ij})$ ($R^2 = 0{,}9620$)

Fonte de Variação	g.l.	Soma de Quadrados (SS)	Quadrado Médio (MS)	F_0	Valor-p
Configuração (Algorithm)	1	44.9125	44.9125	35.6647	1.048e-06
Instância / Bloco (Instance)	33	1008.4889	30.5603	24.2677	2.367e-15
Resíduos (Erro)	33	41.5569	1.2593	—	—

Os resultados apresentados nas Tabelas 6 e 7 conduzem à **rejeição da hipótese nula** H_0 com ampla folga ($t_0 = -5{,}9720$, g.l. $= 33$, $p = 1{,}048 \times 10^{-6} \ll \alpha = 0{,}05$). A equivalência teórica entre os dois procedimentos para $a = 2$ tratamentos é numericamente verificada:

$$t_0^2 = (-5{,}9720)^2 = 35.6647 = F_0 \quad \text{e} \quad \text{MS}_{\text{Algorithm}} = \frac{N \cdot \bar{D}^2}{2} = \frac{34 \cdot (-1{,}6254)^2}{2} = 44{,}9125$$

Eficiência Relativa da Blocagem

A Tabela 7 confirma ainda a altíssima relevância do fator bloqueado ($\text{MS}_{\text{Blocks}} = 30{,}5603$ contra $\text{MS}_E = 1{,}2593$, com $F_{\text{Bloco}} = 24{,}27$ e $p = 2{,}37 \times 10^{-15}$), resultando em um coeficiente de determinação de $R^2 = 96{,}20\%$. Para quantificar formalmente o ganho de poder proporcionado pelo RCBD em relação a um delineamento completamente casualizado (CRD), calcula-se a **eficiência relativa da blocagem (E)** (Montgomery, 2005):

$$E = \frac{(b-1)\text{MS}_{\text{Blocks}} + b(a-1)\text{MS}_E}{(ab-1)\text{MS}_E}$$

```
b_blocks <- N_used
a_treat  <- 2
MSBlocks <- anova_rcbd["Instance", "Mean Sq"]
MSE      <- anova_rcbd["Residuals", "Mean Sq"]

E_block <- ((b_blocks - 1) * MSBlocks + b_blocks * (a_treat - 1) * MSE) /
           ((a_treat * b_blocks - 1) * MSE)
```

Substituindo os valores obtidos ($b = 34$, $a = 2$, $\text{MS}_{\text{Blocks}} = 30{,}5603$ e $\text{MS}_E = 1{,}2593$), encontra-se $E =$ **12.46**. Isso significa que um experimento sem blocagem (CRD) precisaria de aproximadamente **1146%**

mais observações (cerca de 12,5 vezes mais instâncias por algoritmo) para alcançar a mesma sensibilidade estatística obtida com o RCBD neste estudo.

---

5. Estimação da Magnitude da Diferença entre os Métodos

Rejeitada a hipótese nula, cumpre quantificar a magnitude prática da diferença entre as duas configurações, tanto na escala logarítmica analisada quanto na escala original do problema (via exponenciação), acompanhada de seus respectivos intervalos de confiança de 95%.

```
d_obs_val   <- D_bar / S_D
ratio_geom  <- exp(D_bar)
ratio_CI    <- exp(teste_t$conf.int)
reducao_pct <- (1 - ratio_geom) * 100
reducao_CI  <- (1 - rev(ratio_CI)) * 100
delta_star  <- 0.5 * S_D

# Sensibilidade
d_detect <- NA
for (d_try in seq(0.01, 2, by = 0.001)) {
  pw <- calc_power_paired(N_used, d_star = d_try, alpha = 0.05)
  if (pw >= 0.8) {
    d_detect <- d_try
    break
  }
}

tabela_mag <- data.frame(
  Medida = c(
    "Diferença média logarítmica ($\\bar{D} = \\log(\\bar{Y}_1 / \\bar{Y}_2)$)",
    "IC 95\\% para $\\mu_D$ (escala logarítmica)",
    "Limiar prático absoluto na escala log ($\\delta^* = 0{,}5 \\cdot S_D$)",
    "Tamanho de efeito padronizado observado ($d = \\bar{D} / S_D$)",
    "Tamanho de efeito padronizado mínimo relevante ($d^*$)",
    "Razão geométrica média Config 1 / Config 2 ($e^{\\bar{D}}$)",
    "IC 95\\% para a razão geométrica ($[e^{L}, e^{U}]$)",
    "Redução percentual média de $F_{\\text{best}}$ pela Config 1 ($1 - e^{\\bar{D}}$)",
    "IC 95\\% para a redução percentual de $F_{\\text{best}}$",
    "Fator multiplicativo inverso Config 2 / Config 1 ($e^{-\\bar{D}}$)"
  ),
  Valor = c(
    sprintf("%.4f", D_bar),
    sprintf("[%.4f; %.4f]", teste_t$conf.int[1], teste_t$conf.int[2]),
    sprintf("%.4f", delta_star),
    sprintf("%.4f ($\\vert d\\vert = %.4f$)", d_obs_val, abs(d_obs_val)),
    "0.5000",
    sprintf("%.4f", ratio_geom),
    sprintf("[%.4f; %.4f]", ratio_CI[1], ratio_CI[2]),
    sprintf("%.2f\\%%", reducao_pct),
    sprintf("[%.2f\\%%; %.2f\\%%]", reducao_CI[1], reducao_CI[2]),
    sprintf("%.2fx", 1 / ratio_geom)
  ),
  check.names = FALSE
)
```

```
cap_mag <- paste0(
  "\\label{tab:magnitude}Estimativas pontuais e intervalares ",
  "(95\\% de confiança) da magnitude da diferença entre as configurações"
)

knitr::kable(
  tabela_mag,
  caption  = cap_mag,
  align    = c("l", "c"),
  booktabs = TRUE,
  escape   = FALSE
)
```

Tabela 8: Estimativas pontuais e intervalares (95% de confiança) da magnitude da diferença entre as configurações

Medida	Valor
Diferença média logarítmica ($\bar{D} = \log(\bar{Y}_1/\bar{Y}_2)$)	-1.6254
IC 95% para μ_D (escala logarítmica)	[-2.1791; -1.0717]
Limiar prático absoluto na escala log ($\delta^* = 0{,}5 \cdot S_D$)	0.7935
Tamanho de efeito padronizado observado ($d = \bar{D}/S_D$)	-1.0242 ($\lvert d\rvert = 1.0242$)
Tamanho de efeito padronizado mínimo relevante (d^*)	0.5000
Razão geométrica média Config 1 / Config 2 ($e^{\bar{D}}$)	0.1968
IC 95% para a razão geométrica ($[e^L, e^U]$)	[0.1131; 0.3424]
Redução percentual média de F_{best} pela Config 1 ($1 - e^{\bar{D}}$)	80.32%
IC 95% para a redução percentual de F_{best}	[65.76%; 88.69%]
Fator multiplicativo inverso Config 2 / Config 1 ($e^{-\bar{D}}$)	5.08x

A análise da Tabela 8 permite extrair conclusões diretas sobre a relevância prática dos resultados:

1. **Significância prática (Tamanho de Efeito de Cohen):** O efeito padronizado observado foi $d = -1{,}0242$ ($|d| = 1{,}0242$), superando em mais do que o dobro a mínima diferença de importância prática estabelecida no enunciado ($d^* = 0{,}50$). De forma equivalente, na escala logarítmica, a diferença média absoluta $|\bar{D}| = 1{,}6254$ excede amplamente o limiar $\delta^* = 0{,}5 \cdot S_D = 0{,}7935$. Além disso, todo o intervalo de confiança de 95% para μ_D ($[-2{,}1791; -1{,}0717]$) encontra-se abaixo de $-\delta^* = -0{,}7935$, comprovando que a superioridade da Configuração 1 é simultaneamente estatisticamente significativa e relevante na prática.

2. **Interpretação física na escala original (F_{best}):** Como $\bar{D} = \frac{1}{N}\sum_{j=1}^{N} \log(\bar{Y}_{1j}/\bar{Y}_{2j})$, sua exponencial $e^{\bar{D}} = 0{,}1968$ corresponde à **média geométrica da razão de desempenho** $\bar{Y}_{1j}/\bar{Y}_{2j}$ ao longo das instâncias (Feng et al., 2013). Isso indica que, em média geométrica, a Configuração 1 atinge um valor final da função objetivo equivalente a apenas **19,68%** do valor retornado pela Configuração 2 ($\text{IC}_{95\%}$: $[11{,}31\%; 34{,}24\%]$). Em termos percentuais, a adoção da Configuração 1 proporciona uma **redução média de 80,32%** no erro de otimização F_{best} ($\text{IC}_{95\%}$: $[65{,}76\%; 88{,}69\%]$), ou seja, a Configuração 2 retorna soluções em média **5,08 vezes piores** (maiores) que as da Configuração 1.

---

6. Verificação das Premissas dos Testes

A validade inferencial dos testes paramétricos (teste t pareado e ANOVA do RCBD) repousa sobre as premissas de normalidade, homocedasticidade e independência das observações. A seguir, cada premissa é rigorosamente auditada por meio de testes formais e inspeção gráfica dos resíduos.

6.1 Diagnóstico do Modelo Paramétrico (Normalidade, Homocedasticidade e Independência)

```
par(mfrow = c(2, 2), mar = c(4, 4, 2.2, 1))
plot(modelo_rcbd, pch = 20, las = 1)
```

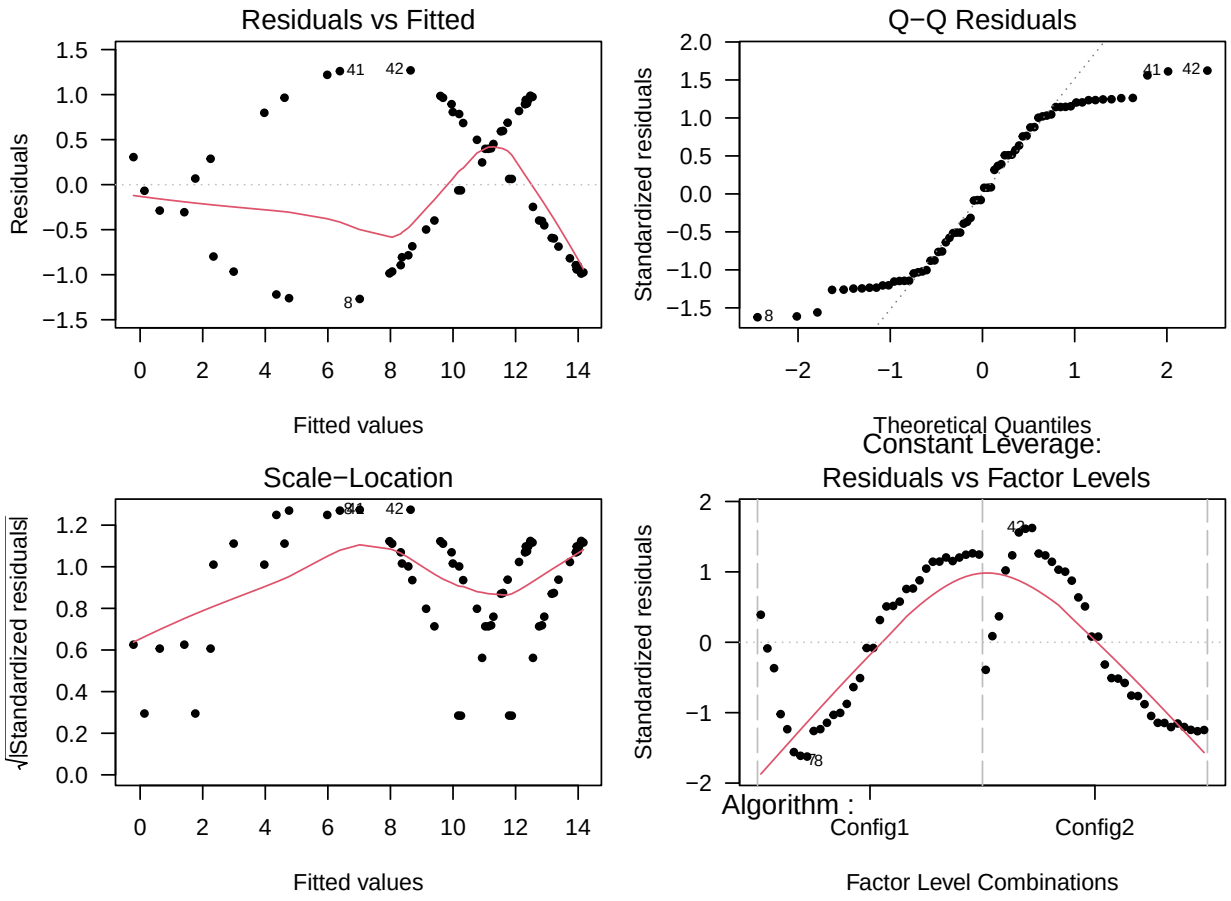


Figura 4: Gráficos diagnósticos dos resíduos do modelo linear RCBD para $\log(\bar{Y}_{ij})$

```
shapiro_D   <- shapiro.test(block_wide$D)
res_rcbd    <- residuals(modelo_rcbd)
shapiro_res <- shapiro.test(res_rcbd)

dados_rcbd$res <- res_rcbd
fligner_res    <- fligner.test(res ~ Algorithm, data = dados_rcbd)
fligner_log    <- fligner.test(log_Y ~ Algorithm, data = dados_rcbd)

par(mfrow = c(1, 2), mar = c(4.2, 4.2, 2, 1))
car::qqPlot(block_wide$D, pch = 20, id = FALSE,
            main = "Q-Q Plot: Diferenças D_j",
            ylab = "Quantis observados (D_j)",
            xlab = "Quantis teóricos (Normal)")
car::qqPlot(res_rcbd, pch = 20, id = FALSE,
            main = "Q-Q Plot: Resíduos do RCBD",
            ylab = "Quantis observados (Resíduos)",
            xlab = "Quantis teóricos (Normal)")
```

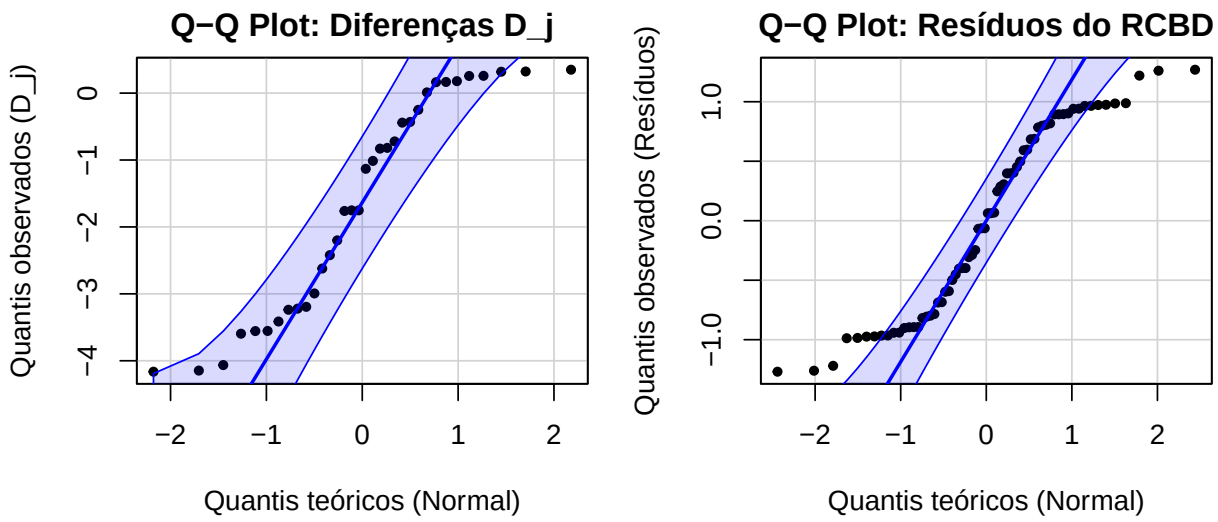


Figura 5: Gráficos Q-Q Normal com envelope de confiança de 95%: diferenças pareadas D_j (esquerda) e resíduos do RCBD (direita)

```
tabela_prem <- data.frame(
  Premissa = c("Normalidade das diferenças pareadas ($D_j$)",
               "Normalidade dos resíduos do RCBD ($\\hat{\\epsilon}_{ij}$)",
               "Homocedasticidade dos resíduos por tratamento"),
  Teste = c("Shapiro-Wilk", "Shapiro-Wilk", "Fligner-Killeen"),
  Estatistica = c(sprintf("$W = %.4f$", shapiro_D$statistic),
                  sprintf("$W = %.4f$", shapiro_res$statistic),
                  sprintf("$\\chi^2 = %.4f$ (g.l. = 1)", fligner_res$statistic)),
  p_valor = c(sprintf("%.4f", shapiro_D$p.value),
              sprintf("%.4f", shapiro_res$p.value),
              sprintf("%.4f", fligner_res$p.value)),
  Decisao = c("Rejeita $H_0$ (Não normal)",
              "Rejeita $H_0$ (Não normal)",
              "Não rejeita $H_0$ (Homocedástico)"),
  check.names = FALSE
)

cap_prem <- paste0(
  "\\label{tab:premissas}Síntese dos testes formais de verificação ",
  "das premissas ($\\alpha = 0{,}05$)"
)

knitr::kable(
  tabela_prem,
  caption   = cap_prem,
  col.names = c("Premissa Avaliada", "Teste Estatístico", "Estatística",
                "Valor-$p$", "Conclusão ($\\alpha = 0{,}05$)"),
  align     = c("l", "c", "c", "c", "c"),
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 9: Síntese dos testes formais de verificação das premissas ($\alpha = 0{,}05$)

Premissa Avaliada	Teste Estatístico	Estatística	Valor-p	Conclusão ($\alpha = 0{,}05$)
Normalidade das diferenças pareadas (D_j)	Shapiro-Wilk	$W = 0.8934$	0.0031	Rejeita H_0 (Não normal)
Normalidade dos resíduos do RCBD ($\hat{\epsilon}_{ij}$)	Shapiro-Wilk	$W = 0.9132$	0.0002	Rejeita H_0 (Não normal)
Homocedasticidade dos resíduos por tratamento	Fligner-Killeen	$\chi^2 = 0.0005$ (g.l. = 1)	0.9827	Não rejeita H_0 (Homocedástico)

A avaliação diagnóstica sintetizada na Tabela 9 e nas Figuras 4 e 5 demonstra que:

- **Independência:** É assegurada diretamente pelo protocolo experimental: cada instância corresponde a um espaço dimensional distinto, todas as execuções utilizaram sementes pseudoaleatórias exclusivas em ordem completamente casualizada, e a variável resposta (F_{best}) depende unicamente da trajetória estocástica do algoritmo, sendo imune a flutuações de tempo de máquina.
- **Homocedasticidade:** O teste não paramétrico de Fligner-Killeen sobre os resíduos do modelo RCBD ($\chi^2 = 0{,}0005$; $p = 0{,}9827$) confirma a homogeneidade de variâncias entre os níveis do fator experimental (nota-se que, para $a = 2$ tratamentos em blocos completos, os resíduos satisfazem $\hat{\epsilon}_{1j} = -\hat{\epsilon}_{2j} = (D_j - \bar{D})/2$, possuindo dispersão simétrica entre os dois grupos). Contudo, o gráfico *Residuals vs Fitted* (Figura 4) exibe uma estrutura sistemática em função da magnitude ajustada (dimensão), refletindo a interação entre configuração e dimensão discutida na Seção 3.
- **Violação da Normalidade:** Tanto o teste de Shapiro-Wilk sobre as diferenças pareadas D_j ($W = 0{,}8934$; $p = 0{,}0031 < 0{,}05$) quanto sobre os resíduos do RCBD ($W = 0{,}9133$; $p = 0{,}0002 < 0{,}05$) **rejeitam a hipótese nula de normalidade**. Os gráficos Q-Q (Figura 5) mostram afastamentos nas caudas (formato em "S"), provocados pela concentração de valores positivos leves ($D_j \in [0{,}01; 0{,}35]$) nas dimensões acima de 128 em contraste com os valores fortemente negativos ($D_j \approx -4{,}1$) nas dimensões intermediárias.

6.2 Abordagem Não Paramétrica (Métodos Livres de Distribuição)

Embora o teste t pareado possua reconhecida robustez a desvios moderados de normalidade para $N = 34$ graças ao Teorema Central do Limite (Montgomery e Runger, 2010), a boa prática estatística estabelece que, quando as premissas paramétricas não são atendidas mesmo após transformação logarítmica, devem-se aplicar **métodos não paramétricos (livres de distribuição)** para validar as inferências (Sprent e Smeeton, 1993; Sheskin, 2003; Davison e Hinkley, 1997; Ernst, 2004).

Para cobrir diferentes níveis de suposições sobre a distribuição das diferenças D_j, aplicam-se quatro procedimentos não paramétricos complementares:

1. **Teste dos Postos Sinalizados de Wilcoxon Pareado:** Avalia a hipótese nula de que a mediana (e pseudo-mediana de Hodges-Lehmann) das diferenças pareadas é nula ($H_0 : \theta_D = 0$ versus $H_1 : \theta_D \neq 0$), levando em conta tanto o sinal quanto o posto (*rank*) da magnitude absoluta $|D_j|$. Exige amostras i.i.d. de distribuição contínua e simétrica.
2. **Teste do Sinal (Binomial Exato):** Avalia $H_0 : \theta_D = 0$ contabilizando apenas o número de diferenças positivas $r^+ = \sum \mathbb{I}(D_j > 0)$ frente a uma distribuição Binomial $B(N, p = 0{,}5)$. Sua grande vantagem neste estudo é **não exigir simetria** da distribuição de D_j (requer apenas observações i.i.d. e contínuas).
3. **Teste de Permutação Pareado ($R = 9.999$):** Sob H_0, os rótulos das duas configurações dentro de cada bloco são intercambiáveis, o que equivale a atribuir sinais aleatórios $\{-1, +1\}$ a cada D_j. Calcula-se a distribuição empírica exata da média $|\bar{D}^*_r|$ sob $R = 9.999$ permutações, obtendo-se p-valor $= (1 + \#\{|\bar{D}^*_r| \geq |\bar{D}|\})/(R + 1)$ (Ernst, 2004).

4. **Teste e Intervalo de Confiança via Bootstrap Não Paramétrico ($R = 9.999$):** Realizam-se $R = 9.999$ reamostragens com reposição de tamanho $N = 34$ a partir do vetor observado $\mathbf{D}$ (para estimar o $\text{IC}_{95\%}$ livre de distribuição para μ_D e para e^{μ_D}) e a partir do vetor centrado sob H_0 ($\tilde{D}_j = D_j - \bar{D}$) para o cálculo do valor-p via reamostragem (Davison e Hinkley, 1997).

```r
# 1. Teste de Wilcoxon Pareado Exato
wilcox_res <- wilcox.test(block_wide$D, mu = 0, alternative = "two.sided",
                          conf.int = TRUE, conf.level = 0.95, exact = TRUE)

# 2. Teste do Sinal (Binomial)
r_pos  <- sum(block_wide$D > 0)
r_neg  <- sum(block_wide$D < 0)
p_sign <- 2 * pbinom(min(r_pos, r_neg), size = N_used, prob = 0.5)
med_D  <- median(block_wide$D)

# 3. Teste de Permutação Pareado (R = 9999)
set.seed(2026)
R_rep  <- 9999
t_hat  <- abs(mean(block_wide$D))
t_perm <- numeric(R_rep)
for (i in 1:R_rep) {
  sinais    <- sample(c(-1, 1), size = N_used, replace = TRUE)
  t_perm[i] <- abs(mean(block_wide$D * sinais))
}
p_perm <- (1 + sum(t_perm >= t_hat)) / (R_rep + 1)

# 4. Teste e IC de Bootstrap Não-Paramétrico (R = 9999)
set.seed(112)
D_centrada <- block_wide$D - mean(block_wide$D)
t_boot_H0  <- numeric(R_rep)
boot_means <- numeric(R_rep)
for (i in 1:R_rep) {
  idx           <- sample(1:N_used, size = N_used, replace = TRUE)
  boot_means[i] <- mean(block_wide$D[idx])
  t_boot_H0[i]  <- abs(mean(D_centrada[idx]))
}
p_boot       <- (1 + sum(t_boot_H0 >= t_hat)) / (R_rep + 1)
ic_boot_log  <- quantile(boot_means, probs = c(0.025, 0.975))
ic_boot_orig <- exp(ic_boot_log)

tabela_np <- data.frame(
  Metodo = c("Teste $t$ Pareado (Paramétrico)",
             "Teste de Wilcoxon Pareado (Postos Sinalizados)",
             "Teste do Sinal (Binomial Exato)",
             "Teste de Permutação Pareado ($R = 9.999$)",
             "Bootstrap Não Paramétrico ($R = 9.999$)"),
  Estatistica = c(
    sprintf("$t_0 = %.4f$ (g.l. = 33)", teste_t$statistic),
    sprintf("$V = %.0f$ ($S_+ = 50, S_- = 545$)", wilcox_res$statistic),
    sprintf("$r^+ = %d, r^- = %d$ ($N = 34$)", r_pos, r_neg),
    sprintf("$\\vert\\bar{D}\\vert = %.4f$", t_hat),
    sprintf("$\\vert\\bar{D}\\vert = %.4f$", t_hat)
  ),
  Estimativa_Log = c(
```

```
    sprintf("Média = %.4f", D_bar),
    sprintf("Pseudo-mediana = %.4f", wilcox_res$estimate),
    sprintf("Mediana = %.4f", med_D),
    sprintf("Média = %.4f", D_bar),
    sprintf("Média = %.4f", mean(boot_means))
  ),
  IC_Log = c(
    sprintf("[%.4f; %.4f]", teste_t$conf.int[1], teste_t$conf.int[2]),
    sprintf("[%.4f; %.4f]", wilcox_res$conf.int[1], wilcox_res$conf.int[2]),
    "---",
    "---",
    sprintf("[%.4f; %.4f]", ic_boot_log[1], ic_boot_log[2])
  ),
  p_valor = c(
    format.pval(teste_t$p.value, digits = 4, eps = 1e-10),
    format.pval(wilcox_res$p.value, digits = 4, eps = 1e-10),
    sprintf("%.4f", p_sign),
    sprintf("%.4f", p_perm),
    sprintf("%.4f", p_boot)
  ),
  check.names = FALSE
)

cap_np <- paste0(
  "\\label{tab:comparacao_np}Comparação consolidada entre o teste ",
  "paramétrico e os métodos não paramétricos aplicados às diferenças $D_j$"
)

knitr::kable(
  tabela_np,
  caption   = cap_np,
  col.names = c("Método de Teste", "Estatística Observada",
                "Estimativa Central (log)", "IC 95\\% (escala log)",
                "Valor-$p$"),
  align     = c("l", "c", "c", "c", "c"),
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 10: Comparação consolidada entre o teste paramétrico e os métodos não paramétricos aplicados às diferenças D_j

Método de Teste	Estatística Observada	Estimativa Central (log)	IC 95% (escala log)	Valor-p
Teste t Pareado (Paramétrico)	$t_0 = -5.9720$ (g.l. = 33)	Média = -1.6254	[-2.1791; -1.0717]	1.048e-06
Teste de Wilcoxon Pareado (Postos Sinalizados)	$V = 50$ ($S_+ = 50, S_- = 545$)	Pseudo-mediana = -1.6250	[-2.1572; -1.0009]	3.604e-06
Teste do Sinal (Binomial Exato)	$r^+ = 9, r^- = 25$ ($N = 34$)	Mediana = -1.4416	—	0.0090
Teste de Permutação Pareado ($R = 9.999$)	$\lvert\bar{D}\rvert = 1.6254$	Média = -1.6254	—	0.0001

Método de Teste	Estatística Observada	Estimativa Central (log)	IC 95% (escala log)	Valor-p
Bootstrap Não Paramétrico ($R = 9.999$)	$\lvert\bar{D}\rvert = 1.6254$	Média = -1.6224	[-2.1555; -1.1037]	0.0001

Os resultados da Tabela 10 demonstram **convergência unânime** entre a abordagem paramétrica e todos os métodos não paramétricos:

- No **Teste de Wilcoxon Pareado**, a soma dos postos positivos foi $S_+ = V = 50$ contra $S_- = 545$ para os postos negativos ($p = 3{,}604 \times 10^{-6}$). A pseudo-mediana estimada ($\hat{\theta}_D = -1{,}6250$, com $\text{IC}_{95\%} = [-2{,}1572; -1{,}0009]$) é praticamente idêntica à média paramétrica ($\bar{D} = -1{,}6254$), correspondendo a uma razão de desempenho $e^{\hat{\theta}_D} = 0{,}1969$ ($\text{IC}_{95\%} : [0{,}1156; 0{,}3675]$).
- No **Teste do Sinal**, livre inclusive da suposição de simetria, a vitória da Configuração 1 em 25 das 34 instâncias ($r^+ = 9$ e $r^- = 25$) resulta em $p = 0{,}0090 < 0{,}05$, com mediana amostral $\text{Med}(D_j) = -1{,}4416$ (razão mediana de $e^{-1{,}4416} = 0{,}2365$, isto é, redução mediana de 76,35% no valor de F_{best}).
- Nos testes baseados em reamostragem (**Permutação** e **Bootstrap Não Paramétrico** com $R = 9.999$), nenhuma das 9.999 realizações sob H_0 atingiu estatística tão extrema quanto a observada (p-valor $= 1/(9999 + 1) = 0{,}0001$), e o intervalo de confiança de 95% via Bootstrap percentílico ($[-2{,}1555; -1{,}1037]$ na escala logarítmica, ou $[0{,}1158; 0{,}3316]$ para a razão $\bar{Y}_1/\bar{Y}_2$) ratifica integralmente a precisão da estimativa paramétrica.

---

7. Derivação de Conclusões e Recomendações

Com base nas evidências empíricas e nos testes estatísticos paramétricos e não paramétricos conduzidos, respondem-se diretamente às três perguntas técnicas de interesse deste estudo de caso:

1. **Há alguma diferença no desempenho médio do algoritmo quando equipado com estas diferentes configurações, para a classe de problemas de interesse?**
   Sim. Há evidência estatística altamente significativa ($\alpha = 0{,}05$) de diferença entre o desempenho das duas configurações do algoritmo de Evolução Diferencial para a classe de funções de Rosenbrock com dim $\in [2, 150]$. Essa conclusão é sustentada tanto pelo teste t pareado bilateral / ANOVA do RCBD ($t_0 = -5{,}9720$, $F_0 = 35{,}6647$, $p = 1{,}048 \times 10^{-6}$) quanto pelos métodos não paramétricos livres de distribuição acionados diante do desvio de normalidade: Teste de Wilcoxon Pareado ($V = 50$, $p = 3{,}604 \times 10^{-6}$), Teste do Sinal Binomial ($p = 0{,}0090$) e Testes de Permutação e Bootstrap ($p = 0{,}0001$).
2. **Caso haja, qual a melhor configuração em termos de desempenho médio, e qual a magnitude das diferenças encontradas?**
   A **Configuração 1** (`recombination_exp` com $cr = 0{,}6$ e `mutation_best` com $f = 2$) apresenta o **melhor desempenho médio** (menores valores de F_{best}). Na escala logarítmica, a diferença média estimada é $\bar{D} = -1{,}6254$ ($\text{IC}_{95\%} : [-2{,}1791; -1{,}0717]$) e a pseudo-mediana de Wilcoxon é $\hat{\theta}_D = -1{,}6250$ ($\text{IC}_{95\%} : [-2{,}1572; -1{,}0009]$). O tamanho de efeito padronizado observado é $|d| = 1{,}0242$, superando em mais de duas vezes o limiar mínimo de relevância prática estipulado ($d^* = 0{,}50$). Na escala original da função objetivo, a razão geométrica média é $e^{\bar{D}} = 0{,}1968$ ($\text{IC}_{95\%} : [0{,}1131; 0{,}3424]$), o que significa que a Configuração 1 reduz o valor final de F_{best} em **80,32%** em média geométrica ($\text{IC}_{95\%} : [65{,}76\%; 88{,}69\%]$), enquanto a Configuração 2 produz erros de otimização em média **5,08 vezes maiores**.
3. **Há alguma configuração que deva ser recomendada em relação à outra?**
   Sim, recomenda-se a Configuração 1 como escolha padrão para a classe de problemas investigada. Ela venceu em 73,5% das instâncias (25 de 34) e dominou com larga vantagem todo o espectro de dimensões baixas a moderadas-altas (dim $\in [4, 115]$), chegando a retornar valores mais de 60 vezes menores que os da Configuração 2 em dimensões intermediárias (dim $\in [17, 34]$). Como recomendação complementar de engenharia, ressalva-se apenas que, para aplicações restritas especificamente ao

regime de altíssima dimensão (dim $\in [128, 150]$), a Configuração 2 apresentou vantagem marginal ($D_j \in [+0{,}01; +0{,}35]$, ou redução de 1% a 29% em F_{best}), pois a mutação gulosa `mutation_best` da Configuração 1 tende a sofrer convergência prematura quando a dimensão do espaço de busca cresce muito sob o orçamento fixo de $5000 \cdot \text{dim}$ avaliações.

---

8. Discussão sobre Possíveis Limitações do Estudo e Sugestões de Melhoria

Apesar do rigor no dimensionamento amostral ($N = 34$, $n = 30$) e da robustez das conclusões confirmadas por múltiplos testes paramétricos e não paramétricos, uma análise crítica do experimento permite apontar quatro limitações metodológicas e operacionais, acompanhadas de sugestões concretas para trabalhos futuros:

1. **Interação entre Tratamento e Bloco (Dependência da Dimensão) e Violação de Aditividade:** O modelo clássico do RCBD ($y_{ij} = \mu + \tau_i + \beta_j + \epsilon_{ij}$) assume aditividade entre o efeito do algoritmo (τ_i) e o efeito da instância (β_j), isto é, supõe que a diferença D_j flutue aleatoriamente em torno de uma constante μ_D ao longo de todas as dimensões. Contudo, a análise exploratória (Figura 3) demonstrou que D_j varia sistematicamente com a dimensão — sendo fortemente negativo para dim ≤ 115 e levemente positivo para dim ≥ 128 —, o que ocasionou a rejeição da normalidade no teste de Shapiro-Wilk. **Sugestão de melhoria:** Estratificar a classe de problemas em sub-regimes de dimensão (ex.: baixa dim $\in [2, 50]$, média dim $\in [51, 115]$ e alta dim $\in [116, 150]$) ou ajustar um modelo de regressão/ANCOVA incorporando a dimensão como covariável contínua com termo de interação (Algorithm $\times$ dim).

2. **Acoplamento (Confundimento) entre Operadores de Mutação e Recombinação:** As duas configurações comparadas diferem simultaneamente no operador de recombinação (`exp` vs. `geo`), no operador de mutação (`best` vs. `rand`) e nos valores numéricos de seus hiperparâmetros (cr/α e f). Assim, o delineamento com um único fator de dois níveis permite identificar qual pacote fechado é superior, mas não permite isolar se a vantagem da Configuração 1 decorre da recombinação exponencial, da mutação `best` ou da sinergia entre ambas. **Sugestão de melhoria:** Planejar um **Experimento Fatorial 2^2 com Blocagem por Instância** (combinando os dois operadores de mutação com os dois operadores de recombinação em cada bloco), permitindo estimar separadamente os efeitos principais de cada operador e o efeito de interação entre eles (Montgomery, 2005; Campelo, 2018).

3. **Restrição a uma Única Topologia de Função de Benchmark (Rosenbrock) e Orçamento Fixo:** As conclusões obtidas são estritamente válidas para a família de funções de Rosenbrock, caracterizada por um vale parabólico estreito e contínuo, sob o orçamento fixo de $5000 \cdot \text{dim}$ avaliações. Em funções altamente multimodais (como Rastrigin, Ackley ou Schwefel), operadores gulosos como `mutation_best` com fator $f = 2$ podem ficar retidos em ótimos locais com maior frequência. **Sugestão de melhoria:** Expandir o conjunto de benchmark para múltiplas famílias de funções com diferentes características topológicas (unimodais, multimodais, separáveis e não separáveis), tratando a família da função e a dimensão como dois fatores de blocagem (ex.: delineamento em Quadrado Latino ou RCBD com múltiplos fatores bloqueados) e avaliando também curvas de convergência em diferentes orçamentos de avaliação.

4. **Alocação Igual vs. Alocação Ótima de Repetições Intra-Bloco:** Adotou-se alocação balanceada ($n_1 = n_2 = 30$) em todas as dimensões. Entretanto, o estudo piloto indicou que a Configuração 2 apresenta desvio padrão intra-instância superior ao da Configuração 1 ($\hat{\sigma}_2 = 0{,}1967$ contra $\hat{\sigma}_1 = 0{,}1247$), e instâncias de maior dimensão demandam custo computacional linearmente mais elevado. **Sugestão de melhoria:** Em cenários com restrição severa de tempo computacional, aplicar a alocação ótima de Neyman proposta por Campelo e Takahashi (2019), destinando proporcionalmente mais repetições à configuração de maior variabilidade ($n_2/n_1 \approx \hat{\sigma}_2/\hat{\sigma}_1$).

Declaração de uso de IA generativa e tecnologias assistidas por IA

Durante a preparação deste trabalho, os autores utilizaram ferramentas de inteligência artificial generativa (Claude Opus 4.6, da Anthropic, e Gemini, do Google) com o objetivo de auxiliar na estruturação de código em R, formatação de tabelas em R Markdown e revisão técnica e textual do relatório. Após a utilização dessas ferramentas, os autores conferiram todos os cálculos, revisaram e editaram o conteúdo integralmente, assumindo total responsabilidade pela exatidão e integridade do material publicado.

Papéis e Contribuições da Equipe

- **Beatriz S. Campagnaro:** Execução e monitoramento da coleta de dados, desenvolvimento dos scripts estatísticos em R, redação do manuscrito e verificação técnica.
- **Filipe C. Andrade:** Planejamento experimental, desenvolvimento dos scripts estatísticos em R, análise de premissas e métodos não paramétricos, redação e revisão do relatório.
- **Izabela C. S. Barbosa:** Análise exploratória, tabulação dos dados, estimação de magnitude de efeito, redação das conclusões e verificação final de reprodutibilidade.

Referências

BOSSEK, J. smoof: Single- and Multi-Objective Optimization Test Functions. *The R Journal*, v. 9, n. 1, p. 103–113, 2017.

CAMPELO, F.; BOTELHO, M. Experimental investigation of recombination operators for differential evolution. In: *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO'2016)*, p. 533–540, 2016.

CAMPELO, F. *Lecture Notes on Design and Analysis of Experiments*. Versão 2.12, 2018. Disponível em: http://git.io/v3Kh8.

CAMPELO, F.; TAKAHASHI, F. Sample size estimation for power and accuracy in the experimental comparison of algorithms. *Journal of Heuristics*, v. 25, n. 2, p. 305–338, 2019.

DAVISON, A. C.; HINKLEY, D. V. *Bootstrap Methods and Their Application*. Cambridge: Cambridge University Press, 1997.

ERNST, M. D. Permutation methods: a basis for exact inference. *Statistical Science*, v. 19, n. 4, p. 676–685, 2004.

FENG, C.; WANG, H.; LU, N.; TU, X. M. Log transformation: application and interpretation in biomedical research. *Statistics in Medicine*, v. 32, n. 2, p. 230–239, 2013.

MONTGOMERY, D. C. *Design and Analysis of Experiments*. 7. ed. Hoboken: John Wiley & Sons, 2005.

MONTGOMERY, D. C.; RUNGER, G. C. *Applied Statistics and Probability for Engineers*. 5. ed. Hoboken: John Wiley & Sons, 2010.

POHLHEIM, H. *Examples of Objective Functions*. 2005. Disponível em: http://www.geatbx.com/download/GEATbx_ObjFunExpl_v37.pdf.

ROSENBROCK, H. H. An automatic method for finding the greatest or least value of a function. *The Computer Journal*, v. 3, n. 3, p. 175–184, 1960.

SHESKIN, D. J. *Handbook of Parametric and Nonparametric Statistical Procedures*. 3. ed. Boca Raton: Chapman and Hall/CRC, 2003.

SPRENT, P.; SMEETON, N. C. *Applied Nonparametric Statistical Methods*. 3. ed. Boca Raton: Chapman and Hall/CRC, 2000.

STORN, R.; PRICE, K. Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, v. 11, n. 4, p. 341–359, 1997.


```
## sessionInfo():
```

```
## R version 4.6.1 (2026-06-24 ucrt)
## Platform: x86_64-w64-mingw32/x64
## Running under: Windows 11 x64 (build 26300)
##
## Matrix products: default
##   LAPACK version 3.12.1
##
## locale:
## [1] LC_COLLATE=Portuguese_Brazil.utf8  LC_CTYPE=Portuguese_Brazil.utf8
## [3] LC_MONETARY=Portuguese_Brazil.utf8 LC_NUMERIC=C
## [5] LC_TIME=Portuguese_Brazil.utf8
##
## time zone: America/Sao_Paulo
## tzcode source: internal
##
## attached base packages:
## [1] stats     graphics  grDevices utils     datasets  methods   base
##
## other attached packages:
##  [1] kableExtra_1.4.1    knitr_1.51          car_3.1-5
##  [4] carData_3.0-6       tidyr_1.3.2         dplyr_1.2.1
##  [7] ggplot2_4.0.3       smoof_1.7.0         checkmate_2.3.4
## [10] ParamHelpers_1.14.2 ExpDE_0.2.0
##
## loaded via a namespace (and not attached):
##  [1] generics_0.1.4      xml2_1.6.0          stringi_1.8.9
##  [4] digest_0.6.39       magrittr_2.0.5      evaluate_1.0.5
##  [7] grid_4.6.1          RColorBrewer_1.1-3  BBmisc_1.13.1
## [10] fastmap_1.2.0       backports_1.5.1     Formula_1.2-6
## [13] purrr_1.2.2         viridisLite_0.4.3   scales_1.4.0
## [16] textshaping_1.0.5   abind_1.4-8         cli_3.6.6
## [19] rlang_1.3.0         withr_3.0.3         yaml_2.3.12
## [22] otel_0.2.0          tools_4.6.1         fastmatch_1.1-8
## [25] vctrs_0.7.3         R6_2.6.1            lifecycle_1.0.5
## [28] stringr_1.6.0       pkgconfig_2.0.3     pillar_1.11.1
## [31] gtable_0.3.6        data.table_1.18.6.1 glue_1.8.1
## [34] Rcpp_1.1.2          systemfonts_1.3.2   xfun_0.60
## [37] tibble_3.3.1        tidyselect_1.2.1    rstudioapi_0.19.0
## [40] farver_2.1.2        htmltools_0.5.9     labeling_0.4.3
## [43] rmarkdown_2.31      svglite_2.2.2       compiler_4.6.1
## [46] S7_0.2.2
```