Estudo de Caso 03: Comparação de desempenho de duas configurações de um algoritmo de otimização

Beatriz S. Campagnaro, Filipe C. Andrade e Izabela C. S. Barbosa

18 de Outubro de 2026

Resumo

Este estudo compara o desempenho de duas configurações do algoritmo de evolução diferencial (DE) aplicadas à classe de funções Rosenbrock com dimensão entre 2 e 150. O delineamento adotado é um experimento em blocos completos casualizados (RCBD), em que cada instância (dimensão) constitui um bloco e as duas configurações são os tratamentos. A variável resposta é a média do melhor valor da função objetivo (F_{best}) sobre as repetições em cada célula, transformada pela função logaritmo para estabilizar a escala entre instâncias. O teste principal é o teste t pareado sobre as diferenças dos logaritmos das médias de bloco, equivalente ao teste F do RCBD quando há dois tratamentos. Os resultados da análise, lorem lroem lorem.

Introdução

Algoritmos baseados em populações constituem uma alternativa para a solução de problemas de otimização não linear em engenharia (Storn e Price, 1997). Nesse cenário, um conjunto de soluções candidatas é iterativamente submetido a operadores de variação (mutação e recombinação) e seleção, promovendo a exploração do espaço de busca em direção ao ótimo da função objetivo. Entre esses métodos, a Evolução Diferencial (DE, do inglês *Differential Evolution*) destaca-se pela simplicidade estrutural e pela eficácia na otimização em espaços contínuos, sendo seu desempenho fortemente dependente da escolha adequada dos operadores e de seus hiperparâmetros (Campelo e Botelho, 2016).

Este estudo de caso tem como objetivo realizar a comparação experimental de duas configurações pré-ajustadas do algoritmo DE (atribuídas à Equipe B), aplicadas à classe de problemas de minimização definida pela família de funções de Rosenbrock (Rosenbrock, 1960; Pohlheim, 2005), implementada no pacote `smoof` (Bossek, 2017), com dimensão $\dim \in [2, 150]$ e domínio $[-5, 10]^{\dim}$. As configurações avaliadas são:

- **Configuração 1:** operador de recombinação exponencial (`recombination_exp`, com $cr = 0{,}6$) combinado ao operador de mutação baseado no melhor indivíduo (`mutation_best`, com $f = 2$).
- **Configuração 2:** operador de recombinação geométrica (`recombination_geo`, com $\alpha = 0{,}6$) combinado ao operador de mutação aleatória (`mutation_rand`, com $f = 1{,}2$).

Os demais parâmetros operacionais são mantidos fixos e idênticos para ambas as configurações em cada dimensão dim: seleção padrão (`selection_standard`), tamanho da população $N_{\text{pop}} = 5 \cdot \dim$, e critério de parada por orçamento máximo de avaliações da função objetivo (maxevals $= 5000 \cdot \dim$ ou maxiter $= 100 \cdot \dim$). O indicador de desempenho de cada execução é o melhor valor da função objetivo encontrado ao final da busca (F_{best}), de modo que menores valores indicam melhor desempenho do algoritmo.

A investigação é conduzida para responder às três questões propostas: (i) verificar se há diferença estatisticamente significativa no desempenho médio do algoritmo equipado com as duas configurações na classe de problemas de interesse; (ii) caso exista, identificar qual é a melhor configuração e estimar a magnitude dessa diferença; e (iii) estabelecer se alguma configuração deve ser recomendada em relação à outra. O

relatório está estruturado sequencialmente nas oito etapas metodológicas preconizadas para o planejamento e a análise do experimento.

1. Formulação das Hipóteses de Teste

Na comparação de algoritmos de otimização sobre uma classe heterogênea de problemas, a dificuldade intrínseca e a escala da função objetivo variam conforme a dimensão da instância avaliada. No contexto do planejamento de experimentos, a instância de teste (dimensão $\dim \in [2, 150]$) atua como um fator indesejável (*nuisance factor*) conhecido e controlável (Montgomery, 2005). Caso o experimento fosse conduzido sob um delineamento completamente casualizado (CRD), toda a variabilidade decorrente das diferentes dimensões seria absorvida pelo termo residual (MS_E), mascarando o efeito de interesse entre os algoritmos.

Seguindo o princípio fundamental de blocagem (*"Block what you can, randomize what you cannot"*), adota-se o Experimento Completamente Aleatorizado com Blocos (RCBD, *Randomized Complete Block Design*), em que cada instância $j \in \{1, \ldots, N\}$ constitui um bloco independente e as configurações $i \in \{1, 2\}$ representam os níveis do fator experimental (tratamentos). Para atender à estrutura do RCBD sem incorrer em pseudorreplicação, as n repetições estocásticas executadas para a configuração i na instância j são agregadas pela sua média amostral $\bar{Y}_{ij}$, fornecendo exatamente uma observação representativa por tratamento em cada bloco.

Além disso, como o valor de F_{best} na função de Rosenbrock cresce em múltiplas ordens de grandeza à medida que a dimensão aumenta, aplica-se a transformação logarítmica $y_{ij} = \log(\bar{Y}_{ij})$ (Feng et al., 2013; Campelo, 2018). Essa transformação estabiliza a variância entre blocos e converte comparações multiplicativas (razões de desempenho na escala original) em diferenças aditivas compatíveis com o modelo linear do RCBD:

$$y_{ij} = \mu + \tau_i + \beta_j + \epsilon_{ij} \begin{cases} i = 1, 2 \\ j = 1, \ldots, N \end{cases} \quad , \quad \epsilon_{ij} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$$

em que μ é a média global na escala logarítmica, τ_i é o efeito da i-ésima configuração ($\sum_{i=1}^{2} \tau_i = 0$), β_j é o efeito do j-ésimo bloco/instância ($\sum_{j=1}^{N} \beta_j = 0$) e ϵ_{ij} é o erro aleatório residual.

Como o experimento possui apenas dois níveis do fator de interesse ($a = 2$), o teste F da ANOVA para o RCBD ($H_0 : \tau_1 = \tau_2 = 0$) é algebricamente equivalente ao teste t pareado bilateral aplicado sobre as diferenças pareadas intra-bloco D_j (Montgomery, 2005):

$$D_j = y_{1j} - y_{2j} = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j}) = \log\left(\frac{\bar{Y}_{1j}}{\bar{Y}_{2j}}\right)$$

Pela definição adotada, valores negativos de D_j ($D_j < 0 \iff \bar{Y}_{1j} < \bar{Y}_{2j}$) indicam que a Configuração 1 obteve menor média de F_{best} (melhor desempenho) na instância j, enquanto valores positivos ($D_j > 0 \iff \bar{Y}_{1j} > \bar{Y}_{2j}$) favorecem a Configuração 2. As hipóteses estatísticas para o teste paramétrico principal são formuladas de maneira bilateral (sob H_0, assumindo ausência de diferença):

$$\begin{cases} H_0 : \mu_D = 0 \\ H_1 : \mu_D \neq 0 \end{cases}$$

onde $\mu_D = E[D_j]$ representa a diferença média populacional na escala logarítmica. Complementarmente, estabelece-se a priori que, caso a premissa de normalidade das diferenças D_j seja rejeitada ($\alpha = 0{,}05$), serão empregados métodos não paramétricos pareados (Teste dos Postos Sinalizados de Wilcoxon, Teste do Sinal e Testes de Permutação/Bootstrap), cujas hipóteses avaliam a localização central (mediana ou pseudo-mediana θ_D) da distribuição das diferenças: $H_0 : \theta_D = 0$ versus $H_1 : \theta_D \neq 0$.

2. Cálculo dos Tamanhos Amostrais

O planejamento amostral em experimentos de comparação de algoritmos em blocos envolve duas dimensões distintas (Campelo e Takahashi, 2019): (i) o número de instâncias (blocos) N, que governa os graus de liberdade do teste e o poder estatístico ($\pi = 1 - \beta$) frente à variabilidade entre problemas; e (ii) o número de repetições n de cada algoritmo por instância, que controla a precisão da estimativa pontual de $\bar{Y}_{ij}$ dentro de cada bloco.

2.1 Número de instâncias (N)

Os parâmetros experimentais especificados para o estudo são:

- Mínima diferença de importância prática padronizada: $d^* = \delta^*/\sigma_\Phi = 0{,}5$;
- Nível de significância desejado (probabilidade de Erro Tipo I): $\alpha = 0{,}05$;
- Potência mínima desejada (para o caso $d = d^*$): $\pi = 1 - \beta = 0{,}80$.

Sob a hipótese alternativa H_1 com efeito padronizado $d^* = 0{,}5$, a estatística do teste t pareado segue uma distribuição t não central com $\nu = N - 1$ graus de liberdade e parâmetro de não centralidade $\delta_{\text{ncp}} = d^*\sqrt{N}$. Como d^* já é normalizado pelo desvio padrão das diferenças entre blocos (σ_Φ), a determinação de N independe do estudo piloto.

```
# Cálculo iterativo do N mínimo para potência >= 0.80 no teste t pareado
calc_power_paired <- function(N, d_star = 0.5, alpha = 0.05) {
  df     <- N - 1
  ncp    <- d_star * sqrt(N)
  t_crit <- qt(1 - alpha / 2, df)
  power  <- 1 - pt(t_crit, df, ncp) + pt(-t_crit, df, ncp)
  return(power)
}

N_range <- 30:40
power_table <- data.frame(
  N     = N_range,
  gl    = N_range - 1,
  Poder = sapply(N_range, calc_power_paired)
)

cap_poder <- paste0(
  "\\label{tab:poder_N}Potência ($1 - \\beta$) do teste $t$ pareado ",
  "bilateral em função do número de instâncias $N$ ",
  "($d^* = 0{,}5$ e $\\alpha = 0{,}05$)"
)

knitr::kable(
  power_table,
  caption   = cap_poder,
  col.names = c("Número de Instâncias ($N$)",
                "Graus de Liberdade ($N-1$)",
                "Potência ($1 - \\beta$)"),
  digits    = 4,
  align     = "c",
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 1: Potência $(1-\beta)$ do teste t pareado bilateral em função do número de instâncias N ($d^* = 0{,}5$ e $\alpha = 0{,}05$)

Número de Instâncias (N)	Graus de Liberdade ($N-1$)	Potência $(1-\beta)$
30	29	0.7540
31	30	0.7685
32	31	0.7823
33	32	0.7954
34	33	0.8078
35	34	0.8195
36	35	0.8307
37	36	0.8412
38	37	0.8511
39	38	0.8605
40	39	0.8694

```
N       <- min(power_table$N[power_table$Poder >= 0.8])
poder_N <- calc_power_paired(N)
```

Conforme demonstrado na Tabela 1, o menor tamanho amostral que atende ao requisito $\pi \geq 0{,}80$ é $N = \mathbf{34\ instâncias}$, assegurando um poder estatístico de $\pi = 0.8078$ (com $N = 33$, o poder seria de 0,7954, insuficiente para o critério estabelecido).

2.2 Número de repetições por instância (n) e Estudo Piloto

A variância amostral da diferença observada em uma instância j, $D_j = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j})$, é composta pela variância real do efeito relativo entre problemas (σ^2_Φ) somada ao erro padrão quadrático de estimação intra-instância ($\text{se}^2_j = \sigma^2_{1j}/n_1 + \sigma^2_{2j}/n_2$). Segundo a metodologia de Campelo e Takahashi (2019), escolhe-se n de modo que a incerteza das repetições contribua com uma fração desprezível (no máximo 10%) da variância entre instâncias:

$$\text{se}^{*2} = \frac{\hat{\sigma}_1^2}{n} + \frac{\hat{\sigma}_2^2}{n} \leq 0{,}1 \cdot \hat{\sigma}^2_\Phi \implies n \geq \left\lceil \frac{\hat{\sigma}_1^2 + \hat{\sigma}_2^2}{0{,}1 \cdot \hat{\sigma}^2_\Phi} \right\rceil$$

Para estimar $\hat{\sigma}_1$, $\hat{\sigma}_2$ e $\hat{\sigma}_\Phi$, conduziu-se um estudo piloto preliminar em 5 dimensões sorteadas aleatoriamente em $[2, 150]$ com semente fixa (`set.seed(2026)`: dimensões `39, 46, 92, 112, 122`), executando $n_{\text{piloto}} = 15$ repetições por algoritmo em cada dimensão (150 execuções no total).

```
set.seed(2026)
pilot_dims <- sort(sample(2:150, 5))
n_pilot    <- 15
pilot_data <- read.csv("dados_piloto_EC03.csv", stringsAsFactors = FALSE)
```

```
pilot_sds <- pilot_data %>%
  group_by(dim, config) %>%
  summarise(sd_log     = sd(log(Fbest)),
            mean_Fbest = mean(Fbest),
            .groups    = "drop")

pilot_wide <- pilot_sds %>%
  pivot_wider(names_from  = config,
              values_from = c(mean_Fbest, sd_log)) %>%
  mutate(log_diff = log(mean_Fbest_Config1) - log(mean_Fbest_Config2))
```

```r
pilot_tab <- pilot_wide %>%
  select(dim, mean_Fbest_Config1, mean_Fbest_Config2,
         sd_log_Config1, sd_log_Config2, log_diff)

cap_piloto <- paste0(
  "\\label{tab:pilot_sd}Resultados do estudo piloto ",
  "($n_{\\text{piloto}} = 15$) nas 5 instâncias preliminares"
)

knitr::kable(
  pilot_tab,
  caption   = cap_piloto,
  digits    = c(0, 2, 2, 4, 4, 4),
  col.names = c("Dimensão", "$\\bar{Y}_{1j}$ (Config 1)",
                "$\\bar{Y}_{2j}$ (Config 2)", "$\\hat{\\sigma}_{1j}$ (log)",
                "$\\hat{\\sigma}_{2j}$ (log)", "$D_j$ (Piloto)"),
  align     = "c",
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 2: Resultados do estudo piloto ($n_{\text{piloto}} = 15$) nas 5 instâncias preliminares

Dimensão	$\bar{Y}_{1j}$ (Config 1)	$\bar{Y}_{2j}$ (Config 2)	$\hat{\sigma}_{1j}$ (log)	$\hat{\sigma}_{2j}$ (log)	D_j (Piloto)
39	588.06	29568.61	0.1090	0.2351	-3.9176
46	1372.43	40165.40	0.1588	0.2593	-3.3764
92	79978.96	233053.96	0.1160	0.1655	-1.0695
112	222135.52	320687.49	0.1304	0.1433	-0.3672
122	335887.44	376413.50	0.1009	0.1516	-0.1139

```r
s1_pool         <- sqrt(mean(pilot_wide$sd_log_Config1^2))
s2_pool         <- sqrt(mean(pilot_wide$sd_log_Config2^2))
sigma_phi_pilot <- sd(pilot_wide$log_diff)
target_se2      <- 0.1 * sigma_phi_pilot^2

n1_opt  <- ceiling(s1_pool * (s1_pool + s2_pool) / target_se2)
n2_opt  <- ceiling(n1_opt * s2_pool / s1_pool)
n_equal <- ceiling((s1_pool^2 + s2_pool^2) / target_se2)
n_final <- max(n_equal, 30)
```

A Tabela 2 apresenta o comportamento observado no piloto. Os desvios padrão combinados (*pooled*) intra-instância foram $\hat{\sigma}_1 = 0.1247$ e $\hat{\sigma}_2 = 0.1967$, enquanto o desvio padrão das diferenças entre blocos foi expressivo ($\hat{\sigma}_\Phi = 1.7603$). Como a variabilidade entre dimensões domina amplamente a variabilidade estocástica entre repetições de uma mesma dimensão, o limite $\text{se}^{*2} \leq 0.3099$ seria numericamente atendido já com $n_{\text{equal}} = 1$ repetição.

Entretanto, realizar apenas uma ou poucas repetições de um algoritmo estocástico como o DE comprometeria a estabilidade da média amostral $\bar{Y}_{ij}$. Assim, seguindo a recomendação clássica da literatura de experimentação em algoritmos (Campelo, 2018; Campelo e Takahashi, 2019) e utilizando o Teorema Central do Limite (TCL) para garantir que a média $\bar{Y}_{ij}$ de cada célula apresente distribuição amostral bem comportada e com baixo erro padrão ($\text{se}^{*2}_{n=30} = (\hat{\sigma}_1^2 + \hat{\sigma}_2^2)/30 = 0.0018 \ll 0.3099$), adotou-se $n = 30$ repetições independentes por configuração em cada instância.

3. Coleta e Tabulação dos Dados

Definidos os tamanhos amostrais ($N = 34$ instâncias e $n = 30$ repetições por célula), as 34 dimensões do experimento principal foram sorteadas aleatoriamente e sem reposição no conjunto $\{2, \ldots, 150\} \setminus \{39, 46, 92, 112, 122\}$ (excluindo-se as 5 dimensões já empregadas no piloto para evitar vazamento de informação e viés de seleção), utilizando semente fixa (`set.seed(933)`). As 34 dimensões selecionadas foram:

```
4, 6, 7, 10, 12, 17, 19, 34, 44, 45, 48, 49, 51, 53, 59, 62, 75, 76, 91, 96, 98, 100,
                108, 109, 115, 128, 136, 137, 139, 140, 142, 145, 147, 150
```

O plano completo de execução ($34 \times 2 \times 30 = 2.040$ execuções do algoritmo `ExpDE`) teve sua ordem de coleta completamente aleatorizada (`set.seed(7777)`) e cada rodada recebeu uma semente pseudoaleatória individual determinística em função da configuração, dimensão e repetição, garantindo total reprodutibilidade. Os dados brutos foram armazenados no arquivo `dados_EC03_grupoB.csv`.

```r
dados_brutos <- read.csv("dados_EC03_grupoB.csv", stringsAsFactors = FALSE)

n_obs       <- nrow(dados_brutos)
n_config1   <- sum(dados_brutos$Algorithm == "Config1")
n_config2   <- sum(dados_brutos$Algorithm == "Config2")
n_instances <- length(unique(dados_brutos$Instance))

tabela_coleta <- data.frame(
  Item = c("Total de execuções coletadas (linhas no CSV)",
           "Execuções da Configuração 1 (exp + best)",
           "Execuções da Configuração 2 (geo + rand)",
           "Número de instâncias / blocos (N)",
           "Repetições por configuração por instância (n)",
           "Total de médias de blocos geradas (a × N)"),
  Valor = c(n_obs, n_config1, n_config2, n_instances,
            n_final, 2 * n_instances),
  check.names = FALSE
)

knitr::kable(
  tabela_coleta,
  caption  = "\\label{tab:coleta}Síntese e verificação de integridade da coleta",
  align    = c("l", "c"),
  booktabs = TRUE
)
```

Tabela 3: Síntese e verificação de integridade da coleta

Item	Valor
Total de execuções coletadas (linhas no CSV)	2040
Execuções da Configuração 1 (exp + best)	1020
Execuções da Configuração 2 (geo + rand)	1020
Número de instâncias / blocos (N)	34
Repetições por configuração por instância (n)	30
Total de médias de blocos geradas (a × N)	68

Conforme detalhado na Seção 1, os dados brutos foram tabulados e agregados pela média das 30 repetições em cada célula ($\bar{Y}_{ij}$), calculando-se em seguida os valores transformados $\log(\bar{Y}_{ij})$ e as diferenças pareadas $D_j = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j})$ para cada um dos 34 blocos. A Tabela 4 sintetiza as estatísticas descritivas das

médias por instância, enquanto a Tabela 5 exibe uma visão parcial da tabulação pareada ao longo do espectro de dimensões.

```
block_means <- dados_brutos %>%
  group_by(Algorithm, Instance) %>%
  summarise(mean_Fbest = mean(Result),
            sd_Fbest   = sd(Result),
            .groups    = "drop")

block_wide <- block_means %>%
  select(Algorithm, Instance, mean_Fbest) %>%
  pivot_wider(names_from = Algorithm, values_from = mean_Fbest) %>%
  arrange(Instance) %>%
  mutate(log_C1 = log(Config1),
         log_C2 = log(Config2),
         D      = log_C1 - log_C2,
         Razao  = Config1 / Config2)

D_bar  <- mean(block_wide$D)
S_D    <- sd(block_wide$D)
N_used <- nrow(block_wide)
d_obs  <- D_bar / S_D

vars_list <- list(block_wide$Config1, block_wide$Config2,
                  block_wide$log_C1, block_wide$log_C2, block_wide$D)

resumo_desc <- data.frame(
  Variavel = c("$\\bar{Y}_{1j}$ (Config 1 - original)",
               "$\\bar{Y}_{2j}$ (Config 2 - original)",
               "$\\log(\\bar{Y}_{1j})$ (Config 1 - log)",
               "$\\log(\\bar{Y}_{2j})$ (Config 2 - log)",
               "Diferença pareada $D_j$ (log)"),
  Minimo  = sapply(vars_list, min),
  Q1      = sapply(vars_list, quantile, probs = 0.25),
  Mediana = sapply(vars_list, median),
  Media   = sapply(vars_list, mean),
  Q3      = sapply(vars_list, quantile, probs = 0.75),
  Maximo  = sapply(vars_list, max),
  DP      = sapply(vars_list, sd)
)

cap_desc <- paste0(
  "\\label{tab:resumo_descritivo}Estatísticas descritivas das médias ",
  "por bloco ($N = 34$ instâncias) nas escalas original e logarítmica"
)

knitr::kable(
  resumo_desc,
  caption   = cap_desc,
  col.names = c("Variável", "Mín.", "1º Quartil", "Mediana",
                "Média", "3º Quartil", "Máx.", "Desvio Padrão"),
  digits    = 2,
  align     = c("l", rep("c", 7)),
  booktabs  = TRUE,
```

```
  escape    = FALSE
)
```

Tabela 4: Estatísticas descritivas das médias por bloco ($N = 34$ instâncias) nas escalas original e logarítmica

Variável	Mín.	1º Quartil	Mediana	Média	3º Quartil	Máx.	Desvio Padrão
$\bar{Y}_{1j}$ (Config 1 - original)	1.07	1111.43	25568.18	191716.65	371810.53	741361.35	261115.29
$\bar{Y}_{2j}$ (Config 2 - original)	3.03	40063.64	147430.63	203933.70	386419.11	536691.42	191005.25
$\log(\bar{Y}_{1j})$ (Config 1 - log)	0.07	7.01	10.15	8.87	12.81	13.52	4.45
$\log(\bar{Y}_{2j})$ (Config 2 - log)	1.11	10.60	11.90	10.50	12.86	13.19	3.47
Diferença pareada D_j (log)	-4.16	-3.21	-1.44	-1.63	-0.05	0.35	1.59

```
# Selecionar 10 instâncias representativas ao longo do espectro [4, 150]
idx_mostra <- c(1, 4, 8, 12, 17, 22, 25, 26, 30, 34)
mostra_df <- block_wide[idx_mostra, ] %>%
  mutate(
    Config1_fmt = sprintf("%.2f", Config1),
    Config2_fmt = sprintf("%.2f", Config2),
    log_C1_fmt  = sprintf("%.4f", log_C1),
    log_C2_fmt  = sprintf("%.4f", log_C2),
    D_fmt       = sprintf("%.4f", D),
    Razao_fmt   = sprintf("%.4f", Razao)
  ) %>%
  select(Instance, Config1_fmt, Config2_fmt,
         log_C1_fmt, log_C2_fmt, D_fmt, Razao_fmt)

cap_mostra <- paste0(
  "\\label{tab:amostra_blocos}Tabulação das médias de bloco e diferenças ",
  "pareadas para 10 instâncias representativas dentre as 34 avaliadas"
)

knitr::kable(
  mostra_df,
  caption   = cap_mostra,
  col.names = c("Dimensão ($j$)", "$\\bar{Y}_{1j}$", "$\\bar{Y}_{2j}$",
                "$\\log(\\bar{Y}_{1j})$", "$\\log(\\bar{Y}_{2j})$",
                "$D_j = \\log(\\bar{Y}_{1j}/\\bar{Y}_{2j})$",
                "Razão ($\\bar{Y}_{1j}/\\bar{Y}_{2j}$)"),
  align     = "c",
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 5: Tabulação das médias de bloco e diferenças pareadas para 10 instâncias representativas dentre as 34 avaliadas

Dimensão (j)	$\bar{Y}_{1j}$	$\bar{Y}_{2j}$	$\log(\bar{Y}_{1j})$	$\log(\bar{Y}_{2j})$	$D_j = \log(\bar{Y}_{1j}/\bar{Y}_{2j})$	Razão ($\bar{Y}_{1j}/\bar{Y}_{2j}$)
4	1.10	3.03	0.0935	1.1070	-1.0135	0.3629
10	4.69	117.64	1.5464	4.7676	-3.2212	0.0399

Dimensão (j)	$\bar{Y}_{1j}$	$\bar{Y}_{2j}$	$\log(\bar{Y}_{1j})$	$\log(\bar{Y}_{2j})$	$D_j = \log(\bar{Y}_{1j}/\bar{Y}_{2j})$	Razão $(\bar{Y}_{1j}/\bar{Y}_{2j})$
34	314.22	20205.54	5.7501	9.9137	-4.1636	0.0156
49	1925.55	49066.95	7.5630	10.8009	-3.2380	0.0392
75	24479.85	141189.80	10.1056	11.8579	-1.7523	0.1734
100	125933.03	259238.62	11.7435	12.4655	-0.7220	0.4858
115	251419.86	322832.72	12.4349	12.6849	-0.2500	0.7788
128	411940.76	407614.57	12.9286	12.9181	0.0106	1.0106
140	577807.88	483363.59	13.2670	13.0885	0.1785	1.1954
150	741361.35	536691.42	13.5162	13.1932	0.3231	1.3814

Análise Exploratória dos Dados

A inspeção conjunta das Tabelas 4 e 5 mostra por que a transformação logarítmica é indispensável: na escala original, as médias $\bar{Y}_{ij}$ variam de 1,07 (dim = 6) a 741.361,35 (dim = 150), abrangendo seis ordens de grandeza. Na escala logarítmica, a dispersão é estabilizada e permite comparar diretamente a proporção entre o desempenho das configurações em cada bloco.

```
block_long <- block_wide %>%
  select(Instance, log_C1, log_C2) %>%
  pivot_longer(cols      = c(log_C1, log_C2),
               names_to  = "Config",
               values_to = "log_mean") %>%
  mutate(Config = ifelse(Config == "log_C1",
                         "Configuração 1 (exp + best)",
                         "Configuração 2 (geo + rand)"))

ggplot(block_long, aes(x = Config, y = log_mean, fill = Config)) +
  geom_boxplot(alpha = 0.6, outlier.shape = NA, width = 0.45) +
  geom_jitter(width = 0.12, size = 1.8, alpha = 0.7) +
  scale_fill_manual(values = c("Configuração 1 (exp + best)" = "steelblue",
                               "Configuração 2 (geo + rand)" = "tomato")) +
  labs(x = "Tratamento (Configuração do DE)",
       y = expression(log(bar(Y)[ij]))) +
  theme_minimal() +
  theme(legend.position = "none")
```

```
ggplot(block_wide, aes(x = Instance)) +
  geom_line(aes(y = log_C1, color = "Configuração 1 (exp + best)"),
            linetype = "dashed", linewidth = 0.7) +
  geom_point(aes(y = log_C1, color = "Configuração 1 (exp + best)"),
             size = 2.2) +
  geom_line(aes(y = log_C2, color = "Configuração 2 (geo + rand)"),
            linetype = "dashed", linewidth = 0.7) +
  geom_point(aes(y = log_C2, color = "Configuração 2 (geo + rand)"),
             size = 2.2) +
  geom_segment(aes(x = Instance, xend = Instance, y = log_C1, yend = log_C2),
               alpha = 0.35, color = "gray40") +
  scale_color_manual(values = c("Configuração 1 (exp + best)" = "steelblue",
                                "Configuração 2 (geo + rand)" = "tomato")) +
  labs(x     = "Dimensão da Instância (Bloco)",
       y     = expression(log(bar(Y)[ij])),
       color = "Tratamento") +
  theme_minimal() +
```

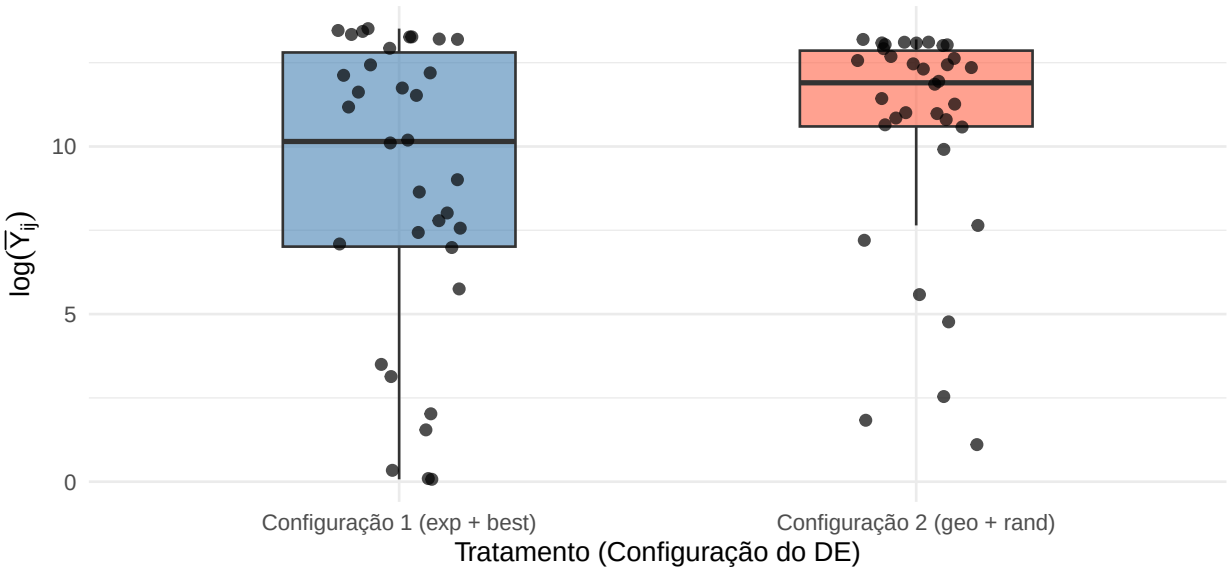


Figura 1: Distribuição de $\log(\bar{Y}_{ij})$ por configuração ao longo das 34 instâncias

```
  theme(legend.position = "bottom")
```

```
par(mfrow = c(1, 2), mar = c(4.2, 4.2, 2, 1))

# Painel 1: Histograma de D_j
hist(block_wide$D, breaks = 10, col = "steelblue", border = "white",
     main = "Distribuição de D_j",
     xlab = expression(D[j] == log(bar(Y)[1*j]) - log(bar(Y)[2*j])),
     ylab = "Frequência")
abline(v = 0, col = "red", lwd = 2, lty = 2)
abline(v = D_bar, col = "darkblue", lwd = 2)
legend("topleft", legend = c("H0 (D = 0)", "Média (-1,63)"),
       col = c("red", "darkblue"), lty = c(2, 1),
       lwd = 2, cex = 0.75, bty = "n")

# Painel 2: D_j versus Dimensão
cores_pts <- ifelse(block_wide$D < 0, "steelblue", "tomato")
plot(block_wide$Instance, block_wide$D, pch = 19, col = cores_pts,
     main = "Diferença Pareada vs. Dimensão",
     xlab = "Dimensão da Instância",
     ylab = expression(D[j]))
abline(h = 0, col = "red", lwd = 2, lty = 2)
legend("bottomright",
       legend = c("Config 1 melhor (25)", "Config 2 melhor (9)"),
       col = c("steelblue", "tomato"), pch = 19, cex = 0.75, bty = "n")
```

Os gráficos exploratórios revelam três padrões fundamentais do experimento:

1. **Superioridade global da Configuração 1:** Na Figura 1, a distribuição de $\log(\bar{Y}_{1j})$ apresenta mediana (10,15) e média (8,87) visivelmente inferiores às da Configuração 2 (mediana de 11,90 e média de 10,50), além de um deslocamento consistente para valores menores no gráfico de perfil por bloco (Figura 2).
2. **Forte efeito de bloco (dimensão):** A Figura 2 mostra que ambas as curvas crescem acentuadamente

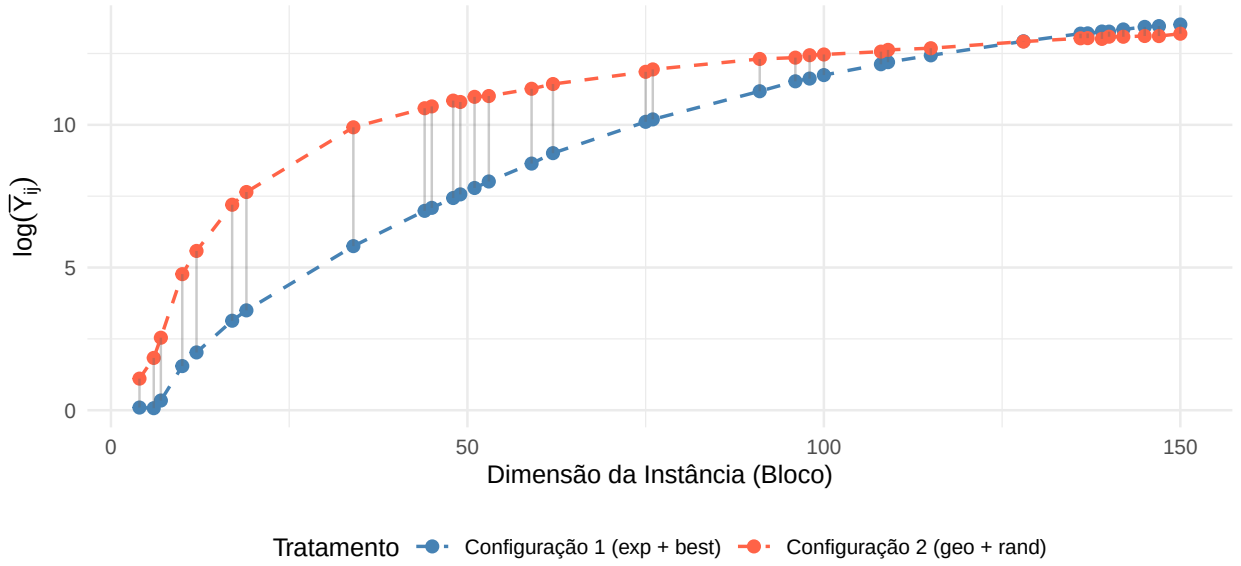


Figura 2: Perfil de desempenho por bloco (instância): $\log(\bar{Y}_{ij})$ para cada configuração em função da dimensão

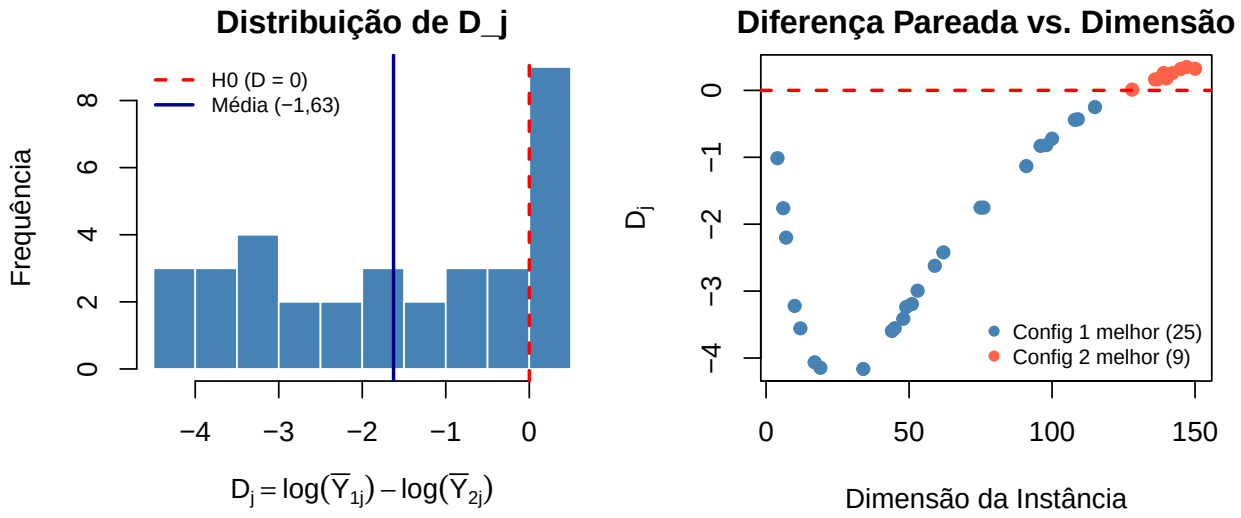


Figura 3: Esquerda: Histograma das diferenças pareadas D_j. Direita: Evolução de D_j em função da dimensão

com a dimensão do problema, confirmando que a blocagem por instância pode ser usada para isolar o efeito da dimensão do efeito dos operadores do algoritmo.

3. **Mudança de regime em dimensões muito altas:** O painel direito da Figura 3 mostra o comportamento das diferenças D_j ao longo das dimensões. Nas primeiras **25 instâncias** (dim $\in [4, 115]$, correspondendo a 73,5% dos blocos), tem-se $D_j < 0$, com vantagem expressiva da Configuração 1 (atingindo $D_j = -4{,}16$ em dim $= 34$, onde $\bar{Y}_1 = 314{,}22$ contra $\bar{Y}_2 = 20.205{,}54$). A partir de dim $= 128$ (nas 9 instâncias finais, dim $\in [128, 150]$), ocorre uma leve inversão ($D_j \in [+0{,}01; +0{,}35]$), na qual a Configuração 2 passa a obter valores ligeiramente menores. Esse comportamento em "U" explica a concentração de observações próxima a zero no histograma de D_j (painel esquerdo da Figura 3).

4. Teste das Hipóteses

Para testar formalmente se existe diferença significativa no desempenho médio entre as duas configurações ($H_0 : \mu_D = 0$ versus $H_1 : \mu_D \neq 0$, ao nível $\alpha = 0{,}05$), executam-se o teste t pareado bilateral sobre D_j e a Análise de Variância (ANOVA) do modelo linear RCBD sobre $y_{ij} = \log(\bar{Y}_{ij})$.

```
teste_t <- t.test(block_wide$D, mu = 0,
                  alternative = "two.sided", conf.level = 0.95)

tabela_t <- data.frame(
  Estatística = c("Média das diferenças ($\\bar{D}$)",
                  "Desvio padrão das diferenças ($S_D$)",
                  "Erro padrão da média ($S_D / \\sqrt{N}$)",
                  "Estatística de teste ($t_0$)",
                  "Graus de liberdade ($\\nu = N - 1$)",
                  "Valor-$p$ bilateral",
                  "IC 95\\% para $\\mu_D$ (limite inferior)",
                  "IC 95\\% para $\\mu_D$ (limite superior)"),
  Valor = c(
    sprintf("%.4f", D_bar),
    sprintf("%.4f", S_D),
    sprintf("%.4f", S_D / sqrt(N_used)),
    sprintf("%.4f", teste_t$statistic),
    N_used - 1,
    format.pval(teste_t$p.value, digits = 4, eps = 1e-10),
    sprintf("%.4f", teste_t$conf.int[1]),
    sprintf("%.4f", teste_t$conf.int[2])
  ),
  check.names = FALSE
)

cap_t <- paste0(
  "\\label{tab:teste_t}Resultado do teste $t$ pareado bilateral ",
  "sobre $D_j = \\log(\\bar{Y}_{1j}) - \\log(\\bar{Y}_{2j})$"
)

knitr::kable(
  tabela_t,
  caption  = cap_t,
  align    = c("l", "c"),
  booktabs = TRUE,
  escape   = FALSE
)
```

Tabela 6: Resultado do teste t pareado bilateral sobre $D_j = \log(\bar{Y}_{1j}) - \log(\bar{Y}_{2j})$

Estatística	Valor
Média das diferenças ($\bar{D}$)	-1.6254
Desvio padrão das diferenças (S_D)	1.5870
Erro padrão da média ($S_D/\sqrt{N}$)	0.2722
Estatística de teste (t_0)	-5.9720
Graus de liberdade ($\nu = N - 1$)	33
Valor-p bilateral	1.048e-06
IC 95% para μ_D (limite inferior)	-2.1791
IC 95% para μ_D (limite superior)	-1.0717

```r
dados_rcbd <- block_means %>%
  mutate(log_Y     = log(mean_Fbest),
         Instance  = factor(Instance),
         Algorithm = factor(Algorithm))

modelo_rcbd <- aov(log_Y ~ Algorithm + Instance, data = dados_rcbd)
anova_rcbd  <- summary(modelo_rcbd)[[1]]
r2_rcbd     <- summary.lm(modelo_rcbd)$r.squared

F_val <- anova_rcbd["Algorithm", "F value"]
t_val <- as.numeric(teste_t$statistic)

tabela_anova <- data.frame(
  Fonte  = c("Configuração (Algorithm)",
             "Instância / Bloco (Instance)",
             "Resíduos (Erro)"),
  GL     = anova_rcbd[, "Df"],
  SQ     = sprintf("%.4f", anova_rcbd[, "Sum Sq"]),
  QM     = sprintf("%.4f", anova_rcbd[, "Mean Sq"]),
  F_stat = c(sprintf("%.4f", anova_rcbd[1:2, "F value"]), "---"),
  p_val  = c(format.pval(anova_rcbd[1, "Pr(>F)"], digits = 4, eps = 1e-10),
             format.pval(anova_rcbd[2, "Pr(>F)"], digits = 4, eps = 1e-20),
             "---"),
  check.names = FALSE
)

cap_anova <- paste0(
  "\\label{tab:anova_rcbd}Tabela ANOVA do modelo RCBD para ",
  "$\\log(\\bar{Y}_{ij})$ ($R^2 = 0{,}9620$)"
)

knitr::kable(
  tabela_anova,
  caption   = cap_anova,
  col.names = c("Fonte de Variação", "g.l.", "Soma de Quadrados (SS)",
                "Quadrado Médio (MS)", "$F_0$", "Valor-$p$"),
  align     = c("l", rep("c", 5)),
  booktabs  = TRUE,
  escape    = FALSE
```

```
)
```

Tabela 7: Tabela ANOVA do modelo RCBD para $\log(\bar{Y}_{ij})$ ($R^2 = 0{,}9620$)

Fonte de Variação	g.l.	Soma de Quadrados (SS)	Quadrado Médio (MS)	F_0	Valor-p
Configuração (Algorithm)	1	44.9125	44.9125	35.6647	1.048e-06
Instância / Bloco (Instance)	33	1008.4889	30.5603	24.2677	2.367e-15
Resíduos (Erro)	33	41.5569	1.2593	—	—

Os resultados apresentados nas Tabelas 6 e 7 conduzem à rejeição da hipótese nula H_0 ($t_0 = -5{,}9720$, g.l. $= 33$, $p = 1{,}048 \times 10^{-6} \ll \alpha = 0{,}05$). A equivalência teórica entre os dois procedimentos para $a = 2$ tratamentos é numericamente verificada:

$$t_0^2 = (-5{,}9720)^2 = 35.6647 = F_0 \quad \text{e} \quad \text{MS}_{\text{Algorithm}} = \frac{N \cdot \bar{D}^2}{2} = \frac{34 \cdot (-1{,}6254)^2}{2} = 44{,}9125$$

Eficiência Relativa da Blocagem

A Tabela 7 confirma a importancia do fator bloqueado ($\text{MS}_{\text{Blocks}} = 30{,}5603$ contra $\text{MS}_E = 1{,}2593$, com $F_{\text{Bloco}} = 24{,}27$ e $p = 2{,}37 \times 10^{-15}$), resultando em um coeficiente de determinação de $R^2 = 96{,}20\%$. Para quantificar formalmente o ganho de poder proporcionado pelo RCBD em relação a um delineamento completamente casualizado (CRD), calcula-se a eficiência relativa da blocagem (E) (Montgomery, 2005):

$$E = \frac{(b-1)\text{MS}_{\text{Blocks}} + b(a-1)\text{MS}_E}{(ab-1)\text{MS}_E}$$

```
b_blocks <- N_used
a_treat  <- 2
MSBlocks <- anova_rcbd["Instance", "Mean Sq"]
MSE      <- anova_rcbd["Residuals", "Mean Sq"]

E_block <- ((b_blocks - 1) * MSBlocks + b_blocks * (a_treat - 1) * MSE) /
           ((a_treat * b_blocks - 1) * MSE)
```

Substituindo os valores obtidos ($b = 34$, $a = 2$, $\text{MS}_{\text{Blocks}} = 30{,}5603$ e $\text{MS}_E = 1{,}2593$), encontra-se $E =$ **12.46**. Isso significa que um experimento sem blocagem (CRD) precisaria de aproximadamente 1146% mais observações (cerca de 12,5 vezes mais instâncias por algoritmo) para alcançar a mesma sensibilidade estatística obtida com o RCBD neste estudo.

5. Verificação das Premissas dos Testes

A validade inferencial dos testes paramétricos (teste t pareado e ANOVA do RCBD) repousa sobre as premissas de normalidade, homocedasticidade e independência das observações. A seguir, cada premissa é verificado por meio de testes formais e inspeção gráfica dos resíduos.

5.1 Diagnóstico do Modelo Paramétrico (Normalidade, Homocedasticidade e Independência)

```
par(mfrow = c(2, 2), mar = c(4, 4, 2.2, 1))
plot(modelo_rcbd, pch = 20, las = 1)
```

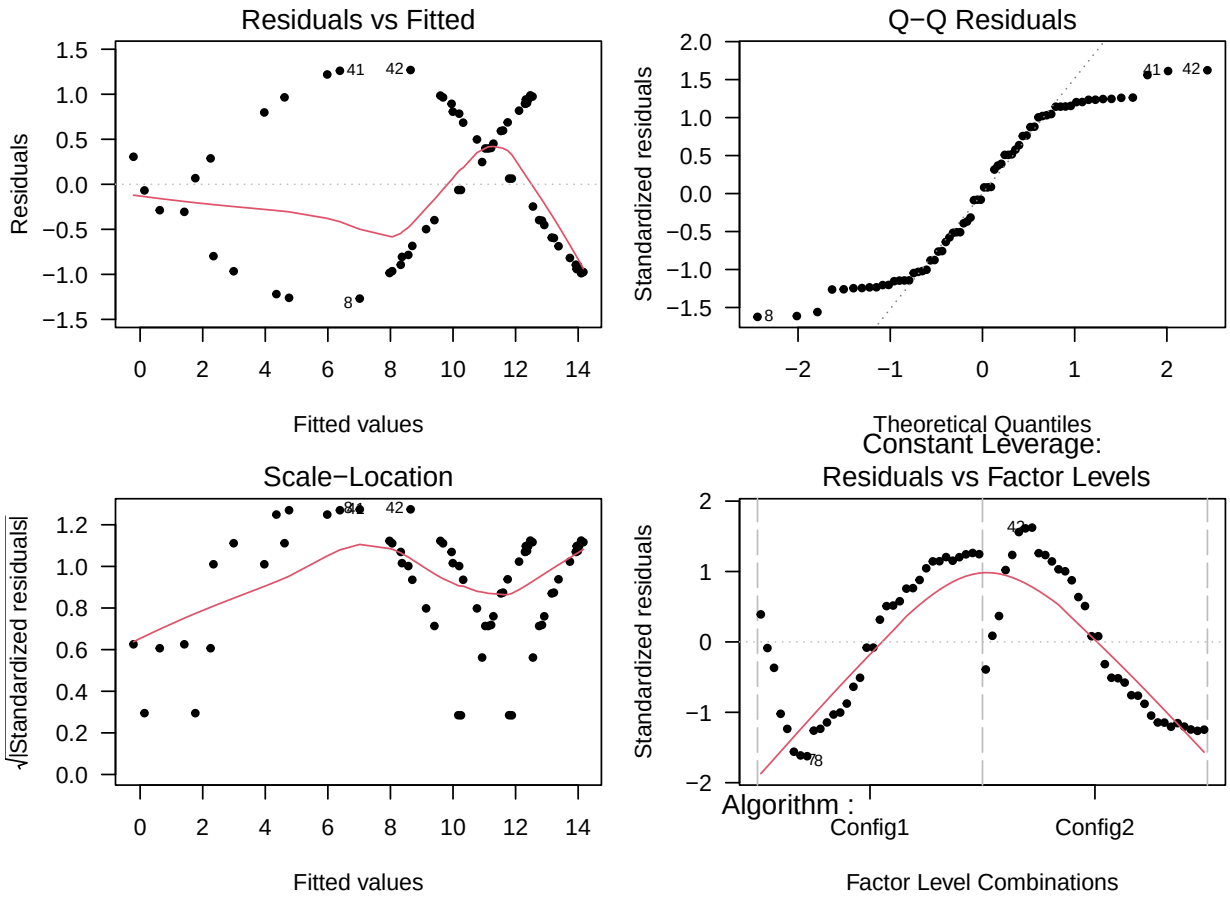


Figura 4: Gráficos diagnósticos dos resíduos do modelo linear RCBD para $\log(\bar{Y}_{ij})$

```r
shapiro_D   <- shapiro.test(block_wide$D)
res_rcbd    <- residuals(modelo_rcbd)
shapiro_res <- shapiro.test(res_rcbd)

dados_rcbd$res <- res_rcbd
fligner_res    <- fligner.test(res ~ Algorithm, data = dados_rcbd)
fligner_log    <- fligner.test(log_Y ~ Algorithm, data = dados_rcbd)

par(mfrow = c(1, 2), mar = c(4.2, 4.2, 2, 1))
car::qqPlot(block_wide$D, pch = 20, id = FALSE,
            main = "Q-Q Plot: Diferenças D_j",
            ylab = "Quantis observados (D_j)",
            xlab = "Quantis teóricos (Normal)")
car::qqPlot(res_rcbd, pch = 20, id = FALSE,
            main = "Q-Q Plot: Resíduos do RCBD",
            ylab = "Quantis observados (Resíduos)",
            xlab = "Quantis teóricos (Normal)")
```

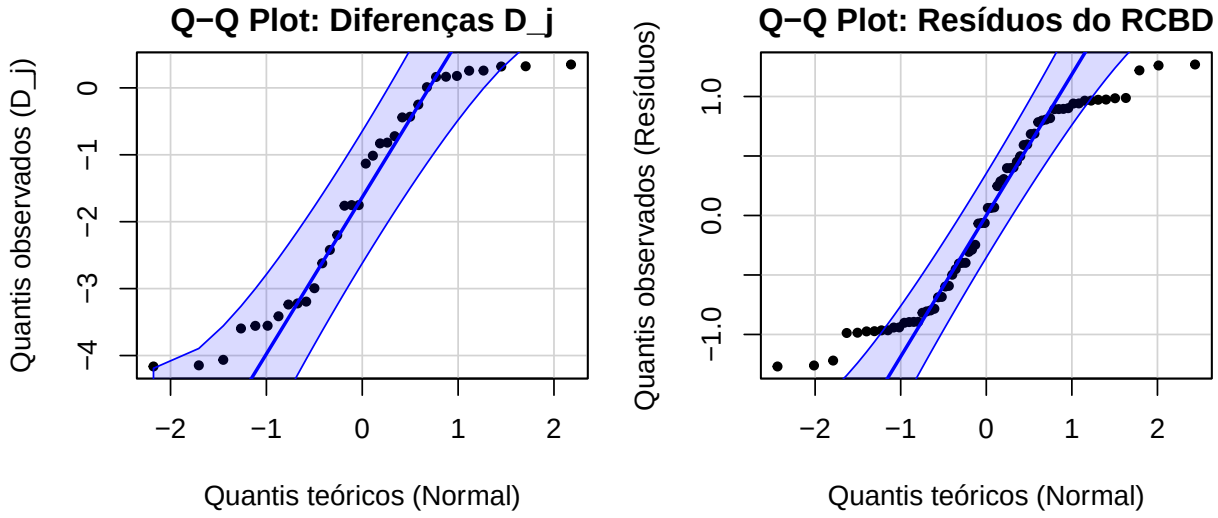


Figura 5: Gráficos Q-Q Normal com envelope de confiança de 95%: diferenças pareadas D_j (esquerda) e resíduos do RCBD (direita)

```r
tabela_prem <- data.frame(
  Premissa = c("Normalidade das diferenças pareadas ($D_j$)",
               "Normalidade dos resíduos do RCBD ($\\hat{\\epsilon}_{ij}$)",
               "Homocedasticidade dos resíduos por tratamento"),
  Teste = c("Shapiro-Wilk", "Shapiro-Wilk", "Fligner-Killeen"),
  Estatistica = c(sprintf("$W = %.4f$", shapiro_D$statistic),
                  sprintf("$W = %.4f$", shapiro_res$statistic),
                  sprintf("$\\chi^2 = %.4f$ (g.l. = 1)", fligner_res$statistic)),
  p_valor = c(sprintf("%.4f", shapiro_D$p.value),
              sprintf("%.4f", shapiro_res$p.value),
              sprintf("%.4f", fligner_res$p.value)),
  Decisao = c("Rejeita $H_0$ (Não normal)",
              "Rejeita $H_0$ (Não normal)",
              "Não rejeita $H_0$ (Homocedástico)"),
  check.names = FALSE
```

```
)

cap_prem <- paste0(
  "\\label{tab:premissas}Síntese dos testes formais de verificação ",
  "das premissas ($\\alpha = 0{,}05$)"
)

knitr::kable(
  tabela_prem,
  caption   = cap_prem,
  col.names = c("Premissa Avaliada", "Teste Estatístico", "Estatística",
                "Valor-$p$", "Conclusão ($\\alpha = 0{,}05$)"),
  align     = c("l", "c", "c", "c", "c"),
  booktabs  = TRUE,
  escape    = FALSE
)
```

Tabela 8: Síntese dos testes formais de verificação das premissas ($\alpha = 0{,}05$)

Premissa Avaliada	Teste Estatístico	Estatística	Valor-p	Conclusão ($\alpha = 0{,}05$)
Normalidade das diferenças pareadas (D_j)	Shapiro-Wilk	$W = 0.8934$	0.0031	Rejeita H_0 (Não normal)
Normalidade dos resíduos do RCBD ($\hat{\epsilon}_{ij}$)	Shapiro-Wilk	$W = 0.9132$	0.0002	Rejeita H_0 (Não normal)
Homocedasticidade dos resíduos por tratamento	Fligner-Killeen	$\chi^2 = 0.0005$ (g.l. = 1)	0.9827	Não rejeita H_0 (Homocedástico)

A avaliação é sintetizada na Tabela 8 e nas Figuras 4 e 5 demonstra que:

- **Independência:** É assegurada diretamente pelo protocolo experimental: cada instância corresponde a um espaço dimensional distinto, todas as execuções utilizaram sementes pseudoaleatórias, e a variável resposta (F_{best}) depende unicamente da trajetória estocástica do algoritmo, sendo imune a flutuações de tempo de máquina.
- **Homocedasticidade:** O teste não paramétrico de Fligner-Killeen sobre os resíduos do modelo RCBD ($\chi^2 = 0{,}0005$; $p = 0{,}9827$) confirma a homogeneidade de variâncias entre os níveis do fator experimental (nota-se que, para $a = 2$ tratamentos em blocos completos, os resíduos satisfazem $\hat{\epsilon}_{1j} = -\hat{\epsilon}_{2j} = (D_j - \bar{D})/2$, possuindo dispersão simétrica entre os dois grupos). Contudo, o gráfico *Residuals vs Fitted* (Figura 4) exibe uma estrutura sistemática em função da magnitude ajustada (dimensão), refletindo a interação entre configuração e dimensão discutida na Seção 3.
- **Violação da Normalidade:** Tanto o teste de Shapiro-Wilk sobre as diferenças pareadas D_j ($W = 0{,}8934$; $p = 0{,}0031 < 0{,}05$) quanto sobre os resíduos do RCBD ($W = 0{,}9133$; $p = 0{,}0002 < 0{,}05$) **rejeitam a hipótese nula de normalidade**. Os gráficos Q-Q (Figura 5) mostram afastamentos nas caudas (formato em "S"), provocados pela concentração de valores positivos leves ($D_j \in [0{,}01; 0{,}35]$) nas dimensões acima de 128 em contraste com os valores fortemente negativos ($D_j \approx -4{,}1$) nas dimensões intermediárias.

6. Derivação de Conclusões e Recomendações

7. Discussão sobre Possíveis Limitações do Estudo e Sugestões de Melhoria

Declaração de uso de IA generativa e tecnologias assistidas por IA

Durante a preparação deste trabalho, os autores utilizaram ferramentas de inteligência artificial generativa (Claude Opus 4.6, da Anthropic, e Gemini, do Google) com o objetivo de auxiliar na estruturação de código em R, formatação de tabelas em R Markdown e revisão técnica e textual do relatório. Após a utilização dessas ferramentas, os autores conferiram todos os cálculos, revisaram e editaram o conteúdo integralmente, assumindo total responsabilidade pela exatidão e integridade do material publicado.

Papéis e Contribuições da Equipe

- **Beatriz S. Campagnaro:** Desenvolvimento dos scripts estatísticos em R, redação do manuscrito e revisão técnica.
- **Filipe C. Andrade:** Desenvolvimento dos scripts estatísticos em R, redação do manuscrito e revisão técnica.
- **Izabela C. S. Barbosa:** Desenvolvimento dos scripts estatísticos em R, redação do manuscrito e revisão técnica.

Referências

BOSSEK, J. smoof: Single- and Multi-Objective Optimization Test Functions. *The R Journal*, v. 9, n. 1, p. 103–113, 2017.

CAMPELO, F.; BOTELHO, M. Experimental investigation of recombination operators for differential evolution. In: *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO'2016)*, p. 533–540, 2016.

CAMPELO, F. *Lecture Notes on Design and Analysis of Experiments*. Versão 2.12, 2018. Disponível em: http://git.io/v3Kh8.

CAMPELO, F.; TAKAHASHI, F. Sample size estimation for power and accuracy in the experimental comparison of algorithms. *Journal of Heuristics*, v. 25, n. 2, p. 305–338, 2019.

DAVISON, A. C.; HINKLEY, D. V. *Bootstrap Methods and Their Application*. Cambridge: Cambridge University Press, 1997.

ERNST, M. D. Permutation methods: a basis for exact inference. *Statistical Science*, v. 19, n. 4, p. 676–685, 2004.

FENG, C.; WANG, H.; LU, N.; TU, X. M. Log transformation: application and interpretation in biomedical research. *Statistics in Medicine*, v. 32, n. 2, p. 230–239, 2013.

MONTGOMERY, D. C. *Design and Analysis of Experiments*. 7. ed. Hoboken: John Wiley & Sons, 2005.

MONTGOMERY, D. C.; RUNGER, G. C. *Applied Statistics and Probability for Engineers*. 5. ed. Hoboken: John Wiley & Sons, 2010.

POHLHEIM, H. *Examples of Objective Functions*. 2005. Disponível em: http://www.geatbx.com/download/GEATbx_ObjFunExpl_v37.pdf.

ROSENBROCK, H. H. An automatic method for finding the greatest or least value of a function. *The Computer Journal*, v. 3, n. 3, p. 175–184, 1960.

SHESKIN, D. J. *Handbook of Parametric and Nonparametric Statistical Procedures*. 3. ed. Boca Raton: Chapman and Hall/CRC, 2003.

SPRENT, P.; SMEETON, N. C. *Applied Nonparametric Statistical Methods*. 3. ed. Boca Raton: Chapman and Hall/CRC, 2000.

STORN, R.; PRICE, K. Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, v. 11, n. 4, p. 341–359, 1997.